

ETL proces

SKLADIŠTA I RUDARENJE PODATAKA

izv. prof. dr. sc. Goran Oreški
*Fakultet informatike,
Sveučilište Jurja Dobrile, Pula*

Sadržaj

- ponavljanje
- ETL proces
- pripremno područje skladišta podataka
- izdvajanje podataka
- transformacija
- punjenje podatka
- real-time skladišta podataka

Projekt

- punjenje dimenzijskog modela podacima
- u prošlom koraku smo stvorili model
 - simulacija više izvora podataka
- danas punimo model s podacima
 - transformiramo i čistimo podatke
- proći ćemo ETL koristeći
 - Apache Spark (Python)
 - možete koristiti druge alate
- nekada smo koristili Pentaho Data Integration!
 - nije više otvoren, promjena prava korištenja
 - grafički alati se polako napuštaju

Modeliranje skladišta podataka

- izrada modela skladišta podataka
- entiteti modela
 - tablice činjenica
 - dimenzijske tablice
- relacije
- atributi
 - surogat ključevi
 - hijerarhije

Modeliranje skladišta podataka

- napredne teme
- vrste dimenzija
 - mini dimenzije
 - degenerirane dimenzije
 - usklađene dimenzije
 - sporo mijenjajuće dimenzije
- vrste tablica činjenica
 - modeli
 - pravovremenost podataka

Punjenje i osvježavanje

- jednom stvoren dimenzijski model podataka potrebno je puniti podacima iz transakcijskog sustava
- složen proces s mnogo parametara
 - način punjenja, praćenje promjena. frekvencija punjenja
- osnovne operacije u procesu punjenja su:
 - izdvajanje
 - transformiranje
 - učitavanje




ETL proces

- ETL proces (Extract, Transform, Load)
- odgovoran je za:
 - izdvajanje podataka iz transakcijskog sustava u pripremno područje
 - transformaciju podataka
 - čišćenje podataka
 - transformacija u strukturu za dimenzijski model
 - učitavanje podataka u skladište podataka
- zahtjevan dio izrade skladište podataka (implementacija i održavanje)
- specifičan za svaku organizaciju, sustav

ETL proces

- svaki korak ima svoje izazove:
 - *izdvajanje (ekstrakcija) podataka*
 - detektiranje promjena
 - više izvora podataka...
 - *transformacija i čišćenje*
 - način transformacije i čišćenja
 - mogućnost različitosti podataka...
 - *punjenje skladišta podataka*
 - način učitavanja...

ETL proces



Izdvajanje podataka

- bitan aspekt izdvajanja podataka je briga o transakcijskom (izvorišnom) sustavu organizacije
- produkcijski sustav ne smije biti ugrožen prikupljanjem podataka za skladište podataka
- potrebno je paziti:
 - da se podaci ne mijenjaju (ili izgube) u izvorišnom sustavu
 - da se ne (ili što manje) mijenja konfiguracija sustava
 - na performanse (zaključavanje) izvorišnog sustava prilikom izdvajanja podataka (vrijeme izdvajanja podataka?)

Pripremno područje

- *engl. staging area*
- pripremno područje izvornih podatka za transformaciju i čišćenje podataka
 - kopija transakcijskog sustava
- korisnici nemaju pristup pripremnom području
- upiti ne mogu pristupiti podacima u pripremnom području
 - tablice mogu biti dodane ili izbrisane bez pravila
- iz pripremnog područja se puni skladište podataka

Izdvajanje podataka

- način izdvajanja podataka:
 - potpuno
 - prvo izdvajanje (*initial load*)
 - *full load*
 - djelomično
 - inkrementalna nadopuna podacima koji su se promijenili od vremena zadnjeg uspješnog ETL procesa
 - različite strategije za pronalazak promjena u izvorišnom sustavu

Izdvajanje podataka

- izdvajanje podataka se odvija periodično (ovisno o potrebama tvrtke), pozadinskim procesom
- **prvo punjenje** podacima prilikom uspostave skladišta podataka
 - obuhvaća sve dostupne podatke iz izvora
- često je manje komplicirano od periodičkog osvježavanja
 - manje problema
 - ne mora se voditi briga već o učitanim podacima
- zahtjeva posebnu verziju ETL procesa

Izdvajanje podataka

- skladište podataka može biti jedini izvor povijesnih podataka neke tvrtke
- obavljanje procesa inicijalnog punjenja iznova (treba paziti na povijesne podatke)
- dohvat iz svih dostupnih izvora i uspoređivanje podataka na odredištu
- nije praktično za veća i kompleksnija skladišta podataka

Izdvajanje podataka

- inkrementalna nadopuna podataka (ažuriranje) dodaje podatke koji nisu bili obuhvaćeni prošlim punjenjem
- frekvencija ažuriranja ovisi o poslovnom procesu
 - na dnevnoj razini
- real-time skladišta podataka - posebna vrsta
- kompleksniji proces od punjenja iznova
- bitan element procesa je detektiranje promjena na izvorišnom sustavu

Izdvajanje podataka

- sposobnost detektiranja promijenjenih podataka u izvorišnom sustavu i njihovo prikupljanje se zove *Change Data Capture (CDC)*
- neke od CDC tehnika:
 - dodavanje vremenske oznake
 - razlika snimki stanja
 - aplikacijsko bilježenje promjena
 - korištenjem okidača (*trigger*) baze podataka
 - korištenje dnevnika transakcija

Izdvajanje podataka

- dodavanje vremenske oznake
- dodavanje posebnog atributa koji prati vrijeme
 - dan, sat, minuta, sekunda
- ETL proces uspoređuje vrijeme zadnje ekstrakcije i oznaku vremena na pojedinom zapisu
- ograničenja:
 - zadnja izmjena
 - obrisani zapisi (A)

Izdvajanje podataka

- razlika snimki stanja
- uspoređivanjem podataka zapis po zapis s podacima iz prethodnog ažuriranja
- stara snimka mora biti zadržana u pripremnom području
- dobar pristup kada se ne može koristiti neki od naprednijih CDC pristupa
- zahtjeva dosta resursa i vremena
- jednostavnija za implementaciju, pronalazi sve promjene

Izdvajanje podataka

- aplikacijsko bilježenje promjena
- bilježenje promjena na posebno mjesto (tablicu) predviđeno za tu namjenu
- svi aplikacijski programi moraju jednako evidentirati promjene da bi sustav funkcionirao
- složeno za implementaciju, potreban je veliki angažman za promjenu aplikacija
- pogodno ukoliko se koriste baze podataka koje ne podržavaju mehanizme za praćenje promjena

Izdvajanje podataka

- korištenjem okidača baze podataka
- mehanizmi su okidači (*trigger*) i pohranjene procedure (*stored procedures*)
- bilježe svaki promjenu na zapisu (*insert, update i delete*) i bilježe u log tablicu
- mogu se pohranjivati različiti log podaci dostupni bazi
- velike izmjene na bazi podataka, opterećenje baze podataka
- okidače treba vrlo oprezno koristiti

Izdvajanje podataka

- korišćenje dnevnika transakcija
- sustavi za osiguravanje obnove podataka (*data recovery*) koje pružaju DBMS
- podaci se čuvaju u dnevniku transakcija, vrsta podataka ovisi o implementaciji
- izvlačenje podataka zahtjeva razvoj posebnog algoritma
- sinkronizacija s ETL procesom

Izdvajanje podataka

- usporedba CDC tehnika

Utjecaj na:	izvorišnu bazu	aplikacije	složenost implementacije	evidencija povijesti	performanse izvornog sus.
dodavanje vremenske oznake	srednji	nema	niska	slaba	nizak
razlika snimki stanja	nema	nema	niska	nema	nizak
aplikacijsko bilježenje promjena	nema	visok	visoka	visoka	visoka
korištenjem okidača baze podataka	visok	nema	srednja	visoka	visoka
korištenje dnevnika transakcija	nema	nema	srednja	visoka	nizak

Transformacija

- drugi korak u ETL procesu
- izvodi se u pripremnom području
 - razlozi stvaranja pripremnog područja?
- transformacija podrazumijeva:
 - analizu podataka
 - čišćenje podataka
 - transformaciju u odgovarajuću strukturu za dimenzijski model podataka
- operacije se izvršavaju slijednim redoslijedom (*pipelining order*)

Transformacija


- čišćenje podataka – zašto?
- kvaliteta podataka koji se učitavaju u skladište podatka!
- bitne karakteristike:
 - ispravnost
 - nedvosmislenost
 - konzistentnost
 - potpunost

Transformacija

ID	Ime	God. rođ.	Starost	Spol	Telefon	Pošta
233	Anić, Ivan	13.4.80	26	M	999999999	51000
233	Petra Ivić	33.4.87	32	M	01234568	99999
234	Ivan Anić	13.4.80	36	M	051236543	51000

Pošta	Grad
44000	Sisak
51000	Rjeka
1000	Hrvatska

Transformacija



Transformacija

- testovi kvalitete (engl. Quality Screens QS)
- su testovi u procesu ETL-a, koji se javljaju ukoliko podaci ne prođu određeni test kvalitete
- ukoliko se javi greška aktivira se QS, i bilježi se u shemu grešaka (*engl. error event shema*)
- različite vrste testova grešaka:
 - stupčani testovi
 - strukturni testovi
 - testovi poslovnih pravila

Transformacija

- shema grešaka
- dimenzijski modela koji ima cilj evidentiranja svih grešaka koje su se dogodile u ETL procesu
- ukoliko se aktivira test kvalitete bilježi se u shemu grešaka
- tablica činjenica je događaj greške
 - granularnost – svaka greška u ETL-u
- dimenzije
 - vremenska, obrada u kojoj se greška dogodila, test kvalitete...

Transformacija

- revizorska dimenzija (*engl. audit dimension*)
- činjeničnoj tablici se pridjeljuje dimenzija s metapodacima koji opisuju kvalitetu podataka
- pridjeljuju se svakom zapisu tablice činjenica
- sadrži ETL podatke o procesiranju i kvaliteti podataka
- može se koristiti shema grešaka da bi se ispitalo da li je bilo problema s kvalitetom tijekom ETL procesa

Transformacija

- transformacija u odgovarajuću strukturu za dimenzijski model podataka
- izgradnja dimenzija
 - uklanjanje duplih dimenzijskih zapisa
 - mehanizam sporo mijenjajućih dimenzija
 - generiranje surogat ključeva
- izgradnja tablice činjenica
 - povezivanje s dimenzijama

Punjenje

- nakon transformacije podataka dolazi punjenje u dimenzijski model podataka
- punjenje podataka je moguće:
 - odjednom
 - zapis po zapis
- odabir metoda ovisi o specifičnom procesu, punjenje odjednom je vremenski manje zahtjevno
- akcije prilikom punjenja podataka, zapise treba:
 - dodati
 - izmijeniti
 - brisati

Real-time skladišta podataka

- nastojanje da se vremensko kašnjenje skladišta podataka smanji na što moguću razinu
- stvarni real-time?
- izazovi u implementaciji skladišta podataka koja u realnom ili gotovo realnom vremenu puni podatke
- izmjene ETL procesa
- mini obrade podataka
- interakcija postojećih i novih zapisa

Projekt



Checkpoint 1 – Odabir i analiza podataka

- pronaći skup podataka
- definirati temu za Case study
- analizirati podatke



Checkpoint 2 – Stvaranje relacijskog modela podataka

- definirati entitete, attribute, veze i kardinalnost veza
- nacrtati ER dijagram (konceptualni model)
- nacrtati EER dijagram (logički model)
- implementirati model u nekom DBMS (npr. MySQL)
- učitati podatke u relacijsku bazu




Projekt



Checkpoint 3 – stvaranje dimenzijskog modela podataka

- pronaći u skupu podataka mjeru koja će se nalaziti u tablici činjenica
 - kvantitativan podatak ili tablica činjenica bez činjenica
- pronaći 5 različitih dimenzija u skupu podataka
 - kvalitativni podaci
- pronaći ili definirati hijerarhije u dimenzijskim tablicama
 - 2-3 hijerarhije u 2 dimenzije, jedna degenerirana dimenzija
- napraviti star shemu
 - ili snowflake
- uključite napredne mogućnosti izvedbe dimenzijskog modela
 - sporo mijenjajuće dimenzije, različite izvedbe dimenzijskih tablica
 - ...




Projekt



Checkpoint 4 – punjenje dimenzijskog modela podataka

- napuniti skladište podataka iz barem 2 izvora
- provesti ETL proces
- provjeriti unos podataka
- provjeriti da nema izgubljenih podataka



Literatura

Pročitati:

Kimball, R., Ross, M., Thornthwaite, W., Mundy, J., & Becker, B. (2008). *The data warehouse lifecycle toolkit*. John Wiley & Sons. – **poglavlje 9 i 10**

Vezana stranica:

Kimball group web stranica <https://www.kimballgroup.com/>