



Fakultet informatike u Puli

Analiza helpdesk sustava i optimizacija procesa rješavanja ticketa

Seminarski rad

Ime i Prezime: Igor Pavlić

JMBAG: 0069012453

Kolegij: Skladišta i rudarenje podataka

Mentor: izv. prof. dr. sc. Goran Oreški

Senj, svibanj 2026.

Sadržaj

1. Uvod
2. Eksplorativna analiza podataka (EDA)
 - 2.1. Odabir i opis skupa podataka
 - 2.2. Analiza skupa podataka
 - 2.3. Predprocesiranje podataka
3. Dizajn i implementacija relacijskog modela
 - 3.1. Priprema i podjela podataka
 - 3.2. Konceptualni model (ER dijagram)
 - 3.3. Relacijski model baze podataka
 - 3.4. Implementacija baze u MySQL-u
 - 3.5. Provjera podataka
4. Dimenzijski model podataka
 - 4.1. Osnove dimenzijskog modeliranja
 - 4.2. Izrada zvjezdastog (star) modela
5. ETL proces
 - 5.1. Ekstrakcija podataka
 - 5.2. Transformacija podataka
 - 5.3. Učitavanje podataka
6. Vizualizacija i poslovna analiza
 - 6.1. Dashboard #1 — Pregled sustava
 - 6.2. Dashboard #2 — Analiza outliera
 - 6.3. Dashboard #3 — Distribucija
 - 6.4. Dashboard #4 — Kvaliteta podataka
7. Generalizacija rezultata
8. Zaključak
9. Literatura

1. Uvod

U suvremenom poslovnom okruženju, helpdesk sustavi generiraju velike količine podataka o korisničkim zahtjevima, njihovom rješavanju i performansama tima podrške. Učinkovita analiza ovih podataka ključna je za optimizaciju procesa, smanjenje vremena rješavanja i bolje planiranje resursa.

U ovom radu razvijen je sustav poslovne inteligencije koristeći stvarni skup podataka helpdesk ticketa koji sadrži 66.691 zapis iz 15 projekata u periodu od 2007. do 2023. godine. Podaci uključuju informacije o životnom ciklusu svakog ticketa: tko ga je prijavio, tko rješava, koliko koraka je prošao kroz workflow, koliko vremena je proveo u svakom stanju i kako je završen.

Rad obuhvaća cijeli proces izgradnje skladišta podataka — od eksplorativne analize i čišćenja podataka, preko dizajna relacijskog i dimenzijskog modela, do ETL procesa i vizualizacije u Power BI-ju. Cilj je demonstrirati kako se kroz proces poslovne inteligencije može razviti sustav za analizu učinkovitosti helpdesk sustava i identifikaciju uskih grla u procesu rješavanja ticketa.

2. Eksplorativna analiza podataka (EDA)

2.1. Odabir i opis skupa podataka

Skup podataka preuzet je s platforme za dijeljenje istraživačkih podataka i sadrži helpdesk tickete iz stvarnog helpdesk sustava. Izvorni dataset ([Support_tickets_named.csv](#)) sadrži 66.691 redaka i 58 stupaca.

Ključne karakteristike skupa podataka:

Karakteristika	Vrijednost
Broj ticketa	66.691
Period	2007 — 2023
Broj projekata	15
Broj osoba	100 (reporteri + tehničari)
Stupaca	58 (identifikatori, datumi, kategorije, workflow metrike)

Stupci se dijele u nekoliko kategorija: identifikatori (id, issue_num), kategorijski atributi (issue_proj, issue_type, issue_priority, issue_status, issue_resolution), datumski stupci (issue_created, issue_resolution_date), numeričke metrike (wf_total_time, processing_steps, issue_comments_count) i workflow stupci — za svako stanje postoji `wf_{stanje}` (vrijeme provedeno u stanju, u sekundama) i `wfe_{stanje}` (broj ulazaka u stanje).

2.2. Analiza skupa podataka

Eksplorativna analiza otkrila je nekoliko ključnih karakteristika dataseta:

Nedostajuće vrijednosti: 51% ticketa ima prioritet "unknown", 47% nema dodijeljenog tehničara (assignee), a 16 od 58 stupaca ima više od 90% NULL vrijednosti (rijetko korišteni workflow statusi poput wf_deployment, wf_cancelled, wf_validation).

Distribucija tipova ticketa: Ticket dominira (68%), zatim Service (8%), Subtask (7%), Story (7%), i ostali tipovi s manjim udjelima.

Distribucija prioriteta: Unknown (51%), Medium (37%), High (7%), Highest (3%), Blocker (1%), Low (1%), Lowest (<1%).

Tri segmenta ticketa: Analiza je otkrila da dataset sadrži tri potpuno različite populacije: "ghost ticketi" (33%) — ticketi s jednim korakom, unknown prioritetom i bez assignee, s medijanom rješavanja od 2.277 dana; aktivni ticketi s assigneeom (53%) — medijan 9 dana; i ostali (14%) — medijan 15 dana.

Slika 1: Rezultati eksplorativne analize

2.3. Predprocesiranje podataka

Predprocesiranje je provedeno u sljedećim koracima:

1. **Uklanjanje stupaca s >90% NULL:** Uklonjeno je 16 stupaca čiji podaci nisu dovoljno zastupljeni za analizu. Od 58 stupaca ostalo je 42.
2. **Standardizacija naziva:** Svi nazivi stupaca pretvoreni su u lowercase s underscore separatorom.
3. **Provjera duplikata:** Potvrđeno je da nema duplikata u datasetu.
4. **Podjela na trening i test skup:** Dataset je podijeljen na 80% za dizajn i implementaciju (53.353 redaka) i 20% za validaciju generalizacije (13.338 redaka) korištenjem fiksnog seeda (`random_state=1`) za reproducibilnost.

Slika 2: Rezultati predprocesiranja

3. Dizajn i implementacija relacijskog modela

3.1. Priprema i podjela podataka

Glavni CSV skup podataka podijeljen je na dva dijela: 80% podataka korišteno je za dizajn, implementaciju i punjenje svih tablica u relacijskoj bazi, čime je osigurano da su svi entiteti i odnosi ispravno definirani. Preostalih 20% izdvojeno je za provjeru ispravnosti ETL procesa i validaciju analitičkih modela.

3.2. Konceptualni model (ER dijagram)

Na temelju analize podataka identificirano je sedam glavnih entiteta: project, person, issue_type, priority, status, resolution i centralna tablica support_ticket. Svaki entitet izvučen je iz originalnog flat CSV-a normalizacijom.

Ključne karakteristike modela:

- `person` se referencira dvaput iz `support_ticket` — jednom kao reporter, jednom kao assignee
- `assignee_fk` je nullable jer 46% ticketa nema dodijeljenu osobu
- Svi lookup entiteti imaju INT primarni ključ i VARCHAR atribut

Slika 3: ER dijagram relacijskog modela

3.3. Relacijski model baze podataka

Relacijski model implementiran je kao staging tablica `support_tickets` u MySQL bazi `fipu_srp_projekt`. Umjesto standardnog `to_sql()` koji generira neoptimalne tipove podataka (datume kao TEXT, ID-ove kao DOUBLE), definirano je 42 eksplicitnih SQL tipova korištenjem SQLAlchemy `dtype` parametra:

- Datumi (`started`, `issue_created`, itd.) → DATETIME umjesto TEXT
- Identifikatori (`id`, `issue_num`) → INTEGER umjesto DOUBLE
- Stringovi (`issue_proj`, `issue_type`, itd.) → VARCHAR(50/255) umjesto TEXT
- Workflow trajanja (`wf_open`, `wf_total_time`, itd.) → FLOAT

3.4. Implementacija baze u MySQL-u

Implementacija je provedena korištenjem Pythona (pandas + SQLAlchemy) s `python-dotenv` za sigurno upravljanje pristupnim podacima. Lozinka baze nikada nije hardkodirana u notebookovima, već se čita iz `.env` datoteke.

Import u bazu izvršen je s `to_sql(if_exists='replace', dtype=sql_dtypes, chunksize=5000)` za batch unos podataka.

Slika 4: Rezultat importa u MySQL — DESCRIBE support_tickets

3.5. Provjera podataka

Nakon importa provedeno je pet provjera kvalitete:

Provjera	Rezultat
Broj redaka CSV = SQL	53.353 = 53.353 ✓
Dupli ID-ovi	0 ✓
NULL u ključnim stupcima	Samo assignee: 24.771 (46%) — očekivano
Konzistentnost mapiranja	1 projekt = 1 ime ✓
Distribucije	Poklapaju se s EDA ✓

4. Dimenzijski model podataka

4.1. Osnove dimenzijskog modeliranja

Za razliku od relacijskog modela koji je optimiziran za transakcijsku obradu (OLTP), dimenzijski model organizira podatke za analitičke upite (OLAP). Centralna tablica činjenica sadrži numeričke metrike i strane ključeve prema dimenzijskim tablicama koje sadrže opisne atribute.

U ovom projektu dimenzijski model temelji se na analizi poslovnog procesa helpdesk podrške. Svrha je omogućiti višedimenzionalni pogled na performanse rješavanja ticketa kroz različite aspekte: projekt, prioritet, status, tip ticketa, rezoluciju, tehničara i vrijeme.

4.2. Izrada zvjezdastog (star) modela

Star shema sastoji se od 5 dimenzijskih tablica i 1 tablice činjenica:

Dimenzijske tablice:

Dimenzija	PK	Atributi	Redaka
dim_tehnicar	tehtnicar_key (INT AI)	ime_prezime	100
dim_projekt_prioritet_status	projekt_prioritet_status_key (INT AI)	naziv_projekta, razina_prioriteta, naziv_statusa	~330
dim_tip_ticketa	tip_ticketa_key (INT AI)	naziv_tipa	15
dim_rezolucija	rezolucija_key (INT AI)	naziv_rezolucije	4
dim_vrijeme	vrijeme_key (DATE)	dan, mjesec, godina, kvartal, dan_u_tjednu	~4.700

dim_projekt_prioritet_status je junk dimenzija koja kombinira tri kategorijske varijable (projekt, prioritet, status) u jednu tablicu. Teoretski max je $15 \times 7 \times 15 = 1.575$ kombinacija, ali samo ~330 stvarno postoji u podacima.

dim_tehnicar se koristi dvostruko — kao reporter i kao assignee, pri čemu je assignee nullable (46% ticketa nema dodijeljenog tehničara).

Grain: Jedan redak u tablici **fact_support_tickets** predstavlja jedan helpdesk ticket.

Tablica činjenica **fact_support_tickets:**

Stupac	Tip	Opis
ticket_id	INT PK	Primarni ključ
reporter_key	INT FK	→ dim_tehnicar
assignee_key	INT FK (nullable)	→ dim_tehnicar
projekt_prioritet_status_key	INT FK	→ dim_projekt_prioritet_status
tip_ticketa_key	INT FK	→ dim_tip_ticketa
rezolucija_key	INT FK (nullable)	→ dim_rezolucija
vrijeme_key	DATE FK	→ dim_vrijeme
vrijeme_rjesavanja_sati	FLOAT	Ukupno vrijeme rješavanja (sati)
broj_komentara	INT	Broj komentara na ticketu
sati_open	FLOAT	Vrijeme u stanju "open" (sati)
sati_in_progress	FLOAT	Vrijeme u stanju "in_progress" (sati)
sati_resolved	FLOAT	Vrijeme u stanju "resolved" (sati)
sati_waiting	FLOAT	Vrijeme u stanju "waiting" (sati)

DDL je implementiran korištenjem SQLAlchemy ORM-a s `declarative_base()` pristupom, gdje je svaka tablica definirana kao Python klasa, a `Base.metadata.create_all(engine)` automatski generira DDL s FK constraintima.

Surrogate key logika: Sve dimenzije koriste surrogate ključeve (AUTO_INCREMENT INT) umjesto prirodnih ključeva iz izvornog sustava. Prednosti su stabilnost identifikatora, bolje performanse JOIN operacija i podrška za eventualnu historizaciju (SCD).

Slika 5: Star shema — ER dijagram dimenzijskog modela

5. ETL proces

ETL (Extract, Transform, Load) proces je ključni dio projekta koji transformira podatke iz dva izvora u dimenzijski model spreman za analizu.

5.1. Ekstrakcija podataka

ETL proces koristi dva izvora podataka prema arhitekturi pripremnog područja (staging area):

Izvor 1 — `Support_tickets_PROCESSED.csv` je predprocesirani 80% skup s 53.353 redaka i 42 stupca. Nastao je u notebooku 2 uklanjanjem stupaca s >90% NULL vrijednosti i stratificiranim uzorkovanjem. Iz njega se grade sve dimenzije i fact tablica.

Izvor 2 — `Support_tickets_named.csv` je originalni puni dataset s 66.691 redaka i 58 stupaca. Sadrži 16 rijetkih `wf_*` stupaca koji su izbačeni predprocesiranjem (>90% NULL) ali ipak sadrže stvarne podatke za podskup ticketa:

Stupac	Non-null redaka	Prosjek (sati)
wf_validation	2.961	603h
wf_reopened	2.123	43h
wf_resolved_under_monitoring	1.931	307h
wf_approved	1.630	190h
wf_pending_deployment	1.413	875h

Oba izvora se spajaju u EXTRACT fazi LEFT JOIN-om po `id` stupcu — čime se čuva svih 53.353 ticketa iz Izvora 1, a Izvor 2 obogaćuje zapise s dodatnim workflow podacima gdje postoje.

5.2. Transformacija podataka

Transformacija uključuje dva ključna koraka:

Izračun metrika:

Metrika	Izvor	Formula
vrijeme_rjesavanja_sati	Izvor 1: <code>issue_resolution_date</code> – <code>issue_created</code>	<code>dt.total_seconds()</code> / <code>3600</code>

Metrika	Izvor	Formula
sati_open	Izvor 1: wf_open (sekunde)	/ 3600
sati_in_progress	Izvor 1: wf_in_progress (sekunde)	/ 3600
sati_resolved	Izvor 1: wf_resolved (sekunde)	/ 3600
sati_waiting	Izvor 1: wf_waiting (sekunde)	/ 3600
sati_validation, sati_reopened...	Izvor 2: wf_* (sekunde)	/ 3600

Ispravnost pretvorbe potvrđena je ručnom provjerom: ticket 11887 ima `wf_total_time = 1992`, a razlika između `issue_created` (08:23:43) i `issue_resolution_date` (08:56:55) iznosi točno 1992 sekunde (33 minute i 12 sekundi).

Mapiranje stranih ključeva: Za svaku dimenziju proveden je merge (JOIN) između izvornih podataka i dimenzijskih tablica kako bi se prirodni ključevi zamijenili surrogate ključevima. Posebna pažnja posvećena je korištenju LEFT JOIN-a za assignee (46% NULL) i rezoluciju (1.3% NULL) kako ne bi došlo do gubitka redaka.

Slika 6: Rezultat ETL procesa — verifikacija broja redaka

5.3. Učitavanje podataka

Učitavanje je provedeno u batch modu (`chunksize=5000`) s privremenim isključivanjem FK provjera za performanse. Na kraju je verifikacijom potvrđeno da sve tablice sadrže očekivani broj redaka te da nema izgubljenih podataka:

Tablica	Redaka
dim_tehnicar	100
dim_projekt_prioritet_status	330
dim_tip_ticketa	15
dim_rezolucija	4
dim_vrijeme	~4.700
fact_support_tickets	53.353

Provjera gubitka podataka izvršena je programski: `assert len(fact_final) == 53353` — potvrđeno da nijedan redak nije izgubljen u procesu mapiranja stranih ključeva.

6. Vizualizacija i poslovna analiza

Vizualizacija je provedena u Power BI Desktopu korištenjem denormaliziranog SQL upita koji spaja fact tablicu sa svim dimenzijama. Dashboard se sastoji od četiri stranice.

6.1. Dashboard #1 — Pregled sustava

Prva stranica prikazuje ukupne KPI-eve i pregled sustava:

- **53.353 ticketa** iz 15 projekata, s prosječnim vremenom rješavanja od 18.441 sati i medijanom 834,89 sati
- **Trend kroz vrijeme:** Volumen ticketa varira značajno po godinama, s vrhuncem 2015. (5.700 ticketa) i padom 2022. (1.388)
- **Ticketi po projektu:** Project Apollo vodi s 6.554 ticketa, Project Nexus je najmanji s 1.439
- **Vrijeme po prioritetu:** Medium (1.521 sati) i Lowest (1.435 sati) su sporiji od Blockera (1.254 sati) — što ukazuje na nekonzistentnu primjenu prioriteta
- **Top assigneei po volumenu:** Petra Marić (1,9K), Petar Marić (1,8K), Maja Kovačić (1,7K)
- **Self-assigned ticketi:** Dodatno je prikazan pregled tehničara koji su sebi dodijelili tickete. Josip Marić vodi s 34 self-assigned ticketa, što može ukazivati na specifičan radni proces ili nedostatak delegacije unutar tima.

Slika 7: Dashboard — Pregled sustava

6.2. Dashboard #2 — Analiza outliera

Outlieri su definirani kao ticketi iznad 95. percentila (6.499 sati $\approx$ 271 dan) među ticketima s poznatim prioritetom.

- **Normal vs Outlier po projektu:** Udio outliera varira od 19% (Project Helios) do 45% (Project Orion). Project Titan i Project Nexus su bez outliera u prikazu što ukazuje na manji uzorak.
- **Najgori slučajevi po prioritetu:** Unknown prioritet dostiže max od 99.221 sati (~11 godina), Blocker do 42.164 sati, Medium do 48.927 sati
- **Workflow analiza po prioritetu:** Posebno se ističe kategorija Lowest prioriteta s prosječno 2.324 sata čekanja (waiting) — višestruko više od Blockera (256 sati). Ovo je kontrainuitivno i ukazuje da ticketi najnižeg prioriteta zapravo čekaju dulje nego kritični. Blocker ticketi imaju najveće prosječno vrijeme u stanju "open" (822 sata), dok Highest provodi najviše u "waiting" (378 sati).

Slika 8: Dashboard — Analiza outliera

6.3. Dashboard #3 — Distribucija

- **Matrica projekt $\times$ prioritet:** Heatmap prikazuje koncentraciju ticketa — "unknown" prioritet dominira u svim projektima. Project Apollo ima najveći apsolutni broj unknown ticketa (3.697), dok Project Solaris ima najmanji (1.284). Ukupno je 27.156 ticketa bez prioriteta (51%).
- **Histogram vremena rješavanja:** Više od 21.700 ticketa (41%) traje dulje od 3 mjeseca. Distribucija ima izrazito dug desni rep koji ukazuje na postojanje outliera.
- **Distribucija po tipu ticketa:** Ticket dominira s 67,8% (36,17K), a ostali tipovi — Story, Service, HD Service, Task i Subtask — zajedno čine preostalih 32%.
- **Distribucija po rezoluciji:** 92,94% ticketa je riješeno s "Done", dok 4,54% otpada na "(Blank)" — neriješene tickete — i 2,51% na "Won't Do".

Slika 9: Dashboard — Distribucija

6.4. Dashboard #4 — Kvaliteta podataka

Četvrta stranica dashboarda posvećena je analizi kvalitete podataka i segmentaciji ticketa.

- **Prioritet po projektu:** Stacked bar prikazuje distribuciju poznatog i nepoznatog prioriteta po projektu. Project Solaris ima najveći udio poznatog prioriteta (66%), dok Project Apollo ima najveći apsolutni broj nepoznatih prioriteta (3,7K).
- **Has Assignee:** 53,57% ticketa ima dodijeljen assignee, dok 46,43% (24,77K) nema. Ovaj podatak je ključan jer analiza pokazuje da ticketi bez assigneea imaju medijan rješavanja ~190 puta duži od onih s assigneeom.
- **Segmentacija ticketa:** Ghost ticketi imaju prosječno ~50.000 sati rješavanja, aktivni ticketi s assigneeom ~1.000 sati, a ostali ~3.000 sati. Ova segmentacija objašnjava zašto ukupni prosjek (18.441 sati) toliko odstupa od medijana (835 sati).
- **Distribucija prioriteta:** 50,9% ticketa ima poznat prioritet, 49,1% je "unknown" — gotovo jednaka podjela koja sugerira sustavni propust u procesu kategorizacije ticketa.

Slika 10: Dashboard — Kvaliteta podataka

7. Generalizacija rezultata

Kako bi se potvrdilo da uvidi iz analize nisu artefakt uzorkovanja, provedena je validacija na 20% test skupu koji je izdvojen u fazi predprocesiranja. Uspoređene su ključne metrike:

Metrika	Trening (80%)	Test (20%)	Razlika
Avg resolve (h)	18.441	18.652	<2%
Median resolve (h)	835	848	<2%
% unknown prioritet	51%	51%	<1pp
% bez assigneea	46%	47%	<1pp
Ghost ticketi udio	33%	32%	<1pp
Assignee efekt (faktor)	~190x	~190x	stabilan
steps↔resolve korelacija	-0.46	-0.46	stabilan

Svi ključni uvidi potvrđeni su na test skupu s razlikama manjim od 5%. Jedina nestabilnost uočena je u kategorijama s malim uzorcima (Blocker: n≈525, Low: n≈560) gdje su medijani odstupali do 30% — što je očekivano za tako male uzorke.

Zaključak generalizacije: uvidi iz analize su pouzdani i primjenjivi na cjelokupni dataset.

8. Zaključak

Provedenom analizom helpdesk sustava, uz korištenje skladišta podataka i vizualizacijskih alata, uspješno je demonstrirana transformacija sirovih podataka o helpdesk ticketima u korisne poslovne uvide.

Ključni nalazi analize:

1. **Trećina dataseta su "ghost ticketi"** — 33% ticketa (21.680) nikad nije ušlo u stvarni workflow (1 korak, unknown prioritet, bez assigneea, status "closed"). Ovi ticketi imaju medijan rješavanja od 2.277 dana i dramatično podižu prosječno vrijeme rješavanja cijelog sustava.

2. **Prioritet funkcionira kad je postavljen** — ticketi s poznatim prioritetom imaju medijan rješavanja od 195 sati (8 dana), dok unknown ticketi imaju 39.682 sati (4.5 godina). Dodjela prioriteta je najvažniji korak za učinkovito rješavanje.
3. **Assignee je najjači prediktor** — ticketi s dodijeljenim tehničarom imaju medijan od 212 sati (9 dana), bez assigneea 39.682 sati. Faktor je $\sim 190x$.
4. **Negativna korelacija koraka i vremena** — više procesnih koraka je kontraintuitivno povezano s kraćim vremenom rješavanja ($r = -0.46$), jer ticketi s jednim korakom su upravo ghost ticketi koji čame godinama.
5. **Čekanje je glavni uzrok dugog rješavanja** — Lowest prioritet provodi prosječno 2.324 sata u čekanju, višestruko više od Blockera (256 sati). Ticketi ne kasne zbog aktivnog rada već zbog čekanja u redu.
6. **Rezolucija je pretežno pozitivna, ali postoje propusti** — 92,94% ticketa završava kao "Done", ali 4,54% ostaje bez rezolucije (Blank), što predstavlja ~ 2.400 neriješenih ticketa koji zahtijevaju pregled.

Rezultati omogućuju optimizaciju helpdesk procesa kroz smanjenje udjela unknown prioriteta, bržu dodjelu assigneea, identifikaciju i zatvaranje ghost ticketa, te praćenje ticketa koji dugo čekaju bez aktivnog rada.

9. Literatura

- [1] Kimball, R., Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd Edition. Wiley.
- [2] Inmon, W.H. (2005). *Building the Data Warehouse*, 4th Edition. Wiley.
- [3] Dokumentacija dataseta — FEATURES.md (priloženo uz dataset)
- [4] MySQL Documentation, <https://dev.mysql.com/doc/>
- [5] SQLAlchemy Documentation, <https://docs.sqlalchemy.org/>
- [6] Power BI Documentation, <https://learn.microsoft.com/power-bi/>
- [7] pandas Documentation, <https://pandas.pydata.org/docs/>