



Fakultet informatike u Puli

Analiza helpdesk sustava i optimizacija procesa rješavanja ticketa

Seminarski rad

Ime i Prezime: Igor Pavlić

JMBAG: 0069012453

Kolegij: Skladišta i rudarenje podataka

Mentor: izv. prof. dr. sc. Goran Oreški

Senj, svibanj 2026.

Sadržaj

1. Uvod
2. Eksplorativna analiza podataka (EDA)
 - 2.1. Odabir i opis skupa podataka
 - 2.2. Analiza skupa podataka
 - 2.3. Predprocesiranje podataka
3. Dizajn i implementacija relacijskog modela
 - 3.1. Priprema i podjela podataka
 - 3.2. Konceptualni model (ER dijagram)
 - 3.3. Relacijski model baze podataka
 - 3.4. Implementacija baze u MySQL-u
 - 3.5. Provjera podataka
4. Dimenzijski model podataka
 - 4.1. Osnove dimenzijskog modeliranja
 - 4.2. Izrada zvjezdastog (star) modela
5. ETL proces
 - 5.1. Ekstrakcija podataka
 - 5.2. Transformacija podataka
 - 5.3. Učitavanje podataka
6. Vizualizacija i poslovna analiza
 - 6.1. Dashboard #1 — Pregled sustava
 - 6.2. Dashboard #2 — Analiza outliera
 - 6.3. Dashboard #3 — Distribucija
 - 6.4. Dashboard #4 — Kvaliteta podataka
 - 6.5. Dodatna analiza outliera u Pythonu
7. Generalizacija rezultata
8. Zaključak
9. Literatura

1. Uvod

U suvremenom poslovnom okruženju, helpdesk sustavi generiraju velike količine podataka o korisničkim zahtjevima, njihovom rješavanju i performansama tima podrške. Učinkovita analiza ovih podataka ključna je za optimizaciju procesa, smanjenje vremena rješavanja i bolje planiranje resursa.

U ovom radu razvijen je sustav poslovne inteligencije koristeći stvarni skup podataka helpdesk ticketa koji sadrži 66.691 zapis iz 15 projekata u periodu od 2007. do 2023. godine. Podaci uključuju informacije o životnom ciklusu svakog ticketa: tko ga je prijavio, tko rješava, koliko koraka je prošao kroz workflow, koliko vremena je proveo u svakom stanju i kako je završen.

Rad obuhvaća cijeli proces izgradnje skladišta podataka — od eksplorativne analize i čišćenja podataka, preko dizajna relacijskog i dimenzijskog modela, do ETL procesa i vizualizacije u Power BI-ju. Cilj je demonstrirati kako se kroz proces poslovne inteligencije može razviti sustav za analizu učinkovitosti helpdesk sustava i identifikaciju uskih grla u procesu rješavanja ticketa.

2. Eksplorativna analiza podataka (EDA)

2.1. Odabir i opis skupa podataka

Skup podataka preuzet je s platforme za dijeljenje istraživačkih podataka i sadrži helpdesk tickete iz stvarnog helpdesk sustava. Izvorni dataset ([Support_tickets_named.csv](#)) sadrži 66.691 redaka i 58 stupaca.

Ključne karakteristike skupa podataka:

Karakteristika	Vrijednost
Broj ticketa	66.691
Period	2007 — 2023
Broj projekata	15
Broj osoba	100 (reporteri + tehničari)
Stupaca	58 (identifikatori, datumi, kategorije, workflow metrike)

Stupci se dijele u nekoliko kategorija: identifikatori (id, issue_num), kategorijski atributi (issue_proj, issue_type, issue_priority, issue_status, issue_resolution), datumski stupci (issue_created, issue_resolution_date), numeričke metrike (wf_total_time, processing_steps, issue_comments_count) i workflow stupci — za svako stanje postoji `wf_{stanje}` (vrijeme provedeno u stanju, u sekundama) i `wfe_{stanje}` (broj ulazaka u stanje).

2.2. Analiza skupa podataka

Eksplorativna analiza otkrila je nekoliko ključnih karakteristika dataseta:

Nedostajuće vrijednosti: 51% ticketa ima prioritet "unknown", 47% nema dodijeljenog tehničara (assignee), a 16 od 58 stupaca ima više od 90% NULL vrijednosti (rijetko korišteni workflow statusi poput wf_deployment, wf_cancelled, wf_validation).

Distribucija tipova ticketa: Ticket dominira (68%), zatim Service (8%), Subtask (7%), Story (7%), i ostali tipovi s manjim udjelima.

Distribucija prioriteta: Unknown (51%), Medium (37%), High (7%), Highest (3%), Blocker (1%), Low (1%), Lowest (<1%).

Tri segmenta ticketa: Analiza je otkrila da dataset sadrži tri potpuno različite populacije: "ghost ticketi" (33%) — ticketi s jednim korakom, unknown prioritetom i bez assignee, s medijanom rješavanja od 2.277 dana; aktivni ticketi s assigneeom (53%) — medijan 9 dana; i ostali (14%) — medijan 15 dana.

```

1 >>> df = pd.read_csv('Support_tickets_named.csv')
2 Dataset učitán: 66691 redaka, 58 stupaca
3
4 === 1.2 Nedostajuće vrijednosti (NULL) – top 12 ===
5
6          NULL count  NULL %
7 wf_in_review      66614    99.9
8 wf_deployment     66556    99.8
9 wf_cancelled      66531    99.8
10 wf_rejected       66579    99.8
11 wf_pending_customer_approval 66437    99.6
12 wf_validation     63730    95.6
13 wf_waiting        46987    70.5
14 wf_resolved       38546    57.8
15 issue_assignee    31047    46.6
16 wf_in_progress    29944    44.9
17 issue_resolution   853      1.3
18 wf_open           78       0.1
19
20 === 1.3 Broj unikatnih vrijednosti (izbor) ===
21 issue_proj      15      issue_status      15
22 issue_reporter  100     issue_resolution    4
23 issue_assignee  100     issue_type         15
24 issue_priority   7      id                66691
25
26 === 1.4 Distribucija: issue_priority ===
27 unknown      33965      Blocker      656
28 Medium       24788      Low          560
29 High         4554      Lowest        84
30 Highest       2084
31
32 === 1.4 Distribucija: issue_type ===
33 Ticket      45275      Story      4538      Task      1540
34 Service      5300      HD Serv. 1686      ostalo    3606
35 Subtask      4746
36
37 === 1.5 Statistika numeričkih varijabli ===
38          wf_total_time  processing_steps  issue_comments_count
39 count      6.669100e+04      66691.000000      66691.000000
40 mean      6.585647e+07          3.214542          8.641796
41 50%      2.961971e+06          3.000000          5.000000
42 max      3.571939e+08          93.000000      685.000000

```

Slika 1: Rezultati eksplorativne analize — NULL vrijednosti, kardinalnost i distribucije (1_analysis.ipynb)

2.3. Predprocesiranje podataka

Predprocesiranje je provedeno u sljedećim koracima:

1. **Uklanjanje stupaca s >90% NULL:** Uklonjeno je 16 stupaca čiji podaci nisu dovoljno zastupljeni za analizu. Od 58 stupaca ostalo je 42.
2. **Standardizacija naziva:** Svi nazivi stupaca pretvoreni su u lowercase s underscore separatorom.
3. **Provjera duplikata:** Potvrđeno je da nema duplikata u datasetu.
4. **Podjela na trening i test skup:** Dataset je podijeljen na 80% za dizajn i implementaciju (53.353 redaka) i 20% za validaciju generalizacije (13.338 redaka) korištenjem fiksnog seeda (`random_state=1`) za reproducibilnost.

```
2_preprocess.ipynb
FIPU-SRP > 2_preprocess.ipynb

1 >>> df = pd.read_csv('Support_tickets_named.csv')
2 Izvorni dataset: 66691 redaka, 58 stupaca
3
4 === 2.1 Uklanjanje stupaca s >90% NULL ===
5 BRIŠEM: wf_in_review (99.9% NULL)
6 BRIŠEM: wf_deployment (99.8% NULL)
7 BRIŠEM: wf_monitoring (99.2% NULL)
8 BRIŠEM: wf_done (98.7% NULL)
9 BRIŠEM: wf_pending_customer_approval (99.6% NULL)
10 BRIŠEM: wf_rejected (99.8% NULL)
11 BRIŠEM: wf_testing_monitoring (99.6% NULL)
12 BRIŠEM: wf_reopened (96.8% NULL)
13 BRIŠEM: wf_to_do (98.8% NULL)
14 BRIŠEM: wf_validation (95.6% NULL)
15 BRIŠEM: wf_resolved_under_monitoring (97.1% NULL)
16 BRIŠEM: wf_closed (97.6% NULL)
17 BRIŠEM: wf_cancelled (99.8% NULL)
18 BRIŠEM: wf_under_review (97.3% NULL)
19 BRIŠEM: wf_approved (97.6% NULL)
20 BRIŠEM: wf_pending_deployment (97.9% NULL)
21
22 Nakon čišćenja: 66691 redaka, 42 stupaca
23
24 === 2.2 Standardizacija naziva stupaca ===
25 df.columns = df.columns.str.lower().str.replace(' ', '_')
26
27 === 2.3 Provjera duplikata ===
28 Broj duplikata: 0
29
30 === 2.4 Spremanje čistog dataseta ===
31 Spremljeno: cleaned_data.csv (66691 redaka)
32
33 === 2.5 Podjela 80 / 20 (random_state=1) ===
34 Trening skup (80%): 53353 redaka -> Support_tickets_PROCESSED.csv
35 Test skup (20%): 13338 redaka -> Support_tickets_PROCESSED_20.csv
```

Slika 2: Predprocesiranje — uklanjanje 16 stupaca s >90% NULL i podjela 80/20 (2_preprocess.ipynb)

3. Dizajn i implementacija relacijskog modela

3.1. Priprema i podjela podataka


Glavni CSV skup podataka podijeljen je na dva dijela: 80% podataka korišteno je za dizajn, implementaciju i punjenje svih tablica u relacijskoj bazi, čime je osigurano da su svi entiteti i odnosi ispravno definirani. Preostalih 20% izdvojeno je za provjeru ispravnosti ETL procesa i validaciju analitičkih modela.

3.2. Konceptualni model (ER dijagram)

Na temelju analize podataka identificirano je sedam glavnih entiteta: project, person, issue_type, priority, status, resolution i centralna tablica support_ticket. Svaki entitet izvučen je iz originalnog flat CSV-a normalizacijom.

Ključne karakteristike modela:

- **person** se referencira dvaput iz **support_ticket** — jednom kao reporter, jednom kao assignee
- **assignee_fk** je nullable jer 46% ticketa nema dodijeljenu osobu
- Svi lookup entiteti imaju INT primarni ključ i VARCHAR atribut



Slika 3: Konceptualni ER dijagram — sedam entiteta s centralnom tablicom support_ticket

3.3. Relacijski model baze podataka

Relacijski model implementiran je kao staging tablica **support_tickets** u MySQL bazi **fipu_srp_projekt**. Umjesto standardnog **to_sql()** koji generira neoptimalne tipove podataka (datume kao TEXT, ID-ove kao DOUBLE), definirano je 42 eksplicitnih SQL tipova korištenjem SQLAlchemy **dtype** parametra:

- Datumi (**started**, **issue_created**, itd.) → DATETIME umjesto TEXT
- Identifikatori (**id**, **issue_num**) → INTEGER umjesto DOUBLE
- Stringovi (**issue_proj**, **issue_type**, itd.) → VARCHAR(50/255) umjesto TEXT
- Workflow trajanja (**wf_open**, **wf_total_time**, itd.) → FLOAT

3.4. Implementacija baze u MySQL-u

Implementacija je provedena korištenjem Pythona (pandas + SQLAlchemy) s **python-dotenv** za sigurno upravljanje pristupnim podacima. Lozinka baze nikada nije hardkodirana u notebookovima, već se čita iz **.env** datoteke.

Import u bazu izvršen je s **to_sql(if_exists='replace', dtype=sql_dtypes, chunksize=5000)** za batch unos podataka.

```

3_ddl_import.ipynb
FIPU-SRP > 3_ddl_import.ipynb

1 >>> conn.execute(text('DESCRIBE support_tickets'))
2 Tablica 'support_tickets' kreirana i 53353 redaka uvezeno.
3
4 Stupac                SQL tip                | Stupac                SQL tip
5 -----
6 id                    int                    | wfe_open              int
7 started              datetime              | wfe_monitoring        int
8 ended                datetime              | wfe_done              int
9 issue_num            int                    | wfe_pending_customer_approval int
10 issue_proj          varchar(255)           | wfe_rejected          int
11 issue_reporter      varchar(255)           | wfe_testing_monitoring int
12 issue_assignee      varchar(255)           | wf_in_progress        float
13 issue_contr_count   int                    | wfe_in_progress       int
14 issue_type          varchar(50)            | wfe_reopened          int
15 issue_priority      varchar(50)            | wfe_to_do             int
16 issue_created       datetime              | wfe_validation        int
17 issue_resolution_date datetime              | wfe_resolved_under_monitoring int
18 issue_resolution    varchar(50)            | wfe_closed            int
19 issue_status        varchar(50)            | wf_waiting            float
20 issue_comments_count int                    | wfe_waiting           int
21 last_change_date    datetime              | wfe_cancelled         int
22 wfe_in_review       int                    | wfe_under_review      int
23 wfe_deployment      int                    | wfe_approved          int
24 wf_resolved         float                    | wfe_pending_deployment int
25 wfe_resolved        int                    | wf_total_time         float
26 wf_open            float                    | processing_steps       int
27 -----
28 Ukupno: 42 stupca – datumi kao DATETIME, ID-ovi kao INT,
29 kategorije kao VARCHAR, workflow trajanja kao FLOAT.

```

Slika 4: Rezultat importa u MySQL — DESCRIBE support_tickets (42 stupca s eksplicitnim tipovima)

3.5. Provjera podataka

Nakon importa provedeno je pet provjera kvalitete:

Provjera	Rezultat
Broj redaka CSV = SQL	53.353 = 53.353 ✓
Dupli ID-ovi	0 ✓
NULL u ključnim stupcima	Samo assignee: 24.771 (46%) — očekivano
Konzistentnost mapiranja	1 projekt = 1 ime ✓
Distribucije	Poklapaju se s EDA ✓

4. Dimenzijski model podataka

4.1. Osnove dimenzijskog modeliranja

Za razliku od relacijskog modela koji je optimiziran za transakcijsku obradu (OLTP), dimenzijski model organizira podatke za analitičke upite (OLAP). Centralna tablica činjenica sadrži numeričke metrike i strane ključeve prema dimenzijskim tablicama koje sadrže opisne atribute.

U ovom projektu dimenzijski model temelji se na analizi poslovnog procesa helpdesk podrške. Svrha je omogućiti višedimenzionalni pogled na performanse rješavanja ticketa kroz različite aspekte: projekt, prioritet, status, tip ticketa, rezoluciju, tehničara i vrijeme.

4.2. Izrada zvjezdastog (star) modela

Star shema sastoji se od 5 dimenzijskih tablica i 1 tablice činjenica:

Dimenzijske tablice:

Dimenzija	PK	Atributi	Redaka
dim_tehnicar	tehtnicar_key (INT AI)	ime_prezime	100
dim_projekt_prioritet_status	projekt_prioritet_status_key (INT AI)	naziv_projekta, razina_prioriteta, naziv_statusa	353
dim_tip_ticketa	tip_ticketa_key (INT AI)	naziv_tipa	15
dim_rezolucija	rezolucija_key (INT AI)	naziv_rezolucije	4
dim_vrijeme	vrijeme_key (DATE)	dan, mjesec, godina, kvartal, dan_u_tjednu	~4.700

dim_projekt_prioritet_status je junk dimenzija koja kombinira tri kategorijske varijable (projekt, prioritet, status) u jednu tablicu. Teoretski max je 15 × 7 × 15 = 1.575 kombinacija, ali samo 353 kombinacije stvarno postoje u podacima.

dim_tehnicar se koristi dvostruko — kao reporter i kao assignee, pri čemu je assignee nullable (46% ticketa nema dodijeljenog tehničara).

Grain: Jedan redak u tablici **fact_support_tickets** predstavlja jedan helpdesk ticket.


Tablica činjenica **fact_support_tickets**:

Stupac	Tip	Opis
ticket_id	INT PK	Primarni ključ
reporter_key	INT FK	→ dim_tehnicar
assignee_key	INT FK (nullable)	→ dim_tehnicar
projekt_prioritet_status_key	INT FK	→ dim_projekt_prioritet_status
tip_ticketa_key	INT FK	→ dim_tip_ticketa
rezolucija_key	INT FK (nullable)	→ dim_rezolucija
vrijeme_key	DATE FK	→ dim_vrijeme
vrijeme_rjesavanja_sati	FLOAT	Ukupno vrijeme rješavanja (sati)
broj_komentara	INT	Broj komentara na ticketu
sati_open	FLOAT	Vrijeme u stanju "open" (sati)

Stupac	Tip	Opis
sati_in_progress	FLOAT	Vrijeme u stanju "in_progress" (sati)
sati_resolved	FLOAT	Vrijeme u stanju "resolved" (sati)
sati_waiting	FLOAT	Vrijeme u stanju "waiting" (sati)

DDL je implementiran korištenjem SQLAlchemy ORM-a s `declarative_base()` pristupom, gdje je svaka tablica definirana kao Python klasa, a `Base.metadata.create_all(engine)` automatski generira DDL s FK constraintima.

Surrogate key logika: Sve dimenzije koriste surrogate ključeve (AUTO_INCREMENT INT) umjesto prirodnih ključeva iz izvornog sustava. Prednosti su stabilnost identifikatora, bolje performanse JOIN operacija i podrška za eventualnu historizaciju (SCD).



Slika 5: Star shema — 5 dimenzijskih tablica i tablica činjenica `fact_support_tickets`

5. ETL proces

ETL (Extract, Transform, Load) proces je ključni dio projekta koji transformira podatke iz dva izvora u dimenzijski model spreman za analizu.

5.1. Ekstrakcija podataka

ETL proces koristi dva izvora podataka prema arhitekturi pripremnog područja (staging area):

Izvor 1 — **Support_tickets_PROCESSED.csv** je predprocesirani 80% skup s 53.353 redaka i 42 stupca. Nastao je u notebooku 2 uklanjanjem stupaca s >90% NULL vrijednosti i stratificiranim uzorkovanjem. Iz njega se grade sve dimenzije i fact tablica.

Izvor 2 — **Support_tickets_named.csv** je originalni puni dataset s 66.691 redaka i 58 stupaca. Sadrži 16 rijetkih **wf_*** stupaca koji su izbačeni predprocesiranjem (>90% NULL) ali ipak sadrže stvarne podatke za podskup ticketa:

Stupac	Non-null redaka	Prosjek (sati)
wf_validation	2.961	603h
wf_reopened	2.123	43h
wf_resolved_under_monitoring	1.931	307h
wf_approved	1.630	190h
wf_pending_deployment	1.413	875h

Oba izvora se spajaju u EXTRACT fazi LEFT JOIN-om po **id** stupcu — čime se čuva svih 53.353 ticketa iz Izvora 1, a Izvor 2 obogaćuje zapise s dodatnim workflow podacima gdje postoje.

5.2. Transformacija podataka

Transformacija uključuje dva ključna koraka:

Izračun metrika:

Metrika	Izvor	Formula
vrijeme_rjesavanja_sati	Izvor 1: <code>issue_resolution_date</code> – <code>issue_created</code>	<code>dt.total_seconds()</code> / 3600
sati_open	Izvor 1: <code>wf_open</code> (sekunde)	/ 3600
sati_in_progress	Izvor 1: <code>wf_in_progress</code> (sekunde)	/ 3600
sati_resolved	Izvor 1: <code>wf_resolved</code> (sekunde)	/ 3600
sati_waiting	Izvor 1: <code>wf_waiting</code> (sekunde)	/ 3600
sati_validation, sati_reopened...	Izvor 2: <code>wf_*</code> (sekunde)	/ 3600

Ispravnost pretvorbe potvrđena je ručnom provjerom: ticket 11887 ima **wf_total_time** = 1992, a razlika između **issue_created** (08:23:43) i **issue_resolution_date** (08:56:55) iznosi točno 1992 sekunde (33 minute i 12 sekundi).

Mapiranje stranih ključeva: Za svaku dimenziju proveden je merge (JOIN) između izvornih podataka i dimenzijskih tablica kako bi se prirodni ključevi zamijenili surrogate ključevima. Posebna pažnja posvećena je korištenju LEFT JOIN-a za assignee (46% NULL) i rezoluciju (1.3% NULL) kako ne bi došlo do gubitka redaka.

```
6_ETL.ipynb X
FIPU-SRP > 6_ETL.ipynb

1 =====
2 VERIFIKACIJA ETL PROCESA
3 =====
4
5 IZVORI:
6 Izvor 1 (PROCESSED.csv): 53.353 redaka, 42 stupca
7 Izvor 2 (named.csv): 16 dodatnih wf_* stupaca
8
9 MAPIRANJE STRANIH KLJUČEVA:
10 Nakon merge s dim_tehnicar (reporter): 53353 redaka
11 Nakon merge s dim_tehnicar (assignee): 53353 redaka (NULL: 24771)
12 Nakon merge s dim_projekt_prioritet_status: 53353 redaka
13 Nakon merge s dim_tip_ticketa: 53353 redaka
14 Nakon merge s dim_rezolucija: 53353 redaka (NULL: 698)
15
16 DIMENZIJE I FACT TABLICA:
17 dim_tehnicar 100 redaka
18 dim_projekt_prioritet_status 353 redaka
19 dim_tip_ticketa 15 redaka
20 dim_rezolucija 4 redaka
21 dim_vrijeme 4.706 redaka
22 fact_support_tickets 53.353 redaka
23
24 Očekivano u fact tablici: 53.353
25 Provjera izgubljenih podataka: PASS (0 izgubljenih redaka)
26
27 UZORAK IZ STAR SCHEMA:
28 ticket_id projekt assignee prioritet status sati
29 10616 Project Nova Josip Jurić unknown closed 5.88
30 10617 Project Aurora Luka Babić unknown closed 50.93
31 10620 Project Vega Marko Pavlović unknown closed 735.36
32 10622 Project Apollo Josip Marić unknown closed 344.18
```

Slika 6: Verifikacija ETL procesa — broj redaka u dimenzijama i fact tablici (6_ETL.ipynb)

5.3. Učitavanje podataka

Učitavanje je provedeno u batch modu (`chunksize=5000`) s privremenim isključivanjem FK provjera za performanse. Na kraju je verifikacijom potvrđeno da sve tablice sadrže očekivani broj redaka te da nema izgubljenih podataka:

Tablica	Redaka
dim_tehnicar	100
dim_projekt_prioritet_status	353
dim_tip_ticketa	15

Tablica	Redaka
dim_rezolucija	4
dim_vrijeme	~4.700
fact_support_tickets	53.353

Provjera gubitka podataka izvršena je programski: `assert len(fact_final) == 53353` — potvrđeno da nijedan redak nije izgubljen u procesu mapiranja stranih ključeva.


6. Vizualizacija i poslovna analiza

Vizualizacija je provedena u Power BI Desktopu korištenjem denormaliziranog SQL upita koji spaja fact tablicu sa svim dimenzijama. Dashboard se sastoji od četiri stranice.

6.1. Dashboard #1 — Pregled sustava

Prva stranica prikazuje ukupne KPI-eve i pregled sustava:

- **53.353 ticketa** iz 15 projekata, s prosječnim vremenom rješavanja od 18.441 sati i medijanom 834,89 sati
- **Trend kroz vrijeme:** Volumen ticketa varira značajno po godinama, s vrhuncem 2015. (5.700 ticketa) i padom 2022. (1.388)
- **Ticketi po projektu:** Project Apollo vodi s 6.554 ticketa, Project Nexus je najmanji s 1.439
- **Vrijeme po prioritetu:** Medium (1.521 sati) i Lowest (1.435 sati) su sporiji od Blockera (1.254 sati) — što ukazuje na nekonzistentnu primjenu prioriteta
- **Top assigneei po volumenu:** Petra Marić (1,9K), Petar Marić (1,8K), Maja Kovačić (1,7K)
- **Self-assigned ticketi:** Dodatno je prikazan pregled tehničara koji su sebi dodijelili tickete. Josip Marić vodi s 34 self-assigned ticketa, što može ukazivati na specifičan radni proces ili nedostatak delegacije unutar tima.




Slika 7: Power BI dashboard #1 — Pregled sustava (KPI-evi, projekti, trend, opterećenje tehničara)

6.2. Dashboard #2 — Analiza outliera

Outlieri su definirani kao ticketi iznad 95. percentila (6.499 sati $\approx$ 271 dan) među ticketima s poznatim prioritetom.


- **Prag i obuhvat:** Od 25.499 ticketa s poznatim prioritetom, 1.275 ticketa (5,0%) prelazi prag od 6.499 sati.
- **Normal vs Outlier po projektu:** Udio outliera nije ravnomjerno raspoređen — najviše ih apsolutno ima Project Solaris, Project Phoenix i Project Helios, dok ih projekti s manjim volumenom (Titan, Nexus) imaju svega nekoliko.
- **Workflow analiza po prioritetu:** Posebno se ističe kategorija Lowest prioriteta s prosječno 2.324 sata čekanja (waiting) — višestruko više od Blockera (256 sati). Ovo je kontraintuitivno i ukazuje da ticketi najnižeg prioriteta zapravo čekaju dulje nego kritični. Blocker ticketi imaju najveće prosječno vrijeme u stanju "open" (822 sati), dok Highest provodi najviše u "waiting" (378 sati).



Slika 8: Power BI dashboard #2 — Analiza outliera (normal vs outlier, vrijeme i workflow po prioritetu)

6.3. Dashboard #3 — Distribucija

- **Matrica projekt × prioritet:** Heatmap prikazuje koncentraciju ticketa — "unknown" prioritet dominira u svim projektima. Project Apollo ima najveći apsolutni broj unknown ticketa (3.697), dok Project Solaris ima najmanji (1.284). Ukupno je 27.156 ticketa bez prioriteta (51%).
- **Histogram vremena rješavanja:** Više od 21.700 ticketa (41%) traje dulje od 3 mjeseca. Distribucija ima izrazito dug desni rep koji ukazuje na postojanje outliera.
- **Distribucija po tipu ticketa:** Ticket dominira s 67,8% (36,17K), a ostali tipovi — Story, Service, HD Service, Task i Subtask — zajedno čine preostalih 32%.
- **Distribucija po rezoluciji:** 92,94% ticketa je riješeno s "Done", dok 4,54% otpada na "(Blank)" — neriješene tickete — i 2,51% na "Won't Do".



Slika 9: Power BI dashboard #3 — Distribucija (matrica projekt × prioritet, tip ticketa, rezolucija)

6.4. Dashboard #4 — Kvaliteta podataka

Četvrta stranica dashboarda posvećena je analizi kvalitete podataka i segmentaciji ticketa.

- **Prioritet po projektu:** Stacked bar prikazuje distribuciju poznatog i nepoznatog prioriteta po projektu. Project Solaris ima najveći udio poznatog prioriteta (66%), dok Project Apollo ima najveći apsolutni broj nepoznatih prioriteta (3,7K).
- **Has Assignee:** 53,57% ticketa ima dodijeljen assignee, dok 46,43% (24,77K) nema. Ovaj podatak je ključan jer analiza pokazuje da ticketi bez assigneea imaju medijan rješavanja ~190 puta duži od onih s assigneeom.
- **Segmentacija ticketa:** Ghost ticketi imaju prosječno ~50.000 sati rješavanja, aktivni ticketi s assigneeom ~1.000 sati, a ostali ~3.000 sati. Ova segmentacija objašnjava zašto ukupni prosjek (18.441 sati) toliko odstupa od medijana (835 sati).
- **Distribucija prioriteta:** 50,9% ticketa ima poznat prioritet, 49,1% je "unknown" — gotovo jednaka podjela koja sugerira sustavni propust u procesu kategorizacije ticketa.




Slika 10: Power BI dashboard #4 — Kvaliteta podataka i segmentacija ticketa

6.5. Dodatna analiza outliera u Pythonu


Uz Power BI dashboarde, detaljna analiza outliera provedena je i u Pythonu ([7_visualization.ipynb](#), poglavlje 7.9) izravno nad star shemom pomoću SQL upita. Analiza pokazuje **gdje** outlieri troše vrijeme:

- Outlieri provode u stanju **open** prosječno 94,5 puta više vremena od normalnih ticketa, u **in_progress** 29,1 puta, a u **waiting** 11,7 puta.
- Najveći apsolutni doprinos ima stanje **open** (11.900 sati prosječno) — ticketi ne kasne zbog aktivnog rada, nego zato što nikad nisu ni preuzeti.



Slika 11: Workflow vrijeme — normalni ticketi vs outlieri i faktor razlike po stanju

Heatmap projekt × prioritet pokazuje da su outlieri gotovo isključivo koncentrirani u **Medium** prioritetu, s najkritičnijim kombinacijama Project Solaris × Medium (184 outliera, prosjek 502 dana) i Project Phoenix × Medium (172 outliera, prosjek 1.078 dana).





Slika 12: Broj outliera po kombinaciji projekt × prioritet (7_visualization.ipynb)

7. Generalizacija rezultata

Kako bi se potvrdilo da uvidi iz analize nisu artefakt uzorkovanja, provedena je validacija na 20% test skupu koji je izdvojen u fazi predprocesiranja. Uspoređene su ključne metrike:

Metrika	Trening (80%)	Test (20%)	Razlika
Avg resolve (h)	18.441,0	18.648,6	1,1%
Median resolve (h)	834,9	857,3	2,7%
Avg broj komentara	8,7	8,4	3,4%
Avg broj koraka	3,2	3,2	1,9%
% unknown prioritet	50,9%	51,0%	0,3 pp
% bez assignee	46,4%	47,1%	0,7 pp
Ghost ticketi udio	32,3%	33,2%	0,9 pp
Assignee efekt (faktor)	186x	203x	stabilan (~190x)
steps↔resolve korelacija	-0,463	-0,464	stabilan



Slika 13: Usporedba trening (80%) i test (20%) skupa — distribucija prioriteta i median vrijeme rješavanja

```
8_generalization.ipynb X
FIPU-SRP > 8_generalization.ipynb

1 =====
2 VALIDACIJA KLJUČNIH UVIDA (trening 80% vs test 20%)
3 =====
4
5 Metrika                Trening      Test      Razlika
6 -----
7 Avg resolve (h)        18441.0    18648.6    1.1% OK
8 Median resolve (h)     834.9     857.3     2.7% OK
9 Avg komentara          8.7       8.4       3.4% OK
10 Avg koraka             3.2       3.2       1.9% OK
11 % unknown prioritet    50.9      51.0      0.3% OK
12 % bez assigneeaa      46.4      47.1      1.3% OK
13
14 1. Ghost ticketi (1 step + unknown + no assignee):
15   Trening: 17.255 (32,3%)   Test: 4.425 (33,2%)
16   -> STABILAN uvid (razlika <1pp)
17
18 2. Assignee efekt (median resolve):
19   Trening: s assignee=213h, bez=39.705h (faktor 186x)
20   Test:    s assignee=196h, bez=39.675h (faktor 203x)
21   -> STABILAN uvid (faktor ~190x u oba skupa)
22
23 3. Korelacije:
24   steps <-> resolve:      trening r=-0.463, test r=-0.464
25   komentari <-> resolve:  trening r=-0.009, test r= 0.002
26   -> STABILAN uvid
27
28 4. Dan u tjednu (top 3):
29   Trening: Sunday=21,2% Monday=20,3% Tuesday=19,4%
30   Test:    Sunday=20,9% Tuesday=19,6% Monday=19,6%
31   -> STABILAN uvid
32
33 NESTABILNO (mali uzorci):
34   Blocker median 95h vs 69h (n~525), Low median 235h vs 151h (n~560)
```

Slika 14: Validacija ključnih uvida na test skupu (8_generalization.ipynb)

Svi ključni uvidi potvrđeni su na test skupu s razlikama manjim od 5%. Jedina nestabilnost uočena je u kategorijama s malim uzorcima (Blocker: $n \approx 525$, Low: $n \approx 560$) gdje su medijani odstupali do 30% — što je očekivano za tako male uzorke.

Zaključak generalizacije: uvidi iz analize su pouzdani i primjenjivi na cjelokupni dataset.

8. Zaključak

Provedenom analizom helpdesk sustava, uz korištenje skladišta podataka i vizualizacijskih alata, uspješno je demonstrirana transformacija sirovih podataka o helpdesk ticketima u korisne poslovne uvide.

Ključni nalazi analize:

1. **Trećina dataseta su "ghost ticketi"** — 33% ticketa (21.680) nikad nije ušlo u stvarni workflow (1 korak, unknown prioritet, bez assignee, status "closed"). Ovi ticketi imaju medijan rješavanja od 2.277 dana i dramatično podižu prosječno vrijeme rješavanja cijelog sustava.
2. **Prioritet funkcionira kad je postavljen** — ticketi s poznatim prioritetom imaju medijan rješavanja od 195 sati (8 dana), dok unknown ticketi imaju 39.682 sati (4.5 godina). Dodjela prioriteta je najvažniji korak za učinkovito rješavanje.
3. **Assignee je najjači prediktor** — ticketi s dodijeljenim tehničarom imaju medijan od 212 sati (9 dana), bez assignee 39.682 sati. Faktor je $\sim 190\times$.
4. **Negativna korelacija koraka i vremena** — više procesnih koraka je kontraintuitivno povezano s kraćim vremenom rješavanja ($r = -0.46$), jer ticketi s jednim korakom su upravo ghost ticketi koji čame godinama.
5. **Čekanje je glavni uzrok dugog rješavanja** — Lowest prioritet provodi prosječno 2.324 sata u čekanju, višestruko više od Blockera (256 sati). Ticketi ne kasne zbog aktivnog rada već zbog čekanja u redu.
6. **Rezolucija je pretežno pozitivna, ali postoje propusti** — 92,94% ticketa završava kao "Done", ali 4,54% ostaje bez rezolucije (Blank), što predstavlja ~ 2.400 neriješenih ticketa koji zahtijevaju pregled.

Rezultati omogućuju optimizaciju helpdesk procesa kroz smanjenje udjela unknown prioriteta, bržu dodjelu assignee, identifikaciju i zatvaranje ghost ticketa, te praćenje ticketa koji dugo čekaju bez aktivnog rada.

9. Literatura

- [1] Oreški, G. *srp_fipu* — *Projekt iz kolegija Skladišta i rudarenje podataka*, Fakultet informatike u Puli. GitHub repozitorij: https://github.com/goreski/srp_fipu
- [2] Oreški, G. *Materijali s predavanja i vježbi kolegija Skladišta i rudarenje podataka*, Fakultet informatike u Puli.
- [3] Dokumentacija dataseta — FEATURES.md (priloženo uz dataset)
- [4] MySQL Documentation, <https://dev.mysql.com/doc/>
- [5] SQLAlchemy Documentation, <https://docs.sqlalchemy.org/>
- [6] Power BI Documentation, <https://learn.microsoft.com/power-bi/>
- [7] pandas Documentation, <https://pandas.pydata.org/docs/>