

SKLADIŠTA I RUDARENJE PODATAKA — skripta za učenje

Sažetak predavanja P1–P6 i P8–P12 (izv. prof. dr. sc. Goran Oreški, FIPU). P7 nije bio u arhivi predavanja — vjerojatno praktični sat s Tableauom; sadržaj mu je dijelom pokriven u P8.

Kako koristiti skriptu

Kolegij ima **dvije jasno odvojene polovice** koje se spajaju tek na kraju:

Dio	Predavanja	Pitanje na koje odgovara
A. Skladišta podataka	P1–P8	Kako organizirati podatke da se nad njima može brzo i smisleno analizirati?
B. Rudarenje podataka	P9–P12	Kako iz tako organiziranih podataka automatski izvući znanje?


Nit koja povezuje sve: **podatak** → **informacija** → **znanje** → **odluka** → **akcija**.

Svako poglavlje ima:

- **Ključne ideje** — ono što se pamti u jednoj rečenici
- **Razrada** — definicije, tablice, usporedbe
- **Provjeri se** — pitanja tipa kakva se očekuju na ispitu

Na kraju su: sinteza cijelog toka, pojmovnik HR↔EN, banka ispitnih pitanja i popis tipičnih zamki.

Mapa kolegija (jedna slika u glavi)



P1 — Uvod, analiza, deskriptivna statistika i vizualizacija

Ključne ideje

- **OLTP vs. DSS** je temeljna podjela cijelog kolegija: jedan sustav zapisuje, drugi analizira.
- Poslovna inteligencija se dijeli na **tri razine analitike** — deskriptivnu, prediktivnu, preskriptivnu.
- Tip varijable određuje **i pripremu i vizualizaciju** podataka. Nije kozmetika, nego temelj.

Transakcijski sustavi (OPS / OLTP)

Operacijski sustavi (engl. *Operational Systems*) podržavaju svakodnevno poslovanje tvrtke.

- Često **ne sadrže povijesne podatke** — podaci se ažuriraju na trenutno stanje.
- Optimizirani za **brzo procesiranje transakcija**.
- Najčešće se obrađuje **jedna transakcija u jednom trenutku**.
- Primjeri: računi na blagajni, novčane transakcije u banci, evidencija posjetitelja.

Sustavi za potporu odlučivanju (DSS)

- Podržavaju **strateško** donošenje odluka.
- Sadrže **povijesne** podatke; pune se **periodički**.
- Optimizirani za **efikasno dohvaćanje velikog skupa podataka** — tisuće zapisa u jednom upitu.
- Primjeri: analiza poslovanja, segmentacija tržišta, predviđanje trendova.

Poslovna inteligencija (BI)

BI je rezultat razvoja DSS-a.

Definicija: BI objedinjuje skup metodologija i alata kojima se omogućuje obrada podataka iz različitih izvora s ciljem njihova pretvaranja u informaciju potrebnu za donošenje poslovnih odluka.

Proces BI temelji se na tri koraka:

1. **Transformacija** podataka u informacije
2. **Odluka** na temelju tih informacija
3. **Akcija** — provedba odluke u praksi

BI vs. BA (Business Analytics): često se koriste kao sinonimi; prema nekim autorima BI je *podskup* BA (BA je širi pojam).

Tri razine analitike — tablica koju treba znati napamet

Razina	Ključna pitanja	Alati / metode	Rezultat
Deskriptivna (~BI)	Što se dogodilo? Što se događa?	Poslovno izvještavanje, skladišta podataka , kontrolne ploče / vizualizacija	Jasno definiran poslovni problem i prepoznate mogućnosti za napredak

Razina	Ključna pitanja	Alati / metode	Rezultat
Prediktivna (~BA)	Što će se dogoditi? Zašto?	Rudarenje podataka , rudarenje teksta, sustavi za predviđanje	Precizne projekcije budućih događaja i rezultata
Preskriptivna (~BA)	Što je potrebno napraviti? Zašto?	Optimizacija, simulacija, ekspertni sustavi	Najbolje odluke i konkretne akcije (<i>best course of action</i>)

Ovo je okvir cijelog kolegija: **P1–P8 = deskriptivna razina, P9–P12 = prediktivna razina.**

Podaci

Karakteristike koje određuju **spremnost podataka za izradu skladišta**:

pouzdanost izvora · točnost sadržaja · dostupnost · sigurnost i privatnost · potpunost · konzistentnost · vremenska dimenzija · granularnost · relevantnost

Podjela po strukturi (CS perspektiva)

Vrsta	Opis	Primjeri
Strukturirani	definirani fiksnom shemom, laki za obradu	relacijske BP, proračunske tablice
Nestrukturirani	nemaju unaprijed definiran model ni organizaciju	tekst, dokumenti, objave, e-mail, video, audio
Polustrukturirani	nisu u relacijskoj BP, ali imaju organizacijska svojstva i oznake za odvajanje semantičkih elemenata	XML, JSON

Podjela varijabli (statistička perspektiva)

Kategoričke (kvalitativne):

- **nominalne** — grupe **bez** prirodnog redoslijeda (npr. boja, država)
- **ordinalne** — grupe **s** prirodnim redoslijedom, ali **bez jasno definirane razlike** među kategorijama (npr. prioritet: nizak/srednji/visok)

Numeričke (kvantitativne):

- **intervalne** — jednaki razmaci, **nema apsolutne nule** (npr. °C, kalendarska godina)
- **omjerne** — sve od intervalnih + **apsolutna nula** → dopuštene sve aritmetičke operacije (npr. prihod, količina, trajanje)

Dodatna podjela numeričkih po distribuciji:

- **diskretne** — samo određene vrijednosti unutar skupa
- **kontinuirane** — bilo koja vrijednost unutar raspona

Zašto je ovo bitno: mjere u tablici činjenica moraju biti kvantitativne (najbolje omjerne, jer se zbrajaju); dimenzijski atributi su kvalitativni.

Statistika

- **Deskriptivna statistika** — uređuje, grafički prikazuje i opisuje **prikupljene** podatke (prosjeak, standardna devijacija, korelacija). Zaključci **samo o uzorku**.
- **Inferencijalna statistika** — na temelju teorije vjerojatnosti donosi zaključke **o populaciji** pomoću uzoraka.

Mjere središnje tendencije

Mjera	Definicija
Srednja vrijednost (aritmetička sredina)	suma svih podataka / broj podataka
Medijan	vrijednost središnjeg podatka koja podatke poredane po veličini dijeli na dva jednako brojna dijela
Mod	vrijednost koja se najčešće ponavlja

Primjer sa slajda — [5, 210, 10, 3, 5, 7, 411557, 1, 78, 220, 4589] sortirano: [1, 3, 5, 5, 7, 10, 78, 210, 220, 4589, 411557]

Mean: 37880.45
Mode: 5
Median: 10

Pouka primjera: jedna ekstremna vrijednost (411 557) razvalila je srednju vrijednost — 37 880 ne opisuje **nijedan** stvarni podatak. Medijan (10) je otporan na stršeće vrijednosti. Ovo je izravna motivacija za **detekciju anomalija** (P12).

Mjere varijabilnosti

Mjera	Definicija
Raspon	max – min
Varijanca (uzorka)	suma kvadrata odstupanja od srednje vrijednosti / (n – 1)
Standardna devijacija (uzorka)	pozitivni drugi korijen varijance
Koeficijent varijacije	omjer standardne devijacije i srednje vrijednosti (relativna mjera, često ×100 %)
Kvantili	vrijednosti koje statistički niz dijele na n jednakih dijelova

Za isti primjer: Range: 411556, Std: 123941.96, Var: 15361610476.07, CV: 327.19 %, Q1 = 5.0, Q2 = 10.0, Q3 = 215.0.

CV od 327 % znači da je raspršenost trostruko veća od same sredine — podatak je praktički bezvrijedan kao "tipična vrijednost".

Osnovni pandas alat: `.mean()` `.median()` `.mode()` `.std()` `.var()` `.quantile([.25,.5,.75])`
`.isna().sum()`

Priprema podataka (data preprocessing)

Priprema **ovisi o namjeni** novog sustava (deskriptivni / prediktivni / preskriptivni). Lanac koraka:

sirovi podaci → konsolidacija → čišćenje → transformacija → redukcija

Vizualizacija

- **Grafikoni** — slikovni prikazi skupova podataka, nizova mjerenja, učestalosti, trenda ili međusobnog odnosa.
- **Tip grafikona ovisi o tipu podataka.**
- Osnovna podjela: **površinski** i **linijski**.
- Osnovni tipovi: linijski, dijagram rasipanja (scatter), stupčasti, okrugli (pie), geografski.

Upozorenje sa slajdova "Oprez!"

Dva slajda pokazuju **iste podatke** prikazane na dva načina:

- odsjecanje y-osi (npr. raspon 11 390–11 640 umjesto 0–12 000) čini minimalne razlike dramatičnima;
- promjena skale/orijentacije mijenja dojam o odnosu kategorija.

Etika vizualizacije: grafikon koji tehnički ne laže i dalje može obmanuti. Y-os koja ne kreće od nule kod stupčastog grafikona je klasična manipulacija.

Provjeri se

1. Navedi tri razlike između OPS-a i DSS-a.
2. Zašto je BI podskup BA, a ne obrnuto?
3. Koja je razlika između intervalne i omjerne skale? Daj po jedan primjer.
4. Kada je medijan bolji od aritmetičke sredine i zašto?
5. Što mjeri koeficijent varijacije i zašto je koristan kada uspoređujemo dvije varijable različitih jedinica?
6. Objasni kako se istim podacima može prikazati suprotan dojam.

Checkpoint 1 (projekt): odabrati skup podataka i napraviti osnovnu analizu u Pythonu — `.head()`, veličina skupa, nazivi stupaca, `.isna()`, `.unique()`, `.dtypes`, `value_counts()` po stupcu. Kriteriji: >~50k zapisa · dovoljna raznolikost · **vremenska dimenzija** · i kvantitativni i kvalitativni podaci · koliko nedostajućih vrijednosti.

P2 — Transakcijski sustavi

Ključne ideje

- Skladište se puni **iz** transakcijskog sustava, pa ga treba dobro razumjeti i modelirati.

- Dizajn baze ide u tri faze: **konceptualni** → **logički** → **fizički**.
- Entitete prepoznaješ kao **imenice**, veze kao **glagole**.

Načini organizacije transakcijskih podataka

	Datotečni sustav	Relacijska baza podataka
Količina podataka	manje količine	velike, neophodna za današnje organizacije
Povezanost	podaci često nepovezani	povezani, s ograničenjima
Operacije	jednostavne (čitanje, pisanje)	složeni upiti, transakcije, integritet
Nedostaci	redundancija, zavisnost, niska produktivnost	zahtijeva dizajn i održavanje

Datoteke su **jedan od čestih izvora za skladišta podataka** — zato projekt namjerno dijeli izvor na bazu + CSV, da se simulira punjenje iz više izvora.

Tri razine dizajna baze

Faza	Model	Alat / rezultat
Konceptualni dizajn	ER model	ER dijagram — neovisan o DBMS-u
Logički dizajn	relacijski model	EER dijagram — tipovi podataka, ključevi, normalizacija
Fizički dizajn	implementacija	indeksi, pohrana, integritet, kontrola pristupa

Model = apstraktna reprezentacija stvarnosti koja isključuje mnoštvo detalja — smanjenje kompleksnosti, fokus na bitno. Modeliranje je "umjetnost apstrakcije": znati što uključiti, a što izostaviti.

ER model — elementi

Element	Definicija	Prikaz	Kako prepoznati u tekstu
Entitet	objekt ili predmet od interesa (fizički ili apstraktni)	pravokutnik	imenica
Atribut	činjenica, svojstvo ili detalj o entitetu; ima naziv, pridruženi entitet i domen	ovalni oblik, spojen ravnom linijom	imenica
Veza	odnos između dva ili više entiteta	romb; kraj veze pokazuje kardinalnost	glagol

Veza ima: **naziv**, **skup entiteta koji sudjeluju**, **stupanj** (broj entiteta u vezi) i **kardinalnost**.

Kardinalnost

Tip	Primjer sa slajda
1:1	svaki direktor ima svoj ured
1:M	svaki proizvod ima jednu liniju, ali linija ima više proizvoda
M:M	proizvod se proizvodi u više tvornica, tvornica proizvodi više proizvoda

Entitet ili atribut? (klasično ispitno pitanje)

Oba su imenice i oba predstavljaju činjenice iz stvarnog svijeta. Smjernice:

- **entiteti sadrže attribute; atributi se ne sastoje od manjih dijelova**
- **entiteti mogu imati veze između sebe; atributi pripadaju entitetima**

Case study — Oprema d.o.o.

Međunarodni proizvođač opreme za planinarenje i kampiranje. Preko 100 proizvoda; proizvodi pripadaju **tipovima**, tipovi **linijama**. Narudžbe se plaćaju iz preko 25 zemalja, godišnje >25 000 narudžbi. Prodaja preko **partnera**, kroz više **prodajnih kanala**. Većina podataka u relacijskoj bazi, manji dio (direktna prodaja) u **CSV datoteci**. Dostupni podaci 3 godine poslovanja: **količina** prodanih proizvoda i **prihod**.

Entiteti: Linija, Tip, Proizvod, Partner, Zemlja, Narudžba, Kanal **Veze:** Pripada (Linija–Tip, Tip–Proizvod), Naručeno od (Partner–Narudžba), Plaćeno iz (Narudžba–Zemlja), Naručeno kroz (Narudžba–Kanal), Uključuje (Narudžba–Proizvod)

Ograničenja koja se lako previde:

- moguće je naručiti **samo jedan proizvod po narudžbi**
- **zemlja iz koje se plaća nije povezana s partnerom**

Logički model

Most između konceptualnog modela i fizičke implementacije. Ključan za detaljan plan strukture, optimizaciju dohvaćanja i integriteta, te usklađivanje s poslovnim zahtjevima.

Komponente:

- entiteti i atributi — **sa specificiranim tipovima podataka**
- veze — detaljnije, s vrstama (1:N, N:1, N:N) i ograničenjima
- **primarni i strani ključevi**
- **EER dijagram** — prilagođeni ER dijagram s ključevima i tipovima

Koraci izrade:

1. transformacija konceptualnog u logički (identifikacija entiteta i veza)
2. **normalizacija** — smanjenje redundancije
3. definiranje atributa i ključeva

Alati: MySQL Workbench, Microsoft Visio, Lucidchart, Draw.io. Fizička implementacija: Oracle SQL Developer, MySQL Workbench, SSMS, pgAdmin.

Provjeri se

1. Nabroji tri faze dizajna baze i rezultat svake.
2. Kako u tekstualnom opisu poslovnog procesa razlikuješ entitet, atribut i vezu?
3. Kada je nešto entitet, a kada atribut? Navedi obje smjernice.
4. Što EER dijagram dodaje na ER dijagram?
5. Zašto su datotečni izvori važni u kontekstu skladišta podataka?

Checkpoint 2 (projekt): definirati proces → entitete, attribute, veze i kardinalnost → ER dijagram (konceptualni) → EER dijagram (logički) → implementirati u DBMS → učitati podatke u relacijsku bazu.

P3 — Skladišta podataka

Ključne ideje

- **Inmonova definicija u četiri riječi** je najčešće ispitno pitanje cijelog kolegija.
- **Top-down (Inmon) vs. bottom-up (Kimball)** — znati tablicu usporedbe.
- **Dimenzijsko razmišljanje:** ne modeliramo sve detalje procesa, nego *kontekste koji utječu na odluku*.

Potreba

- iskoristiti podatke iz **različitih izvora unutar i izvan organizacije** za potporu odlučivanju
- **integracija u jedinstvenu bazu**, modeliranu u skladu s ciljem
- olakšati postavljanje upita menadžerima koji donose odluke

Definicije

Bill Inmon: Skladište podataka jest **subjektno orijentiran, integriran, postojan i vremenski različit** skup podataka koji služi kao potpora odlučivanju.

Ralph Kimball: Kopija transakcijskih podataka specijalno strukturirana za upite i analize.

Barry Devlin: Jedinstven, kompletan i dosljedan repozitorij podataka pribavljen iz raznih izvora i predstavljen krajnjem korisniku na razumljiv način.

Četiri svojstva iz Inmonove definicije

Svojstvo	Značenje
subjektno orijentiran	podaci su organizirani po poslovnim temama , ne po aplikacijama
integriran	podaci dolaze iz različitih izvora i usklađuju se
postojan	podaci se ne mijenjaju u skladištu — samo se dodaju novi
vremenski različit	skladište ima vremensku dimenziju koja omogućuje pregled u vremenskom kontekstu

OLTP vs. OLAP

OLTP (transakcijska aplikacija)	OLAP (analitika, izvješćivanje)
veliki broj transakcija	velika količina podataka
brza obrada	de-normalizirani podaci
normalizirani podaci	manje tablica
puno tablica	

Tok podataka: **Izvori podataka** → **Pripremno područje** → **Skladište podataka** → **Korisnici**

Pristupi implementacije

	Top-down (Inmon)	Bottom-up (Kimball)
Postupak	prvo cijelo skladište, pa područna skladišta (<i>data marts</i>)	prvo područna skladišta, pa se spajaju u cjelinu
Izrada skladišta	vremenski iscrpno	vremenski kraće
Održavanje	lagano	teško
Trošak	visoki inicijalni	niski inicijalni
Vrijeme do početka	duže	kraće
Integracija podataka	ukupna organizacija	pojedini dijelovi

Izbor ovisi o slučaju. Kod bottom-upa **usklađene dimenzije** postaju kritične (vidi P5) jer različiti timovi razvijaju različita područna skladišta.

Uvod u dimenzijski model

Prednosti u odnosu na relacijski model: standardizacija · pohranjivanje povijesnih podataka · modularnost · dohvat velike količine podataka · performanse upita · razumljivost.

Predmet modeliranja: činjenice i dimenzije. **Osnovni elementi:** tablica činjenica, dimenzijske tablice, atributi.

Sheme: *star* ili *snowflake*.

- **Star shema** — dimenzijske tablice izravno spojene na tablicu činjenica (denormalizirane).
- **Snowflake shema** — dimenzije su **normalizirane**, pa se granaju u podtablice.

Dimenzijsko razmišljanje

Razmišljanje o poslovanju **kroz različite kontekste koji utječu na rezultat**, posebno one bitne za odlučivanje.

- Konteksti **mogu, ali ne moraju** odgovarati entitetima iz relacijskog modela.
- Mogu se **izvući (generirati) iz transakcijskih podataka** — npr. ponašanje kupaca koje nigdje nije eksplicitno zapisano.

Primjer 1 — Kafić želi povećati prodaju:

- analiziramo: prodaju
- podaci: prodaja po vremenu dana, popularnost proizvoda, preferencije kupaca
- odluke: promotivne ponude, prilagođavanje radnog vremena, zapošljavanje

Primjer 2 — E-trgovina želi poboljšati iskustvo kupaca:

- kontekst: izvor posjetitelja, demografija kupaca, povijest kupnje, pregledi proizvoda, stopa napuštanja košarice
- odluke: promjena web trgovine, marketinške odluke

Zaključak: nije nam bitno pratiti sve detalje procesa — za to postoji transakcijski sustav. Fokus je na elementima koji značajno utječu na cilj. Ali: što više podataka uključimo, detaljnije analize možemo raditi → potrebno **definirati granicu**.

Četiri koraka dizajna skladišta podataka

Ovo je okosnica cijelog projekta — nauči redoslijed.

1. **Odabrati poslovni proces** — dnevne aktivnosti podržane OLTP sustavom (marketing, prodaja, HR, nabava). Definirati potrebe korisnika. Paziti na kvalitetu podataka.
2. **Odabrati granularnost tablice činjenica** — razina detalja; identificirati **najnižu razinu informacija**.
3. **Definirati dimenzije** — daju kontekst i odgovaraju na **Tko? Što? Gdje? Kada?**
4. **Definirati mjere (činjenice)** — predmet interesa odlučivanja, pohranjuju se u tablicu činjenica.

Case study: dimenzije = partneri, proizvod, lokacija, vrijeme; mjere = prihodi od prodaje, prodana količina.

Provjeri se

1. Reproduciraj Inmonovu definiciju i objasni sva četiri svojstva.
2. Što znači da je skladište **postojano**? Kako to utječe na ETL?
3. Usporedi top-down i bottom-up po pet kriterija.
4. Nabroji četiri koraka dizajna skladišta, ispravnim redoslijedom.
5. Zadan proces: "*Bolnica želi smanjiti vrijeme čekanja pacijenata.*" Odredi poslovni proces, granularnost, tri dimenzije i dvije mjere.

P4 — Modeliranje skladišta podataka

Ključne ideje

- **Tablica činjenica = mjere + strani ključevi dimenzija.** Dimenzije = kontekst.
- Tablica činjenica je (gotovo) **normalizirana**; dimenzijske tablice su **de-normalizirane**. Ovo je najčešća zamka.
- **Star shema i OLAP kocka imaju isti logički dizajn, različitu fizičku implementaciju.**

Dimenzijsko modeliranje

Tehnika za prezentiranje analitičkih podataka koja omogućava:

- **razumljivost podataka poslovnim korisnicima**
- **brze performanse upita**

Razlika u odnosu na klasične normalizirane modele: **normalizirani modeli su prekomplicirani za BI upite.**

Podaci koji se uključuju su **isti** kao u OLTP-u — različit je **način organizacije i pohrane.**

Tablica činjenica

- **Činjenica = poslovna mjera**, kvantitativan tip podataka (pošiljke, prihodi, rashodi, plaćanja...)
- **Centralna** tablica dimenzijskog modela
- Tablica s **velikim brojem zapisa**; nije predviđena pohrana na više mjesta
- Cilj: sadržavati **najnižu razinu granularnosti**
- **Često je normalizirana ili gotovo normalizirana** i vrlo slična tablici u transakcijskom sustavu

Sadržaj:

Tablica činjenica

TK	← tehnički (surogat) ključ = primarni ključ
Vrijeme ID	┌ strani ključevi prema dimenzijama
Lokacija ID	
Proizvodi ID	
Prihod	┌
Količina	└ mjere

Dimenzijska tablica

- **Kontekstualni dodatak** tablici činjenica
- **Kvalitativan** tip podataka (diskretan skup vrijednosti)
- Pridružena tablici činjenica vezom **1:M** → rezultat je **star shema**
- Često **manje veličine** od tablice činjenica (može imati svega nekoliko zapisa)
- **De-normalizirane** — zbog lakše obrade zahtjevnih analitičkih upita i čitljivosti modela
- Ima **surogat ključ** kao primarni ključ; **količina atributa doprinosi kvaliteti i raznovrsnosti analize**

Dimenzijska tablica

TK	← surogat ključ
Šifra (prirodni ID)	← zadržan produkcijski ključ
Naziv	
Tip proizvoda	┌
Linija	└ hijerarhija
Pakiranje	

Hijerarhije i redundancija

Dimenzijska tablica može imati **jednu ili više hijerarhija** unutar iste tablice — npr. dimenzija Trgovina:

Trgovina naziv → Grad → Županija → Država (geografska hijerarhija)
Trgovina naziv → Prodajna zona → Prodajna regija (organizacijska hijerarhija)

Hijerarhije unutar jedne tablice su **izvor redundancije podataka**. Normalizacija dimenzijskih tablica → **snowflake shema**. Pitanje koje treba postaviti: *je li normalizacija uopće potrebna?* (obično nije — prostor je jeftin, čitljivost i brzina nisu).

Star shema ili OLAP kocke

Obje implementacije imaju isti logički dizajn, ali različitu fizičku implementaciju.

	OLAP kocke	Star sheme
Fizička implementacija	MDB (multidimenzijska baza)	RDB (relacijska baza)
Agregacije	stvara i održava OLAP cube engine	rade se u ETL-u / upitima
Performanse	bolje performanse upita	slabije
Analitičke funkcije	robusnije	ograničene na SQL
Stabilnost	manja	veće

Dobra praksa: stvoriti star shemu čak i kada se podaci pohranjuju u OLAP kocke — i onda izvesti kocke iz star sheme.

Normalizirani model → dimenzijski model

Transakcijski sustavi su tipično u **3NF**; dimenzijski model je **de-normaliziran**. Postupak pretvorbe koristi **ista četiri koraka** iz P3:

1) Odabrati poslovni proces

- dobro proučiti **ukupan** model transakcijskog sustava
- usredotočiti se na **područje** u relacijskom modelu — svi entiteti vezani uz proces su tek dio ukupnog modela
- imati ideju koje mjere će se odabrati
- kvaliteta podataka

2) Odabrati granularnost

- razina detalja; **preporuka: najniža granularnost**
- npr. individualne transakcije, linije dokumenta

3) Definirati dimenzije

- moraju biti **razumljive i korisne poslovnim korisnicima** — one su **korisničko sučelje** skladišta
- definirati potrebne attribute

- definirati hijerarhije (tražiti u povezanim tablicama) **ili stvoriti nove**
- najčešće vezane s tablicom činjenica **1:M**
- **transformacija kvantitativnih vrijednosti** → **grupiranje** (npr. dob → dobna skupina)
- **dodati dimenziju vrijeme**

4) Definirati mjere (tablicu činjenica)

- **često odgovaraju asocijativnim entitetima u ER dijagramu** ← ključna heuristika
- može se odabrati više mjera u jednu tablicu činjenica (količina, vrijednost)
- mjere moraju biti odgovarajućeg tipa
- uključivanje trivijalnih dimenzija

Dodatak: asocijativni entiteti

- Kombinacija **veze i entiteta**.
- Kada ih stvoriti: kod **many-to-many** veze i kod **ternarnih** veza.
- Imaju **nezavisno značenje** od povezanih entiteta koji su stvorili vezu.
- Sadrže **svoj id** i često dodatni atribut koji nije id povezanog entiteta.
- Primjer: *Student* — **Predaje** — *Kolegij*, s dodatnim atributima **id**, **ocjena**.
- Pri implementaciji se pretvara u **zasebnu tablicu u 1:M vezama**.

Zato je asocijativni entitet prirodni kandidat za tablicu činjenica — on već sadrži veze prema više entiteta (→ dimenzije) i vlastite mjerljive attribute (→ mjere).

Case study — dimenzijski model: tablica činjenica **Narudžba t.č.**, dimenzije **Partner d.**, **Zemlja d.**, **Proizvod d.**, **Vrijeme d.**

Provjeri se

1. Zašto je tablica činjenica normalizirana, a dimenzijske tablice de-normalizirane?
2. Koja je veza između star sheme i OLAP kocke?
3. Što je hijerarhija u dimenziji i zašto uzrokuje redundanciju?
4. Kako iz ER dijagrama prepoznaješ kandidata za tablicu činjenica?
5. Objasni zašto se preporučuje najniža granularnost, i koja je cijena te odluke.

Checkpoint 3 (projekt): pronaći mjeru (kvantitativan podatak) · 5 različitih dimenzija (kvalitativni podaci) · 2–3 hijerarhije u 2 dimenzije · napraviti star shemu.

P5 — Dimenzijski model podataka (napredne teme)

Ključne ideje

- **Surogat ključevi** su obavezni u svim tablicama dimenzijskog modela.
- **SCD tipovi 1–4 + hibridni** — najgušće ispitno gradivo cijelog kolegija.
- Za svaku "specijalnu" dimenziju znati **jednu rečenicu definicije i kada se koristi**.

Logika predavanja: (1) dizajniraj osnovni dimenzijski model → (2) **poboljšaj ga**.

Surogat (tehnički) ključevi

- Uvode se u **sve** tablice dimenzijskog modela; **cijeli brojevi (sekvence)**.
- Originalni primarni (**produksijski**) ključevi se **zadržavaju** — veze na izvorne podatke.
- **Ne smiju biti "pametni" niti kompozitni**.
- **Ne smiju biti povezani s produkcijskim ključevima**.
- Surogat ključevi dimenzija koriste se za **vezu prema tablici činjenica**.

Zašto? Izvorni sustav može promijeniti format ključa, spojiti se s drugim sustavom, reciklirati šifre. Osim toga, SCD tip 2 **zahtijeva** da ista poslovna šifra postoji u više redaka — a to je moguće samo ako primarni ključ nije poslovna šifra.

Sporo mijenjajuće dimenzije (SCD — *slowly changing dimensions*)

Atributi dimenzije mijenjaju se kroz vrijeme, a **želimo praćenje povijesti** — to je opća ideja skladišta podataka.

Tip 1 — presnimavanje

Stara vrijednost se **prepisuje** novom. Koristi se kada praćenje povijesti tog atributa **nema analitički značaj**.

```
prije: 1200345 | Acer A5 Računalo | i5  
poslije:1200345 | Acer A5 Računalo | i7
```

+ jednostavno, bez rasta tablice — **povijest je nepovratno izgubljena**; stara izvješća se retroaktivno mijenjaju

Tip 2 — dodavanje novog zapisa

Povijest se čuva kao **novi zapis** u dimenziji. **Najčešći oblik praćenja SCD-a**.

```
1200345 | Acer A5 Računalo | i5  
1200346 | Acer A5 Računalo | i7 ← novi surogat ključ, ista poslovna šifra
```

Za praćenje aktivnosti zapisa dodaju se atributi — **dovoljan je samo jedan mehanizam**:

- Datum od / Datum do, ili
- indikator **Aktivan** (Y/N)

ID	Naziv	Procesor	Datum od	Datum do	Aktivan
1200345	Acer A5 Računalo	i5	2018-01-12	2019-03-15	N
1200346	Acer A5 Računalo	i7	2019-03-16		Y

+ potpuna povijest, izvješća ostaju točna — dimenzija raste, ETL je složeniji

Tip 3 — novi atribut

Povijest se zadržava **dodavanjem novog atributa**, u istom retku.

ID	Naziv	Procesor tip	Stari procesor tip
1200345	Acer A5 Računalo	i7	i5

+ jedan redak po entitetu, lako uspoređivati "prije/poslije" — čuva samo ograničen broj promjena (obično jednu) — razlika u odnosu na tip 2

Tip 4 — zasebna tablica povijesti

Trenutni podaci u **glavnoj** dimenzijskoj tablici, povijesni podaci u **zasebnoj tablici povijesti**.

Idealno za okruženja s jasnim potrebama za analizu trenutnih **vs.** povijesnih podataka.

+ poboljšava performanse upita na trenutnim podacima; pojednostavljuje analizu povijesnih — dodatni prostor za pohranu; **složeniji ETL procesi**

Hibridni tip 1 (proširenje tipa 3)

Tablica se proširuje **novim atributima** — kada su promjene **redovite i predvidive**.

ID	Naziv	Procesor tip	Procesor tip 2018	Procesor tip 2017
		i7	i5	i3

Hibridni tip 2 (kombinacija tipova 1+2+3)

Način primjene — sva tri mehanizma istovremeno:

- 1. održavamo **dva atributa**, trenutni i povijesni → **tip 3**
- 2. unosimo **novi zapis** s promjenom vrijednosti → **tip 2**
- 3. **ažuriramo svim atributima trenutnu vrijednost** → **tip 1**

1200345	Acer A5	Trenutni: i9	Povijesni: i5
1200346	Acer A5	Trenutni: i9	Povijesni: i7
1200347	Acer A5	Trenutni: i9	Povijesni: i9 ← novi zapis

Rezultat: možeš analizirati i "kako je bilo tada" (povijesni stupac po retku) i "kako je danas" (trenutni stupac, ažuriran svugdje).

SCD — sažeta tablica za brzo ponavljanje

Tip	Mehanizam	Povijest	Kada
1	prepiši vrijednost	nema	povijest nema analitičkog značaja

Tip	Mehanizam	Povijest	Kada
2	novi redak + Datum od/do ili Aktivan	potpuna	standardni izbor
3	novi stupac (stara vrijednost)	ograničena	usporedba prije/poslije jedne promjene
4	zasebna tablica povijesti	potpuna, odvojena	jasno odvojene analize trenutno vs. povijesno
Hibrid 1	više stupaca po razdoblju	ograničena, predvidiva	redovite, predvidive promjene
Hibrid 2	1 + 2 + 3 zajedno	potpuna + trenutni pogled	najzahtjevniji analitički scenariji

Ostale vrste dimenzija

Vrsta	Definicija	Glavna karakteristika
Usklađene (conformed)	tablice koje se pojavljuju u više dimenzijskih modela	omogućavaju prijelaz iz jednog područnog skladišta u drugo; osiguravaju konzistentnost, usporedivost, smanjuju redundanciju; kritične kod bottom-up pristupa
Degenerirane	atributi unutar same tablice činjenica	imaju svojstva dimenzijskog ključa, ali ne postoji odgovarajuća dimenzijska tablica ; korisne za grupiranje zapisa (npr. broj računa)
Potporne	referencira se iz druge dimenzije , ne iz tablice činjenica	to je snowflake shema; iznimka, a ne pravilo
Mini dimenzije	kod dimenzija s velikim brojem atributa, logički povezani atributi se odvajaju	spajaju se izravno s tablicom činjenica (dodatni atribut u t.č.); ubrzavaju pretraživanje; iz <i>monster dimensions</i> može se stvoriti više mini dimenzija
Kompozitne (junk)	atributi niske kardinalnosti premješteni iz tablice činjenica u posebnu dimenziju	oznake (Da/Ne), indikatori (Staro/Novo), statusi (Završeno/Nije završeno); za razliku od mini dimenzija, atributi NISU logički povezani
Heterogene	kombinira različite, ali logički slične entitete u jednu dimenziju	zajednički atribut u glavnoj tablici, opcionalni često u zasebnima; npr. hrana/posuđe/piće → Proizvodi; traži se ravnoteža između jedne velike polu-prazne dimenzije i mnogo zasebnih

Mini vs. junk — razlika koja se pita: mini dimenzija grupira **logički povezane** attribute (npr. sva demografija kupca); junk dimenzija grupira **nepovezane** attribute niske kardinalnosti samo da ih makne iz tablice činjenica.

Napredna svojstva tablica činjenica

Modeli činjeničnih tablica

Model	Opis	Primjer
Transakcijske	fokusirane na pojedinačne događaje ili transakcije ; vrlo detaljne	svaka stavka računa
Periodička snimka stanja (<i>periodic snapshot</i>)	bilježe stanje podataka u određenim intervalima ; korisno za analizu trendova	stanje računa na kraju svakog mjeseca
Akumulirajuća snimka stanja (<i>accumulating snapshot</i>)	prate napredak procesa od početka do kraja , ažurirajući status u istom retku kroz faze	narudžba: zaprimljena → plaćena → poslana → isporučena

Najčešće se koristi transakcijski model.

Tablica činjenica bez činjenica (*factless fact table*)

- Bilježi **postojanje događaja**.
- Tablica činjenica **bez mjere** (vrijednost = 1, ili 0/1).
- Mogu se koristiti za analizu **što se NIJE dogodilo** (npr. koji su promovirani proizvodi ostali neprodani; koji student nije došao na predavanje).

Unakrsni pregled (*drill across*)

- Upit **iz više tablica činjenica**; podaci se kombiniraju u jedinstven rezultat.
- Preduvjet: **usklađene dimenzije**.
- Tablice činjenica **mogu biti različite granularnosti**.

Pravovremenost podataka

Podaci obično dolaze sinkronizirano, redoslijedom **dimenzije** → **tablica činjenica**. Kada dođe do desinkronizacije:

	Rano	Kasno
Dimenzije	U redu	Problem
Činjenice	Problem	Problem

Rano dolazeće činjenice — dva rješenja:

1. Postoji **općeniti zapis** u dimenziji → unese se zapis u t.č. i **privremeno poveže s općenitim zapisom**; t.č. se ažurira kad stigne pravi dimenzijski zapis.
2. Unese se zapis u dimenziju **s dostupnim podacima** → poveže se s t.č. → kasnije se dimenzija ažurira po **tipu 1**.

Kasno dolazeće činjenice — utječu na **prethodna izvješća** (treba dozvoliti unos kasnih podataka):

- pronaći zapise u **svim** dimenzijama koji su vrijedili u **trenutku stvaranja transakcije** (moguće samo uz **dimenzije tipa 2**)
- unijeti novi zapis u t.č. s tako određenim ključevima

Kasno dolazeće dimenzije:

- unijeti novi zapis u dimenzijsku tablicu s odgovarajućim vremenom nastanka
- ažurirati sve pripadajuće dimenzijske zapise **nakon** vremena novog zapisa, ako se mijenjaju
- ažurirati **DatumDo** prethodnog i promatranog zapisa
- **promijeniti veze u činjeničnoj tablici** koje se odnose na razdoblje novounesenog zapisa

Provjeri se

1. Nabroji četiri pravila za surogat ključeve.
2. Objasni razliku između SCD tipa 2 i tipa 3 na istom primjeru.
3. Kada bi izabrao tip 4 umjesto tipa 2?
4. Što je degenerirana dimenzija? Zašto nema svoju tablicu?
5. Razlika mini dimenzije i junk (kompozitne) dimenzije?
6. Što je factless fact table i za kakvu analizu je nezamjenjiva?
7. Zašto su za kasno dolazeće činjenice **nužne** dimenzije tipa 2?
8. Popuni tablicu pravovremenosti (rano/kasno × dimenzije/činjenice).

Checkpoint 3 (proširen): mjera ili tablica činjenica bez činjenica · 5 dimenzija · 2–3 hijerarhije u 2 dimenzije, jedna degenerirana dimenzija · star ili snowflake shema · uključiti napredne mogućnosti (SCD, različite izvedbe dimenzijskih tablica).

P6 — ETL proces

Ključne ideje

- **ETL = Extract, Transform, Load**, a sve tri faze se odvijaju preko **pripremnog područja**.
- **CDC tehnike** i njihova usporedna tablica — sigurno ispitno pitanje.
- Transformacija nije samo "pretvorba formata" nego prije svega **čišćenje i kontrola kvalitete**.

ETL proces

```

IZVOR 1  |
IZVOR 2  | → IZDVAJANJE → TRANSFORMACIJA → UČITAVANJE → skladište podataka
IZVOR 3  |      |
           |      | PRIPREMNO PODRUČJE (staging area) |
  
```

Odgovorani je za:

- **izdvajanje** podataka iz transakcijskog sustava u pripremono područje
- **transformaciju** — čišćenje podataka + transformacija u strukturu za dimenzijski model
- **učitavanje** podataka u skladište

ETL je **najzahtjevniji dio izrade skladišta** (implementacija i održavanje) i **specifičan je za svaku organizaciju**.

Izazovi po fazama: *izdvajanje* — detektiranje promjena, više izvora; *transformacija* — način transformacije i čišćenja, različitost podataka; *punjenje* — način učitavanja.

Pripremno područje (*staging area*)

- Područje izvornih podataka za transformaciju i čišćenje — u biti **kopija transakcijskog sustava**.
- **Korisnici nemaju pristup** pripremnom području; **upiti ne mogu pristupiti** tim podacima.
- Tablice mogu biti **dodane ili izbrisane bez pravila**.
- Iz pripremnog područja se puni skladište podataka.

Zašto uopće postoji: da se produkcijski sustav ne opterećuje transformacijama i da se prljavi, polutransformirani podaci nikada ne vide u skladištu.

Izdvajanje podataka

Prvo pravilo: produkcijski sustav ne smije biti ugrožen prikupljanjem podataka za skladište. Paziti da:

- se podaci **ne mijenjaju (ili izgube)** u izvorišnom sustavu
- se **ne mijenja (ili što manje) konfiguracija** sustava
- ne stradaju **performanse** (zaključavanje) izvorišnog sustava — pitanje **vremena izdvajanja**

Načini izdvajanja

	Potpuno	Djelomično
Što obuhvaća	sve dostupne podatke iz izvora	samo podatke promijenjene od zadnjeg uspješnog ETL-a
Kada	prvo punjenje (<i>initial load</i>), <i>full load</i>	inkrementalna nadopuna
Složenost	manje komplicirano — ne mora se voditi briga o već učitanim podacima	kompleksnije — traži detekciju promjena
Napomena	zahtijeva posebnu verziju ETL procesa	frekvencija ovisi o poslovnom procesu (npr. dnevno)

Skladište može biti **jedini izvor povijesnih podataka** tvrtke — zato ponovno inicijalno punjenje treba raditi vrlo oprezno; nije praktično za veća skladišta.

Change Data Capture (CDC)

CDC = sposobnost detektiranja promijenjenih podataka u izvorišnom sustavu i njihovo prikupljanje.

1. Dodavanje vremenske oznake Poseban atribut koji prati vrijeme (dan, sat, minuta, sekunda). ETL uspoređuje vrijeme zadnje ekstrakcije s oznakom na zapisu. *Ograničenja:* bilježi samo **zadnju izmjenu**; **ne vidi obrisane zapise**.

2. Razlika snimki stanja Usporedba **zapis po zapis** s podacima iz prethodnog ažuriranja; stara snimka mora ostati u pripremnom području. **+** jednostavna za implementaciju, **pronalaži sve promjene** **–** zahtijeva

dosta resursa i vremena

3. Aplikacijsko bilježenje promjena Bilježenje promjena u posebnu tablicu; **svi aplikacijski programi moraju jednako evidentirati promjene**. + pogodno za baze koje ne podržavaju mehanizme praćenja — složeno, traži veliki angažman na promjeni aplikacija

4. Korištenje okidača baze podataka Okidači (*triggers*) i pohranjene procedure bilježe svaki **INSERT**, **UPDATE**, **DELETE** u log tablicu. — velike izmjene na bazi, **opterećenje baze** — okidače treba **vrlo oprezno** koristiti

5. Korištenje dnevnika transakcija Koristi mehanizme oporavka podataka (*data recovery*) koje pruža DBMS. Vrsta podataka ovisi o implementaciji; zahtijeva **razvoj posebnog algoritma** i sinkronizaciju s ETL-om.

Usporedba CDC tehnika — tablica za memoriranje

Utjecaj na:	izvorišnu bazu	aplikacije	složenost implementacije	evidencija povijesti	performanse izvornog sus.
dodavanje vremenske oznake	srednji	nema	niska	slaba	nizak
razlika snimki stanja	nema	nema	niska	nema	nizak
aplikacijsko bilježenje promjena	nema	visok	visoka	visoka	visoka
korištenjem okidača baze	visok	nema	srednja	visoka	visoka
korištenje dnevnika transakcija	nema	nema	srednja	visoka	nizak

Zadnji redak je jedini s "nema/nema/srednja/visoka/nizak" — **dnevnik transakcija je tehnički najelegantnije rješenje**, cijena mu je razvoj posebnog algoritma.

Transformacija

Drugi korak ETL-a, izvodi se **u pripremnom području**. Podrazumijeva:

- **analizu** podataka
- **čišćenje** podataka
- **transformaciju u odgovarajuću strukturu** za dimenzijski model

Operacije se izvršavaju **sljednim redoslijedom** (*pipelining order*).

Čišćenje podataka — zašto?

Zbog **kvalitete podataka koji se učitavaju u skladište**. Bitne karakteristike: **ispravnost** · **nedvosmislenost** · **konzistentnost** · **potpunost**.

Primjer sa slajda i tipovi grešaka koje pokazuje:

ID	Ime	God. rođ.	Starost	Spol	Telefon	Pošta
233	Anić, Ivan	13.4.80	26	M	99999999	51000
233	Petra Ivić	33.4.87	32	M	01234568	99999
234	Ivan Anić	13.4.80	36	M	051236543	51000

Pošta	Grad
44000	Sisak
51000	Rjeka
1000	Hrvatska

Detektirane greške:

- **reprezentacija** — "Anić, Ivan" vs. "Ivan Anić"
- **jedinstvenost** — ID 233 pojavljuje se dvaput
- **kontradikcija** — ista godina rođenja, različita starost (26 vs. 36)
- **netočne vrijednosti** — datum 33.4.87, telefon 99999999
- **nedostajuće vrijednosti**
- **referencijalni integritet** — pošta 99999 ne postoji u šifarniku
- **greške** — "Rjeka" (tipfeler), 1000 → Hrvatska (država umjesto grada)
- **duplikati** — 233/234 su vjerojatno ista osoba

Testovi kvalitete (*Quality Screens, QS*)

- Testovi u ETL procesu koji se **javljaju ako podaci ne prođu određeni test kvalitete**.
- Ako se javi greška, aktivira se QS i **bilježi se u shemu grešaka** (*error event schema*).
- Vrste testova: **stupčani · strukturni · testovi poslovnih pravila**

Schema grešaka (*error event schema*)

Dimenzijski model čiji je cilj evidentiranje svih grešaka u ETL procesu.

- **tablica činjenica = događaj greške; granularnost = svaka greška u ETL-u**
- **dimenzije:** vremenska, obrada u kojoj se greška dogodila, test kvalitete...

Revizorska dimenzija (*audit dimension*)

- Činjeničnoj tablici se pridjeljuje **dimenzija s metapodacima koji opisuju kvalitetu podataka**.
- Pridjeljuje se **svakom zapisu** tablice činjenica.
- Sadrži ETL podatke o procesiranju i kvaliteti.
- Zajedno sa shemom grešaka omogućuje provjeru je li bilo problema s kvalitetom tijekom ETL-a.

Transformacija u strukturu dimenzijskog modela

Izgradnja dimenzija:

- uklanjanje duplih dimenzijskih zapisa
- mehanizam **sporo mijenjajućih dimenzija**
- **generiranje surogat ključeva**

Izgradnja tablice činjenica:

- **povezivanje s dimenzijama** (dohvat surogat ključeva)

Redoslijed je obavezan: **prvo dimenzije, pa tablica činjenica** — inače nema surogat ključeva na koje bi se t.č. povezala. To je i razlog zašto su "rano dolazeće činjenice" problem (P5).

Punjenje

Moguće je: **odjednom** ili **zapis po zapis**. Odabir ovisi o procesu; **punjenje odjednom je vremenski manje zahtjevno**. Akcije nad zapisima: **dodati** · **izmijeniti** · **brisati**.

Real-time skladišta podataka

- Nastojanje da se **vremensko kašnjenje smanji na najmanju moguću razinu**. (Pitanje: postoji li *stvarni* real-time?)
- Izazovi: izmjene ETL procesa, **mini obrade podataka**, interakcija postojećih i novih zapisa.

Provjeri se

1. Nabroji tri faze ETL-a i navedi po jedan izazov svake.
2. Zašto postoji pripremno područje i tko mu ima pristup?
3. Nabroji pet CDC tehnika i za svaku navedi jedan nedostatak.
4. Koja CDC tehnika ne bilježi obrisane zapise i zašto?
5. Koja CDC tehnika ne vodi nikakvu evidenciju povijesti?
6. Što je shema grešaka? Koja joj je granularnost i koja tablica čini činjenice?
7. Razlika između sheme grešaka i revizorske dimenzije?
8. Zašto se u transformaciji dimenzije grade prije tablice činjenica?

Checkpoint 4 (projekt): napuniti skladište iz **barem 2 izvora** · provesti ETL · provjeriti unos podataka · **provjeriti da nema izgubljenih podataka**.

P8 — OnLine Analytic Processing (OLAP)

Ključne ideje

- **Pet faza implementacije DW-a** poklapa se s pet checkpointa projekta.
- **Pet OLAP operacija** na kocki — znati ih nabrojati i objasniti.
- **FASMI** — akronim za svojstva koja OLAP alat mora imati.
- **MOLAP / ROLAP / HOLAP** — usporedna tablica.

Implementacija skladišta podataka — 5 faza

#	Faza	Sadržaj
1	Poslovni zahtjev	definirati predmet DW-a, očekivane rezultate projekta, korisnike; planiranje projekta; definiranje potrebnih resursa
2	Analiza operativnog sustava	definiranje izvora podataka; analiza relacijskog modela; detektiranje bitnih elemenata (entiteta, relacija, atributa)
3	Dizajn DW-a	definiranje tablice činjenica i dimenzija; ostala pitanja dizajna; stvaranje dimenzijskog modela
4	ETL	izdvajanje, transformacija, punjenje; prvo punjenje; ažuriranje sustava
5	Korištenje / OLAP	OLAP analiza; održavanje

Ove faze 1:1 odgovaraju checkpointima projekta 1–5.

Što je OLAP

Različite definicije: OLAP je **pristup / tehnike i alati / metoda** koja podržava **jednostavnu analizu multi-dimenzijskih podataka**.

- Korisnik **nije ograničen na već definirani skup izvještaja** — može sam kreirati nove.
- Dostupno mu je **grafičko sučelje** za specificiranje parametara analize.
- Korisnici: **poslovni korisnici, analitičari, menadžeri**.
- Ne podrazumijeva znanje programskih jezika** (ni SQL-a).
- Rezultati su grafički, u obliku koji se može uključiti u druge aplikacije.
- Tipični upiti: **multi-dimenzijski upiti, usporedbe, top vrijednosti**.

Definiranje OLAP izvješća: odabrati mjeru(e) → odabrati dimenzije → definirati filtere → definirati izgled.

Alati: **Tableau** (na predavanjima), **Power BI**, i drugi.

OLAP operacije na kocki

Operacija	Definicija	Efekt na kocku
Slice	ograničavanje jedne dimenzije na neki raspon vrijednosti	rez kroz kocku
Dice	ograničavanje više dimenzija na neki raspon	manja kocka
Roll-up	sažimanje podataka kretanjem prema višim razinama hijerarhije ili redukcijom dimenzija	manje detalja (dan → mjesec → godina)
Drill-down	obrnuto od roll-upa: niže razine sažimanja / detaljni podaci, dodavanje novih dimenzija	više detalja
Pivot (rotate)	promjena redoslijeda dimenzija ; rotacija kocke; 3D serije u 2D površine	ista podatkovna baza, drugi pogled
Drill across	uključivanje više tablica činjenica u jedan rezultat	traži usklađene dimenzije (P5)

Sažeto: *slice and dice* = selekcija i projekcija · *drill-down* = spuštanje niz hijerarhiju · *roll-up* = uspinjanje uz hijerarhiju · *pivot* = rotiranje kocke · *drill across* = više tablica činjenica.

FASMI

Fast **A**nalysis of **S**hared **M**ultidimensional **I**nformation — svojstva koja OLAP alat mora imati:

Slovo	Svojstvo	Zahtjev
F	brzina	većina upita unutar 5 sekundi , rijetki do 20
A	analiza	podržava poslovnu logiku i statističku analizu; ad-hoc upiti bez programiranja
S	dijeljenje	sigurnosni zahtjevi
M	multi-dimenzionalnost	multidimenzionalni konceptualni pogled, podržava dimenzije i hijerarhije
I	informacije	obrađuje velike količine podataka

Metapodaci

„Podaci o podacima“. Kategorije:

- **poslovni** metapodaci
- **tehnički** metapodaci
- **operacijski** metapodaci

Uloga: pomažu u **lociranju sadržaja** skladišta; koriste ih alati za upit, **transformacijski alati** i **alati za izradu izvješća**.

Agregacije

Temeljna tehnika kojom OLAP sustavi postižu veću brzinu.

- Ideja: **unaprijed izračunati agregirane podatke** koji će se pozivati tijekom upita.
- Cijena: **troši se procesorsko vrijeme i mjesto na disku unaprijed.**
- Rade se **prilikom ETL procesa**, točnije punjenja.
- Agregirani podaci se pohranjuju u **posebnu tablicu namijenjenu isključivo za to.**
- **Procesiranje kocke** = osvježavanje sadržaja kocke i agregatne tablice.

Agregirana tablica činjenica pohranjuje agregirane podatke niže granularnosti prema **višim hijerarhijama** dimenzija:

[illegible]

MDX

- *Multidimensional expressions* — **upitni jezik za rad s multi-dimenzijskim podacima**, razvio ga **Microsoft**.
- Osnovni element analitičkog procesiranja su **kocke**; kockom se smatra **tablica činjenica i sve pripadajuće dimenzije**.
- Postoji **posebna dimenzija Mjere**.
- Naredba za dohvat podskupa podataka: **SELECT**.

Arhitektura OLAP sustava

	MOLAP	ROLAP	HOLAP
Pohrana	multi-dimenzijska kocka	relacijska baza podataka	kombinacija
Mehanizam	automatsko popunjavanje agregata pri učitavanju	sloj meta-podataka koji mapira tablice u dimenzije	dio podataka u RDB, dio u MDB
Prednosti	dobre performanse (brzina upita); mogu se izvoditi kompleksne kalkulacije	velike količine podataka ; funkcionalnosti relacijske baze	obuhvaća prednosti oba
Nedostaci	limitirana količina podataka ; tehnologija se često unaprijed ne koristi u organizaciji, može biti skupa	performanse upita ; ograničenje na SQL	različite interpretacije ovisno o proizvođaču
Tipično			podaci se dijele na agregate i podatke

Provjeri se

1. Nabroji pet faza implementacije DW-a i poveži ih s checkpointima.
2. Objasni razliku između slicea i dicea.
3. Koja je razlika između roll-upa i redukcije dimenzija? Je li to isto?
4. Što znači akronim FASMI? Koji je vremenski kriterij za "F"?
5. Kada nastaju agregacije i gdje se pohranjuju?
6. Što je izvedena dimenzija?
7. Usporedi MOLAP i ROLAP po dvije prednosti i dva nedostatka.
8. Zašto drill across zahtijeva usklađene dimenzije?

Checkpoint 5 (projekt): odabrati OLAP alat · provesti smislenu analizu u kontekstu svog problema · različiti scenariji korištenja · **pokazati sve operacije na kocki** kroz analizu rezultata · generirati tablice, grafove, **dashboard**.

P9 — Skladišta podataka i rudarenje podataka

Ključne ideje

- **Skladište odgovara na "koliko je bilo", rudarenje na "koliko će biti".**
- **KDD proces** ima 5 koraka; rudarenje podataka je **jedan od njih**.
- **Nadzirano** ↔ **prediktivno**, **nenadzirano** ↔ **deskriptivno**. Ova ekvivalencija je ključ cijelog drugog dijela kolegija.

Zašto rudarenje

Skladišta podataka prikupljaju podatke iz različitih izvora, sadrže povijesne podatke koji su prošli transformaciju i čišćenje, i služe za upite i analizu — **OLAP alatima**.

Ograničenja skladišta:


- velike količine podataka **vs.** OLAP alati
- **data rich, information poor situacija**
- analiza je **ovisna o poslovnom korisniku**; poslovna odluka se često donosi **na temelju intuicije**
- traži se **ekspertno znanje**
- **potreba za alatima koji bi sami pronalazili znanje unutar podataka**

Ilustracija razlike:

- „Koliko je iznosila prodaja proizvoda u 2018.?” → **skladište podataka / OLAP**
- „Koliko će iznositi prodaja proizvoda u 2030.?” → **rudarenje podataka**

Definicija (Berry i Linoff, 2004.): Rudarenje podataka je **istraživanje i analiza velikih količina podataka u nastojanju otkrivanja smislenih obrazaca i pravila**.

Rudarenje podataka kao interdisciplinarno područje



Motivacija: velika količina podataka · pronalaženje skrivenih uzoraka · u nekim slučajevima nemoguće je podatke analizirati "ručno" bez alata.

KDD proces

KDD = Knowledge Discovery in Databases — proces stvaranja znanja iz podataka.

Dva pogleda na odnos KDD-a i rudarenja: (a) izjednačavanje dvaju pojmova, (b) **rudarenje podataka je dio KDD procesa** (Fayyad, Piatetsky-Shapiro & Smyth, 1996.).

Koraci KDD-a:

1. **odabir podataka**
2. **predprocesiranje**
3. **transformacija**

4. rudarenje podataka


5. evaluacija

Uočiti paralelu s ETL-om: koraci 1–3 KDD-a su u biti isto što i ETL, samo s ciljem modeliranja umjesto izvještavanja.

Od podataka do znanja — primjeri

Podaci	Metoda	Znanje
pozivi	detektiranje stršućih vrijednosti	otkrivanje prijevara
transakcije	klasifikacija	kreditna rizičnost
računi	asocijativna pravila	povezanost proizvoda
slike	klasifikacija	prepoznavanje tijela

Mjesto u poslovnoj analitici



Dvije vrste zadaća

	Deskriptivni modeli	Prediktivni modeli
Što rade	opisuju generalna svojstva podataka u bazama	koriste podatke za stvaranje predikcije
Cilj	pronalazak uzorka koji poslovni korisnici mogu interpretirati ; stvaranje novih, netrivialnih informacija; razumijevanje odnosa između atributa	predviđanje budućih događaja
Način učenja	nenadzirano	nadzirano

Nadzirano učenje

- Učenje **predviđanja izlazne varijable na temelju ulaznih**.
- Vrijednosti izlazne varijable su **poznate na trening skupu**.
- Skup za učenje se daje sustavu s ciljem da nauči "**pravila**" po kojima će vrednovati buduće primjere.
- Zadaci: **klasifikacija, regresija**.

Nenadzirano učenje

- **Otkrivanje grupa sličnih objekata** u podacima, na temelju karakteristika/atributa.
- **Ne postoji a priori znanje o grupama** u podacima.
- Zadaći: **klasteriranje, asocijativna pravila, detektiranje anomalija**.

Pet glavnih zadataka rudarenja podataka

Zadaca	Tip	Izlazna varijabla	Tipične tehnike
Klasifikacija	prediktivna (nadzirano)	kategorička , mali broj diskretnih vrijednosti	neuronske mreže, SVM, logistička regresija
Regresija	prediktivna (nadzirano)	kontinuirana	linearna, polinomna regresija
Klasteriranje	deskriptivna (nenadzirano)	nema — broj klastera i njihovo značenje nisu poznati unaprijed	k-means
Asocijativna pravila	deskriptivna (nenadzirano)	nema — pravila oblika <i>ako X onda Y s vjerojatnošću $\geq X\%$</i>	Apriori
Detekcija anomalija	deskriptivna (nenadzirano)	identifikacija netipičnih vrijednosti	statističke, distance-based

Klasifikacija: trening podaci sadrže vrijednost izlazne varijable; rezultat učenja je **model koji se koristi za klasifikaciju budućih primjera**.

Klasteriranje: dekompozicija skupa objekata u skupove sličnih objekata; različiti klasteri predstavljaju različite klase ili objekte.

Asocijativna pravila: cilj je pronalazak svih pravila oblika "Ako su x, y, z sadržani u skupu M , tada je k također sadržan u M uz vjerojatnost od najmanje $X\%$."

Detekcija anomalija: identifikacija netipičnih vrijednosti. Moguća zloupotreba (kreditne kartice, telekomunikacijske poruke), loši podaci. Može se koristiti **pri predprocesiranju** ili **kao cilj analize**.

Provjeri se

1. Navedi pet ograničenja skladišta koja motiviraju rudarenje podataka.
2. Što znači *data rich, information poor*?
3. Nabroji pet koraka KDD-a. Gdje je unutar njih rudarenje podataka?
4. Poveži: nadzirano/nenadzirano ↔ prediktivno/deskriptivno.
5. Za svaku od pet zadataka navedi tip izlazne varijable.
6. Za jedan konkretan poslovni problem po vlastitom izboru definiraj: zadatak, izlaznu varijablu i izvor podataka.

P10 — Rudarenje podataka: klasifikacija

Ključne ideje

- **Tri uvjeta za primjenu strojnog učenja** — obrazac, nemogućnost formule, podaci.
- **Šest komponenti učenja** — s oznakama f , h , H , D ...
- **Klasično programiranje vs. strojno učenje** — dijagram koji objašnjava sve.

Zašto strojno učenje

- **složeni problemi**
- **velike količine podataka**
- **sustavi koji se dinamički mijenjaju**

Interdisciplinarno: računarna znanost · statistika · matematika i linearna algebra · optimizacija.

Primjene: Google (preciznost rezultata pretraživanja), Facebook (postovi prema interesima), Netflix (preporuke), NVIDIA (praćenje objekata u vožnji), digitalni pomoćnici (prepoznavanje govora).

Klasifikacija

Klasifikacija predstavlja problem identifikacije kojoj klasi (kategoriji) nova opservacija pripada, na temelju trening skupa podataka koji sadrži opservacije čije su klase unaprijed poznate.

Klasifikacija je primjer nadziranog učenja.

Kada odabrati strojno učenje — tri uvjeta

Primjer problema: *Predvidjeti koji klijent banke će imati problema prilikom vraćanja kredita.* Odluka se mora donijeti pri primitku zahtjeva, mora vrijediti za cijelo razdoblje trajanja kredita, i mora što bolje razlikovati dobre od loših klijenata.

Karakteristike problema bitne pri odabiru:

1. **postoji uzorak u podacima** (veza između karakteristika klijenta i sposobnosti vraćanja kredita)
2. **ne može se matematički odrediti formula**
3. **postoje podaci**

Arthur Samuel (1959): „Strojno učenje je grana koja proučava kako dati računalu sposobnost učenja bez eksplicitnog programiranja.”


Ako uvjet 2 ne vrijedi — napiši formulu, ne treniraj model. Ako uvjet 1 ne vrijedi — model uči šum. Ako uvjet 3 ne vrijedi — nema učenja.

Komponente učenja

Oznaka	Komponenta	U primjeru banke
x	ulaz	prijava klijenta
y	izlaz	dobar ili loš klijent
$f : X \rightarrow Y$	ciljna funkcija	savršena formula za odobravanje — nepoznata!
$(x_1, y_1) \dots (x_n, y_n)$	podaci	povijesni podaci o kreditima
$h : X \rightarrow Y$	hipoteza	model koji smo naučili

Oznaka	Komponenta	U primjeru banke
H	skup (prostor) hipoteza	svi mogući modeli odabranog tipa

Grafički prikaz procesa (prema Abu-Mostafa, *Learning from Data*):



Ključno pitanje sa slajda: „**Da li je moguće naučiti nešto o nečemu što nam je nepoznato?**” Da — jer h aproksimira f na podacima, a validacija provjerava koliko dobro ta aproksimacija generalizira.

Pouka: **usredotočiti se na komponente koje su pod našim utjecajem** (podaci, H , algoritam) — f nikada nije.

Primjer učenja (10 klijenata)

Poznati su mjesečni **trošak** i **prihod** klijenta; 10 prijašnjih kredita.

Klijent	Trošak	Prihod	Klijent	Trošak	Prihod
A	4057	4000	F	6500	1800
B	5800	5500	G	8000	3000
C	2500	8500	H	4750	4250
D	3000	5200	I	5000	7000
E	2100	12000	J	3400	8000

Tok procesa kroz slajdove:

1. **Prostor primjera** — prazan koordinatni sustav (trošak $\times$ prihod)
2. **Povijesni podaci** — ucrtani klijenti s poznatim ishodom
3. **Intuicija** — ljudsko oko vidi granicu
4. **Učenje (trening)** — algoritam iterativno pomiče granicu: **greška = 9 $\rightarrow$ 7 $\rightarrow$ 2 $\rightarrow$ 0**
5. **Odabir hipoteze / validacija** — četiri kandidata (I–IV) daju istu ili sličnu grešku na treningu, ali ne generaliziraju jednako
6. **Novi klijenti** — model se primjenjuje na neviđene podatke
7. **Rekalibracija** — nakon nekog vremena model se ponovno trenira


Najvažnija poanta: greška = 0 na treningu **nije** cilj. Slajd "Odabir hipoteze — validacija" pokazuje četiri hipoteze s dobrom trening-točnošću, a valja izabrati onu koja najbolje generalizira. To je uvod u **bias-variance trade-off** (P12).

Podjela učenja

- **Nadzirano učenje** (problemi: klasifikacija i regresija)

- generativni i diskriminativni modeli
- probabilistički i neprobabilistički modeli
- parametarski i neparametarski modeli
- linearni i nelinearni modeli
- **Nenadzirano učenje**
- **Učenje uz podršku** (*reinforcement learning*)

Klasično programiranje vs. strojno učenje



Ovo je najkoncizniji sažetak cijele discipline: u klasičnom programiranju čovjek piše pravila, u strojnom učenju **računalo izvodi pravila iz podataka i rezultata**.

Zaključak predavanja

- prepoznati **prikladnost problema**
- važnost **dostupnih podataka**
- poznavati **komponente učenja** — svaka nosi svoje izazove; usredotočiti se na one pod našim utjecajem
- **pažljivo odabrati najbolju hipotezu**
- **rekalibracija** nakon određenog vremena

Provjeri se

1. Nabroji tri uvjeta za primjenu strojnog učenja. Što ako neki nije zadovoljen?
2. Objasni f , h i H . Koja je od njih nepoznata i zašto to nije problem?
3. Zašto greška = 0 na treningu nije nužno dobra vijest?
4. Nacrtaj dijagram komponenti učenja.
5. Objasni razliku klasičnog programiranja i strojnog učenja u smislu ulaza i izlaza.
6. Zašto je potrebna rekalkibracija?

P11 — Rudarenje podataka: regresija i klasteriranje

Ključne ideje

- **Klasifikacija vs. regresija: razlika je isključivo u tipu izlazne varijable.**
- **Normalna jednadžba** $\beta = (X^T X)^{-1} X^T y$ — treba znati izračunati na malom primjeru.
- **k-means u 4 koraka.**

Regresija

Predviđanje vrijednosti zavisne varijable na temelju vrijednosti nezavisnih varijabli.

	Klasifikacija	Regresija
Izlazna varijabla	diskretne vrijednosti	kontinuirane vrijednosti
Primjer	dobar/loš klijent	iznos potrošnje

Oba su **nadzirano učenje** — razlika je *samo* u vrijednostima koje izlazna varijabla može poprimiti.

Modeli

Hipotetski model odnosa između dvije ili više varijabli: $\mathbf{y} = \mathbf{f}(\mathbf{x}, \boldsymbol{\beta})$

Osnovni model — **linearna regresija**:

$$\hat{y} = \beta_1 x + \beta_0$$

Opisuje odnos između varijabli koristeći **jednadžbu pravca**.

Složeniji modeli: **polinomna regresija**, **ridge regresija**, ...

Vrste prema broju varijabli

Naziv	Ulaznih varijabli	Izlaznih varijabli
Linearna regresija	jedna	jedna
Višestruka linearna regresija	više	jedna
Multivarijatna regresija	više	više

Terminologija (znati sve pojmove)

- **nezavisna varijabla (varijable), X**
- **zavisna varijabla, y**
- **model** — linearna regresija
- **funkcija gubitka** — **RSS** (*Residual Sum of Squares*)
- **reziduali** — odstupanja stvarnih od predviđenih vrijednosti
- **optimizacijski postupak** — **OLS** (*Ordinary Least Squares*)
- **pretpostavke linearne regresije**
- **inferencija i generalizacija**

Komponente učenja primijenjene na regresiju

Komponenta učenja	U linearnoj regresiji
cilj	ciljna funkcija f
skup podataka (x, y)	povijesni podaci
skup hipoteza H	linearna regresija (svi pravci)
algoritam za učenje	OLS
mjera kvalitete	RSS

Komponenta učenja U linearnoj regresiji

odabrana hipoteza h konkretan pravac $\hat{y} = \beta_0 + \beta_1 x$

Matrični zapis i rješenje

Linearni model: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ (gdje je $\boldsymbol{\epsilon}$ **stohastička komponenta**)

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & X_{11} & \cdots & X_{1k} \\ 1 & X_{21} & \cdots & X_{2k} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n1} & \cdots & X_{nk} \end{bmatrix} \times \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \epsilon_0 \\ \epsilon_1 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

Rješenje (normalna jednadžba):

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Riješen primjer sa slajdova — nauči ovo napamet

$$\mathbf{y} = \begin{bmatrix} 100 \\ 100 \\ 200 \\ 250 \\ 350 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{bmatrix}$$

Korak 1 — transponiraj:

$$\mathbf{X}^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{bmatrix}$$

Korak 2 — pomnoži:

$$\mathbf{X}^T \mathbf{X} = \begin{bmatrix} 5 & 15 \\ 15 & 55 \end{bmatrix}$$

(gornji lijevi = $n = 5$; ostalo = $\sum x = 15$ i $\sum x^2 = 55$)

Korak 3 — determinanta i inverz:

$$\det(\mathbf{X}^T \mathbf{X}) = 5 \cdot 55 - 15 \cdot 15 = 275 - 225 = 50$$

$$(\mathbf{X}^T \mathbf{X})^{-1} = \frac{1}{50} \begin{bmatrix} 55 & -15 \\ -15 & 5 \end{bmatrix} = \begin{bmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{bmatrix}$$

Korak 4 — desna strana:

$$\mathbf{X}^T \mathbf{y} = \begin{bmatrix} \sum y \\ \sum xy \end{bmatrix} = \begin{bmatrix} 1000 \\ 3650 \end{bmatrix}$$

Korak 5 — rezultat:

$$\hat{\boldsymbol{\beta}} = \begin{bmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{bmatrix} \begin{bmatrix} 1000 \\ 3650 \end{bmatrix} = \begin{bmatrix} 1100 - 1095 \\ -300 + 365 \end{bmatrix} = \begin{bmatrix} 5 \\ 65 \end{bmatrix}$$

$$\hat{y} = 5 + 65x$$

Interpretacija rezultata

- **odsječak na osi y (intercept, β_0)** — vrijednost y ako je $x = 0$
- **beta koeficijenti** — ako se neka x varijabla promijeni za **jednu jedinicu**, dok su **sve ostale nezavisne varijable iste**, y će se promijeniti za vrijednost beta
- **veličina koeficijenta aproksimira relativnu važnost varijable**
- voditi brigu o **pretpostavkama linearne regresije**

Validacija

Imamo model, ali **ne znamo koliko je dobar**. Rješenje:

- podijeliti skup podataka na **trening/test**
- trening → generiranje modela; test (**primjeri koji nisu korišteni u treningu**) → provjera kvalitete
- mjera: npr. **MSE** (*Mean Squared Error*) na **testnom** skupu

Klasteriranje

Klasteriranje (grupiranje) je proces grupiranja fizičkih ili apstraktnih objekata u klase sličnih objekata.

Nadzirano vs. nenadzirano — usporedna tablica sa slajda

	Nadzirano učenje	Nenadzirano učenje
Model	$y = f(x)$: ciljna funkcija	Generator: ciljni model
Podaci	D: skup podataka s izlaznom varijablom, D: (x, y)	D: skup podataka bez izlazne varijable, D: (x)
Učenje	$y = h(x)$: model treniran za klasifikaciju primjera X	?
Cilj	greška ≈ 0	?
Mjere	točnost, preciznost, odziv	dobro definirane mjere: ?

Znakovi pitanja nisu propust — to je **poanta**: kod nenadziranog učenja **nema objektivnog kriterija ispravnosti**.

Zadaci nenadziranog učenja:

- **grupiranje** (*clustering*)
- **procjena gustoće** (*density estimation*)
- **otkrivanje novih/stršećih vrijednosti** (*novelty/outlier detection*)
- **smanjenje dimenzionalnosti** (*dimensionality reduction*)

Što je klaster? — tri definicije

1. **podskup objekata koji su „slični“**
2. podskup objekata gdje je **udaljenost između bilo koja dva objekta unutar klastera manja** nego udaljenost između bilo kojeg objekta izvan i onog unutar klastera

3. **spojene regije multidimenzijskog prostora** koje sadrže relativno **visoku koncentraciju točaka**, odvojene od drugih takvih regija prostorom relativno **niske** koncentracije

Cilj i kvaliteta

Cilj: **pomoći korisnicima da razumiju „prirodno“ grupiranje ili strukturu u skupu podataka**. Pogodno za velike količine podataka; primjenjivo na podacima skladišta podataka.

Može se koristiti **kao zaseban alat za istraživanje podataka** ili **kao predprocesiranje za druge algoritme**.

Dobra metoda producira klastere za koje vrijedi:

- **sličnost unutar klase (intra-cluster) je visoka**
- **sličnost izvan klase (inter-cluster) je niska**

Kvaliteta ovisi o **mjeri sličnosti i načinu njezine implementacije**; može se mjeriti i sposobnošću otkrivanja skrivenih uzoraka. **Objektivna evaluacija je problem — vrlo često je radi čovjek/ekspert područja**.

Vrste klasteriranja

Prema strukturi:

	Particijsko	Hijerarhijsko
Grupe	međusobno nepovezane	postoji povezanost i hijerarhija
Složenost	linearna	kvadratna ili veća
Preduvjet	potrebno odrediti broj grupa	rezultat je hijerarhijsko stablo , potrebno definirati uvjet prekida

Prema pripadnosti točke grupi: čvrsto i meko grupiranje.

k-means — algoritam u 4 koraka

1. **Odaberi k centara klastera** (postavljaju se **slučajnim odabirom** na prostor rješenja)
2. **Dodijeli svaki element najbližem centru** (koristeći **Euklidovu udaljenost**)
3. **Pomakni centar prema srednjoj vrijednosti** primjera dodijeljenih centru
4. **Ponovi korake 2 i 3** dok se ne zadovolji uvjet prestanka (npr. centar se ne miče, niti jedan primjer ne mijenja klaster)

Iz slajdova: $k = 3 \rightarrow$ postave se 3 centra slučajno $\rightarrow$ svaka točka se dodjeljuje najbližem $\rightarrow$ centri se pomiču $\rightarrow$ ponovna dodjela ("**Promjene**") $\rightarrow$ postupak se ponavlja do konvergencije.

Zamke k-meansa (izvedivo iz slajda "koje rješenje je najbolje?"): rezultat **ovisi o početnom slučajnom odabiru centara**, i **k se mora zadati unaprijed** — a "pravi" k obično nije poznat.

Provjeri se

1. Jedina razlika između klasifikacije i regresije?
2. Napiši normalnu jednadžbu i izračunaj β za $y = [100, 100, 200, 250, 350]$, $x = [1, 2, 3, 4, 5]$.
3. Što su RSS, OLS i rezidual? Kako su povezani?

4. Kako se interpretira beta koeficijent?
5. Zašto se MSE računa na **testnom**, a ne na trening skupu?
6. Navedi tri definicije klastera.
7. Što znači visoka intra-cluster i niska inter-cluster sličnost?
8. Usporedi partijsko i hijerarhijsko klasteriranje.
9. Opiši k-means u 4 koraka. Koje su mu dvije glavne slabosti?
10. Zašto je evaluacija nenadziranog učenja teža od nadziranog?

P12 — Asocijativna pravila, detekcija anomalija, ansambl učenje

Ključne ideje

- **Signifikantnost (support) i pouzdanost (confidence)** — formule i verbalna interpretacija.
- **Apriori princip:** svaki podskup čestog skupa je čest → kontrapozicija omogućuje rezanje pretrage.
- **Bagging smanjuje varijancu, boosting smanjuje bias.** Jednorečenična razlika.

Asocijativna pravila

Analiza proizvoda u košarici (*market basket analysis*).

Zadano: skup transakcija; svaka transakcija je skup artikala koje je kupac kupio prilikom posjeta trgovini. **Cilj:** pronaći sva pravila koja povezuju prisutnost jednog skupa artikala s drugim u košarici. *Npr. 80 % ljudi koji kupe kruh kupe i mlijeko.*

Primjena: košarica proizvoda · dizajn kataloga · web log analiza · detekcija prijevara · cross-marketing.

Formalno

$$X \implies Y \quad (\text{implikacija AKO-ONDA}), \quad X \cap Y = \emptyset$$

- **X = antecedent** (pretpostavka)
- **Y = consequent** (zaključak)
- Vrijednost/snaga pravila mjeri se prema **signifikantnosti** i **pouzdanosti**.

Kako se pravila koriste — primjer {pecivo,...} $\implies$ {sok}

Fokus	Poslovna upotreba
sok kao Y (zaključak)	kako povećati prodaju soka
pecivo u X (pretpostavka)	na koje proizvode će utjecati odluka da se pecivo više ne prodaje
pecivo u X i sok u Y	koji se proizvodi trebaju prodavati s pecivom da bi se povećala prodaja soka

Pojmovi

- **atribut / element** (*item*) — često pretvoreni u **binarne oznake**
- **skup atributa** (*itemset*) **I** — podskup mogućih atributa; npr. $I = \{A, C, E\}$; **redoslijed nije bitan**
- **transakcija** (*transaction*) — instanca skupa, jedna košarica; **TID** = ID transakcije

Osnovne mjere — $A \Rightarrow B$ [s, c]

Signifikantnost (support): frekvencija pravila unutar transakcija. Visoka vrijednost = velik broj transakcija uključuje promatrano pravilo.

$$\text{sig}(A \Rightarrow B) = p(A \cup B)$$

Govori: „**Koliko je ovo pravilo uopće važno u cijelom skupu?**”

Pouzdanost (confidence): postotak transakcija koje sadrže B ako sadrže i A — **uvjetna vjerojatnost**.

$$\text{pouzdanost}(A \Rightarrow B) = p(B|A) = \frac{\text{sig}(A, B)}{\text{sig}(A)}$$

Govori: „**Kad je pretpostavka ispunjena, koliko puta je došao i zaključak?**”

Čest uzorak

Čest uzorak (*frequent pattern*) ili skup atributa **I** je onaj čija je signifikantnost **viša ili jednaka minimalno definiranoj**: $\text{Sig}(I) \geq \text{minSig}$.

Svojstvo: svaki podskup čestog skupa atributa je čest. Gotovo svi algoritmi za asocijativna pravila temelje se na tom svojstvu.

Mali primjer

RB	Sadržaj košarice
1	A, D
2	A, C
3	A, B, C
4	B, E, F

- Skup atributa: {A,B} ili {B,E,F}
- $\text{Sig}(A,B) = 1$, $\text{Sig}(A,C) = 2$
- Za $\text{minSig} = 2$: **{A,C} je učestali uzorak**
- Uz minimalnu signifikantnost 50 % i pouzdanost 50 %:
 - $A \Rightarrow C$, sig 50 % (2/4), pouzdanost **66 %** (2/3)
 - $C \Rightarrow A$, sig 50 % (2/4), pouzdanost **100 %** (2/2)

Uoč: **pravilo nije simetrično**. $A \Rightarrow C$ i $C \Rightarrow A$ imaju istu signifikantnost ali različitu pouzdanost, jer se dijeli različitim nazivnikom.

Sva moguća pravila iz čestog uzorka {A,B,C}

$A \Rightarrow B, C$	$B \Rightarrow A, C$
$A, B \Rightarrow C$	$B, C \Rightarrow A$
$A, C \Rightarrow B$	$C \Rightarrow A, B$


Iz uzorka od k elemenata dobiva se $2^k - 2$ pravila (ovdje $2^3 - 2 = 6$).

Apriori princip

Problem: velike količine podataka — broj kombinacija eksplodira.

Princip: svaki podskup čestog uzorka je također čest — $\{A, B, C\}$ je čest $\Rightarrow \{A, B\}$ je čest

Posljedica (kontrapozicija): niti jedan nadskup skupa atributa koji nije čest ne treba generirati ili provjeravati. To omogućava odbacivanje mnogih kombinacija.



Ako $\{A, B\}$ nije čest $\rightarrow$ cijela podgrana ABC, ABD, ABCD otpada. Ako $\{A\}$ nije čest $\rightarrow$ otpada A, AB, AC, AD, ABC, ABD, ACD, ABCD.

Postupak (Apriori algoritam)

- Pronalazak čestih uzoraka** — skupovi koji zadovoljavaju minimalnu signifikantnost:
 - generirati skupove veličine $(k+1)$ iz skupova čestih uzoraka veličine k
 - provjeriti kandidate u skupu podataka radi utvrđivanja koji su česti
- Iskoristiti česte uzorke za generiranje pravila** — koristeći mjeru pouzdanosti

Potpuno riješen primjer sa slajdova (minSig = 2)

Skup podataka D:

TID	atributi
1	1, 3, 4
2	2, 3, 5
3	1, 2, 3, 5
4	2, 5

C1 $\rightarrow$ L1 (pretraži D, odbaci sig < 2):

skup	sig		skup	sig
{1}	2	→	{1}	2
{2}	3	→	{2}	3
{3}	3	→	{3}	3
{4}	1	X odbačen		
{5}	3	→	{5}	3

C2 → L2 (kandidati iz L1, pa pretraži D):

skup	sig	status
{1 2}	1	X
{1 3}	2	✓
{1 5}	1	X
{2 3}	2	✓
{2 5}	3	✓
{3 5}	2	✓

L2 = { {1,3}, {2,3}, {2,5}, {3,5} }

C3 → L3: jedini kandidat je **{2,3,5}** — jer su svi njegovi 2-podskupovi ({2,3}, {2,5}, {3,5}) u L2. **Sig({2,3,5}) = 2 ✓ → L3 = { {2,3,5} }**

(Zašto ne {1,3,x}? Jer bi {1,2} ili {1,5} morali biti u L2 — nisu.)

Generiranje pravila iz {2,3,5}, minPouzdanost = 75 %:

Pravilo	Račun	Pouzdanost	
$2 \Rightarrow 3,5$	2/3	66 %	X
$2,3 \Rightarrow 5$	2/2	100 %	✓
$2,5 \Rightarrow 3$	2/3	66 %	X
$3 \Rightarrow 2,5$	2/3	66 %	X
$3,5 \Rightarrow 2$	2/2	100 %	✓
$5 \Rightarrow 2,3$	2/3	66 %	X

Rezultat: asocijativna pravila $2,3 \Rightarrow 5$ i $3,5 \Rightarrow 2$.

Detekcija anomalija

Anomalija / vršna vrijednost = podaci čije su karakteristike značajno različite od ostatka skupa podataka.

Primjena: kreditne kartice · telekomunikacijske prijevare · neovlašteni pristupi · procesiranje slika.

Odakle anomalije dolaze

Uzrok	Objašnjenje
elementi drugih klasa	podaci se mogu značajno razlikovati ako pripadaju različitim klasama; ne-balansirani skupovi podataka
priroda varijacija u podacima	skupovi se mogu modelirati statističkom distribucijom; što su podaci dalje od centra distribucije, manja je vjerojatnost njihova pojavljivanja
greška u prikupljanju podataka	mjerni/unos problemi

Prva dva su **signal**, treći je **šum**. Razlikovanje je cijela vještina.

Pristupi prema označenosti podataka

Pristup	Dostupne oznake
Nadzirano	oznake klase dostupne za redovne primjere i za anomalije
Polu-nadzirano	oznake dostupne samo za redovne primjere
Nenadzirano	neoznačeni podaci ; temelji se na pretpostavci da su anomalije vrlo rijetka pojava

Rezultat detekcije

- **da/ne** — tipičan odgovor klasifikacije
- **vrijednost (score)** — svakom primjeru se dodjeljuje vrijednost anomalije; **rezultati se mogu rangirati**

Postupak

1. **obrada podataka** — predprocesiranje
2. **trening modela** — izrada modela; ovisi o podacima i odabranoj tehnici
3. **korištenje** — primjena modela za detekciju anomalija

Ansambl učenje

Proces kombiniranja više modela strojnog učenja (tzv. „slabih prediktora“) kako bi se dobio jedan jači, precizniji model.

- Cilj: **smanjenje pogrešaka predviđanja, poboljšanje robusnosti, bolja generalizacija na neviđenim podacima.**
- Umjesto traženja **jednog savršenog modela**, koristimo grupu modela čija se predviđanja **agregiraju**.
- **Meta-prediktor** — neki pristupi koriste dodatni model koji uči **kako najbolje kombinirati** predviđanja ostalih.

Koncept: mudrost gomile

Temelji se na statističkom fenomenu gdje je **prosjeak procjena grupe često točniji od procjene bilo kojeg pojedinca**.

- **individualna varijanca** — svaki model može pogriješiti na specifičnom dijelu podataka
 - **agregacija** — kombiniranjem se **individualne pogreške međusobno poništavaju**
 - **uvjet** — **modeli moraju biti različiti** kako bi ansambl bio koristan
- Uvjet raznolikosti je bitan: pet identičnih modela griješi identično i njihov prosjek ne popravlja ništa.

Bias vs. Variance trade-off

	Bias (pristranost)	Variance (varijanca)
Uzrok	prejednostavne pretpostavke (<i>underfitting</i>)	osjetljivost na šum u podacima (<i>overfitting</i>)
Simptom	visoka trening I visoka test greška	vrlo mala greška pri treniranju, vrlo velika pri testiranju
Slika	model pokušava prilagoditi ravnu crtu očito zakrivljenim podacima	model radi besprijekorno na viđenim podacima, ne generalizira na nove


Rješenje: ansambli omogućuju postizanje „zlatne sredine“ smanjujući jedan ili oba tipa pogreške.

Tri kategorije ansambla



	Bagging	Boosting	Stacking
Način	paralelno treniranje na različitim uzorcima	sekvencijalno — svaki model ispravlja greške prethodnika	meta-model kombinira predviđanja različitih tipova modela
Primjer	Random Forest	AdaBoost, GBM, XGBoost	SVM + KNN + RF + meta-model
Glavni cilj	smanjenje varijance (overfittinga)	smanjenje pristranosti (bias)	sveukupna točnost

Kako funkcionira Bagging



↓
Agregacija → glasovanje (klasifikacija) ili prosjek (regresija)

Random Forest

Najpoznatija Bagging metoda — gradi **ansambl stabala odluke**; svako stablo se trenira na **drugačijem uzorku podataka i drugačijem podskupu značajki**.

Prednosti: izuzetno točan · **rješava problem nedostajućih vrijednosti** · rijetko overfita

Ključne značajke:

- **feature randomness** — pri svakom dijeljenju čvora bira se samo **slučajan podskup atributa**; to **smanjuje korelaciju između stabala**
- **Out-of-Bag (OOB) error** — podaci koji **nisu korišteni za trening stabla** služe za **internu validaciju** točnosti
- **važnost značajki** — RF omogućuje **automatsko rangiranje atributa** prema doprinosu točnosti modela

Boosting

Za razliku od Bagginga, **sekvencijalan** proces:

1. prvi model se trenira na **svim** podacima
2. **primjeri koji su pogrešno klasificirani dobivaju veću težinu**
3. sljedeći model se **fokusira upravo na te greške**
4. proces se ponavlja dok se ne postigne željena točnost

AdaBoost (Adaptive Boosting)

- koristi **decision stumps** — stabla odluke sa **samo jednom razinom dijeljenja**
- **prilagodljivost** — svaki novi model dodaje se ansamblu s određenim „glasom" koji ovisi o njegovoj točnosti
- bio je **prvi algoritam koji je uspješno implementirao boosting princip na masovnim podacima**

Gradient Boosting (GBM)

- **ne mijenja težine primjera direktno**, već **trenira novi model na rezidualima (pogreškama) prethodnog modela**
- koristi **gradijentni spust** za minimizaciju funkcije gubitka

XGBoost (Extreme Gradient Boosting) — *de facto* standard za Kaggle natjecanja i industriju:

- **brzina** — paralelna obrada i optimizacija memorije
- **regularizacija** — ugrađena **L1/L2** zaštita od overfittinga
- **nedostajuće vrijednosti** — automatsko rukovanje nepoznatim vrijednostima

Stacking (Stacked Generalization)

Kombinira predviđanja **više baznih modela** (npr. SVM, KNN, RF) koristeći završni **meta-prediktor**:

- **raznolikost** — najbolje radi kada su bazni modeli **različitog tipa**

- **dvije razine** — Razina 1 (osnovni modeli), Razina 2 (meta-model)
- **složenost** — zahtijeva više resursa za treniranje

Usporedba glavnih metoda — tablica sa slajda

Značajka	Bagging (RF)	Boosting (XGB)	Stacking
Struktura	Paralelna	Sekvencijalna	Hijerarhijska
Glavni cilj	Smanjenje varijance	Smanjenje biasa	Sveukupna točnost
Osjetljivost na šum	Mala (robusna)	Veća	Srednja
Interpretacija	Teška	Vrlo teška	Nemoguća

Zašto (ne) koristiti ansamble

Prednosti: superiorna točnost u odnosu na pojedinačne modele · smanjena šansa za overfitting (kod Bagginga) · mogućnost rješavanja **kompleksnih nelinearnih odnosa**

Izazovi: „**Black box**“ modeli (teška interpretacija odluka) · veliki zahtjevi za memorijom i CPU-om · povećana složenost u produkcijskom okruženju

Provjeri se

1. Napiši formule za signifikantnost i pouzdanost. Objasni ih rečenicom.
2. Zašto $A \Rightarrow B$ i $B \Rightarrow A$ imaju istu signifikantnost a različitu pouzdanost?
3. Formuliraj apriori princip i njegovu kontrapoziciju. Zašto je kontrapozicija korisnija?
4. Provedi Apriori na $D = \{\{1,3,4\},\{2,3,5\},\{1,2,3,5\},\{2,5\}\}$ uz $\text{minSig} = 2$ do $L3$.
5. Iz $\{2,3,5\}$ generiraj sva pravila i primijeni $\text{minPouzdanost} = 75\%$.
6. Tri uzroka anomalija. Koji od njih nije koristan signal?
7. Razlika nadziranog, polu-nadziranog i nenadziranog pristupa detekciji anomalija?
8. Bias vs. variance: koji simptom ide s kojim?
9. Koji ansambl smanjuje varijancu, a koji bias? Objasni **zašto** iz njihove strukture.
10. Što su feature randomness i OOB error i zašto su bitni za Random Forest?
11. Po čemu se GBM razlikuje od AdaBoosta?

SINTEZA — cijeli kolegij u jednom toku

Priča u 10 rečenica

1. Organizacija ima **transakcijski sustav (OLTP)** koji zapisuje svakodnevno poslovanje, ali je optimiziran za pisanje, normaliziran i bez povijesti. (P1, P2)
2. Za odlučivanje treba **suprotan sustav**: subjektno orijentiran, integriran, postojan i vremenski različit — **skladište podataka**. (P3)
3. Skladište se ne modelira relacijski nego **dimenzijski**: u središtu je **tablica činjenica** s mjerama, oko nje **dimenzije** s kontekstom. (P3, P4)
4. Dizajn ide u **četiri koraka**: poslovni proces → granularnost → dimenzije → mjere. (P3)

- Model se zatim **poboljšava**: surogat ključevi, SCD tipovi, junk/mini/degenerirane dimenzije, modeli činjeničnih tablica. (P5)
- Podaci se u model prenose **ETL procesom** kroz **pripremno područje**, uz **CDC** za detekciju promjena i **testove kvalitete** za čišćenje. (P6)
- Nad napunjenim skladištem radi se **OLAP analiza** — slice, dice, drill-down, roll-up, pivot, drill across — ubrzana **agregacijama**. (P8)
- Ali OLAP zahtijeva **da čovjek zna što pitati** — odatle *data rich, information poor*; rješenje je **rudarenje podataka** kroz **KDD proces**. (P9)
- Rudarenje ima pet zadataka: **klasifikacija i regresija** (nadzirano, prediktivno) te **klasteriranje, asocijativna pravila i detekcija anomalija** (nenadzirano, deskriptivno). (P9–P12)
- Kvaliteta modela se mjeri **na testnom skupu**, a poboljšava **ansamblima** koji balansiraju **bias i varijancu**. (P11, P12)

Checkpointi projekta ↔ predavanja ↔ faze implementacije

CP	Zadatak	Predavanja	Faza implementacije DW (P8)
1	Odabir i analiza podataka	P1	1. Poslovni zahtjev
2	Relacijski model (ER → EER → DBMS → punjenje)	P2	2. Analiza operativnog sustava
3	Dimenzijski model (mjera, 5 dimenzija, hijerarhije, degenerirana dim., star/snowflake, napredne izvedbe)	P3, P4, P5	3. Dizajn DW-a
4	Punjenje iz ≥2 izvora , ETL, provjera da nema izgubljenih podataka	P6	4. ETL
5	OLAP alat, sve operacije na kocki, dashboard	P8	5. Korištenje / OLAP
(+)	Rudarenje nad skladištem	P9–P12	—

Parovi pojmova koji se najčešće brkaju

	vs.	Ključna razlika
OLTP	OLAP	puno malih transakcija i normalizacija ↔ velika količina podataka i denormalizacija
Top-down (Inmon)	Bottom-up (Kimball)	cijelo skladište pa data marts ↔ data marts pa skladište
Star	Snowflake	denormalizirane dimenzije ↔ normalizirane, granate dimenzije
Tablica činjenica	Dimenzijska tablica	kvantitativno, normalizirano, puno redaka ↔ kvalitativno, denormalizirano, malo redaka
SCD tip 2	SCD tip 3	novi redak , potpuna povijest ↔ novi stupac , ograničena povijest

	vs.	Ključna razlika
Mini dimenzija	Junk (kompozitna) dimenzija	logički povezani atributi ↔ logički nepovezani atributi niske kardinalnosti
Degenerirana dimenzija	Potporna dimenzija	atribut u tablici činjenica bez svoje tablice ↔ dimenzija spojena na drugu dimenziju (snowflake)
Schema grešaka	Revizorska dimenzija	zaseban dimenzijski model svih ETL grešaka ↔ dimenzija s metapodacima o kvaliteti uz svaki zapis t.č.
Slice	Dice	jedna dimenzija ograničena ↔ više dimenzija ograničeno
Roll-up	Drill-down	sažimanje, više u hijerarhiji ↔ detaljiziranje, niže u hijerarhiji
MOLAP	ROLAP	brz, ograničena količina podataka ↔ velike količine, slabije performanse
Klasifikacija	Regresija	diskretna izlazna varijabla ↔ kontinuirana
Klasifikacija	Klasteriranje	nadzirano, klase poznate ↔ nenadzirano, klase nepoznate
Signifikantnost	Pouzdanost	<i>koliko je pravilo važno u cijelom skupu ↔ kad je X ispunjen, koliko puta dođe i Y</i>
Bias	Variance	underfitting, obje greške visoke ↔ overfitting, trening niska / test visoka
Bagging	Boosting	paralelno, smanjuje varijancu ↔ sekvencijalno, smanjuje bias

POJMOVNIK HR ↔ EN

Hrvatski	English
skladište podataka	data warehouse
područno skladište podataka	data mart
pripremno područje	staging area
tablica činjenica	fact table
dimenzijska tablica	dimension table
surogat / tehnički ključ	surrogate key
granularnost	granularity
usklađene dimenzije	conformed dimensions
sporo mijenjajuće dimenzije	slowly changing dimensions (SCD)
degenerirane dimenzije	degenerate dimensions

Hrvatski	English
kompozitne dimenzije	junk dimensions
mini dimenzije	mini dimensions
heterogene dimenzije	heterogeneous dimensions
tablica činjenica bez činjenica	factless fact table
periodička snimka stanja	periodic snapshot
akumulirajuća snimka stanja	accumulating snapshot
unakrsni pregled	drill across
izdvajanje / transformacija / punjenje	extract / transform / load
detekcija promjena	Change Data Capture (CDC)
okidač	trigger
dnevnik transakcija	transaction log
testovi kvalitete	quality screens
shema grešaka	error event schema
revizorska dimenzija	audit dimension
kontrolna ploča	dashboard
rudarenje podataka	data mining
otkrivanje znanja u bazama	Knowledge Discovery in Databases (KDD)
predprocesiranje	preprocessing
nadzirano / nenadzirano učenje	supervised / unsupervised learning
učenje uz podršku	reinforcement learning
klasteriranje	clustering
stršeća vrijednost / anomalija	outlier / anomaly
asocijativna pravila	association rules
signifikantnost	support
pouzdanost	confidence
čest uzorak	frequent pattern
pretpostavka / zaključak	antecedent / consequent
skup atributa	itemset
funkcija gubitka	loss function
suma kvadrata reziduala	residual sum of squares (RSS)

Hrvatski	English
metoda najmanjih kvadrata	ordinary least squares (OLS)
pristranost / varijanca	bias / variance
ansambl učenje	ensemble learning
uzorkovanje s ponavljanjem	bootstrap
stablo odluke sa jednom razinom	decision stump
smanjenje dimenzionalnosti	dimensionality reduction
procjena gustoće	density estimation

BANKA ISPITNIH PITANJA

A. Definicije koje se traže doslovno

1. Definiraj skladište podataka prema **Inmonu** i objasni sva četiri svojstva.
2. Definiraj **rudarenje podataka** prema Berryju i Linoffu.
3. Definiraj **klasifikaciju**.
4. Definiraj **klasteriranje** (i navedi tri definicije klastera).
5. Što je **CDC**?
6. Što je **ansambl učenje**?
7. Što je **anomalija**?
8. Objasni akronim **FASMI** i navedi zahtjev za svako slovo.

B. Nabranja

9. Tri razine analitike i alati za svaku.
10. Četiri koraka dizajna skladišta podataka.
11. Pet faza implementacije DW-a.
12. Pet koraka KDD procesa.
13. Pet zadataka rudarenja podataka + tip svake.
14. Pet CDC tehnika.
15. Šest OLAP operacija.
16. SCD tipovi 1–4 + dva hibridna.
17. Tri modela činjeničnih tablica.
18. Tri vrste testova kvalitete u ETL-u.
19. Tri kategorije metapodataka.
20. Četiri zadatka nenadziranog učenja.
21. Šest komponenti učenja.
22. Tri kategorije ansambl metoda.

C. Usporedbe (tablična pitanja)

23. Top-down vs. bottom-up po pet kriterija.

24. OLTP vs. OLAP.
25. Star shema vs. OLAP kocka.
26. Usporedba pet CDC tehnika po pet kriterija.
27. MOLAP vs. ROLAP vs. HOLAP.
28. Bagging vs. Boosting vs. Stacking.
29. Nadzirano vs. nenadzirano učenje (uključujući zašto kod nenadziranog nema jasne mjere kvalitete).
30. Particijsko vs. hijerarhijsko klasteriranje.
31. Bias vs. variance.

D. Računski zadaci

32. Zadan niz brojeva → izračunaj mean, median, mod, raspon, std, CV, kvartile; objasni koja mjera najbolje opisuje podatke.
33. Zadano y i X → izračunaj $\beta = (X^T X)^{-1} X^T y$ i napiši jednadžbu pravca.
34. Zadan skup transakcija i minSig → provedi Apriori do L3.
35. Zadan čest uzorak i minPouzdanost → generiraj i filtriraj sva pravila.
36. Zadana tablica s greškama → identificiraj sve tipove problema kvalitete podataka.
37. Zadan dimenzijski zapis koji se mijenja → prikaži rezultat za SCD tip 1, 2 i 3.

E. Primjena / esejska pitanja

38. Zadan poslovni opis → odredi entitete, attribute, veze, kardinalnost; nacrtaj ER.
39. Zadan poslovni opis → odredi poslovni proces, granularnost, 5 dimenzija, 2 mjere, nacrtaj star shemu.
40. Zadan proces → koji SCD tip bi primijenio na koju dimenziju i zašto.
41. Zadan izvorišni sustav (npr. legacy baza bez okidača) → koju CDC tehniku i zašto.
42. Zadan poslovni problem → koja zadaća rudarenja, koja izlazna varijabla, koji izvor podataka.
43. Zašto je moguće naučiti nešto o ciljnoj funkciji koja nam je nepoznata?
44. Objasni zašto je *data rich, information poor* problem koji OLAP ne rješava.
45. Zašto je model s greškom 0 na treningu sumnjiv?

TIPIČNE ZAMKE

- „**Dimenzije su normalizirane**” — ne. Dimenzije su **denormalizirane**; **tablica činjenica** je (gotovo) normalizirana. Snowflake je iznimka.
- „**Postojan znači da se podaci nikad ne mijenjaju**” — preciznije: **ne mijenjaju se, samo se dodaju novi**. Zato SCD tip 1 (prepisivanje) zapravo krši duh skladišta i koristi se samo kad povijest nema značaja.
- „**Roll-up = brisanje dimenzije**” — roll-up je **ili** kretanje prema višim razinama hijerarhije **ili** redukcija dimenzija. Oboje.
- „**Drill-down je samo spuštanje niz hijerarhiju**” — uključuje i **dodavanje novih dimenzija**.
- **Kardinalnost SCD-a**: tip 3 **ne** čuva neograničenu povijest, samo prethodnu vrijednost (ili nekoliko, kod hibridnog tipa 1).
- „**Agregacije nastaju pri upitu**” — ne, nastaju **pri ETL-u / punjenju**, i troše prostor i CPU **unaprijed**.
- „**Pouzdanost = signifikantnost pravila**” — različite mjere s različitim nazivnikom; pravilo može imati 100 % pouzdanosti a biti beznačajno (npr. 2 od 10 000 transakcija).

- **Apriori princip se koristi u kontrapoziciji:** ne "svaki podskup čestog je čest", nego "**nijedan nadskup nečestog nije čest**" — to je ono što reže pretragu.
- „**Bagging smanjuje bias**” — ne. **Bagging** → **varijanca**. **Boosting** → **bias**.
- „**Random Forest je boosting**” — ne, Random Forest je **bagging** metoda.
- „**Klasteriranje ima izlaznu varijablu**” — nema. To je bit nenadziranog učenja i razlog zašto nema objektivne mjere kvalitete.
- **Regresija vs. klasifikacija** — razlika **nije** u algoritmu nego u **tipu izlazne varijable** (logistička regresija je klasifikacija!).
- **MSE se računa na testnom skupu.** Na trening skupu je beskoristan kao mjera generalizacije.
- **Junk ≠ mini dimenzija.** Junk = nepovezani atributi; mini = povezani.
- **Faze implementacije DW-a nisu ETL faze.** Implementacija ima 5 faza (poslovni zahtjev → analiza → dizajn → ETL → korištenje), ETL ima 3 koraka.

Skripta pokriva P1–P6 i P8–P12. Za literaturu vidi zadnje slajdove svakog predavanja: [SDT], [KR] (Kimball & Ross), Kimball et al. „The data warehouse lifecycle toolkit” (pogl. 9–10), Han/Pei/Kamber „Data mining: concepts and techniques” (pogl. 1, 6, 10, 12), Abu-Mostafa „Learning from Data”, kimballgroup.com.

ODGOVORI

Prvo odgovori sam, pa provjeri. Ako se odgovor razlikuje samo u formulaciji — u redu je; ako se razlikuje u broju stavki ili u smjeru tvrdnje — vrati se na poglavlje.

Odgovori — P1

1. Tri razlike OPS vs. DSS OPS podržava svakodnevno poslovanje, DSS strateško odlučivanje. OPS najčešće nema povijesne podatke (ažurira na trenutno stanje), DSS ih sadrži i puni se periodički. OPS je optimiziran za brzu obradu jedne transakcije u trenutku, DSS za efikasno dohvaćanje tisuća zapisa u jednom upitu.

2. Zašto je BI podskup BA BI pokriva deskriptivnu razinu — što se dogodilo i što se događa (izvještavanje, skladišta, dashboardi). BA dodatno obuhvaća prediktivnu i preskriptivnu razinu (rudarenje podataka, forecasting, optimizacija, simulacija). BA je dakle širi pojam, pa je BI njegov podskup — iako se termini često koriste kao sinonimi.

3. Intervalna vs. omjerna skala Obje imaju jednake razmake između mjerenja. Intervalna **nema apsolutnu nulu** (npr. temperatura u °C, kalendarska godina) — 20 °C nije "dvostruko toplije" od 10 °C. Omjerna ima apsolutnu nulu (npr. prihod, količina, trajanje) pa dopušta **sve aritmetičke operacije**, uključujući omjere.

4. Kada je medijan bolji od sredine Kada u podacima postoje stršće vrijednosti ili je distribucija asimetrična. Primjer iz predavanja: kod niza s vrijednošću 411 557 srednja vrijednost je 37 880, a nijedan stvarni podatak nije blizu te vrijednosti; medijan je 10 i vjerno opisuje tipičan slučaj. Medijan je **otporan na ekstreme** jer ovisi o poziciji, ne o iznosu.

5. Koeficijent varijacije Omjer standardne devijacije i srednje vrijednosti (obično $\times 100\%$). Mjeri **relativnu** raspršenost, pa je bez mjerne jedinice — zato se njime mogu uspoređivati varijable različitih jedinica ili različitih redova veličine (npr. prihod u eurima i trajanje u sekundama). CV od 327 % iz primjera znači da je raspršenost tri puta veća od same sredine.

6. Isti podaci, suprotan dojam Odsjecanjem y-osi (npr. raspon 11 390–11 640 umjesto 0–12 000) minimalne razlike izgledaju dramatično; promjenom skale ili orijentacije mijenja se dojam o odnosu kategorija. Grafikon koji tehnički ne laže i dalje može obmanuti — stupčasti grafikon čija y-os ne kreće od nule klasična je manipulacija.

Odgovori — P2

1. Tri faze dizajna baze i rezultati Konceptualni → **ER model / ER dijagram** (neovisan o DBMS-u). Logički → **relacijski model / EER dijagram** (tipovi podataka, primarni i strani ključevi, normalizacija). Fizički → **implementacija** (indeksi, pohrana, integritet, kontrola pristupa).

2. Prepoznavanje elemenata u tekstu Entiteti su objekti, u pravilu **imenice**. Atributi su obilježja entiteta, također **imenice**. Veze su najčešće opisane **glagolima**.

3. Entitet ili atribut Dvije smjernice: (a) entiteti **sadrže** attribute, a atributi se **ne sastoje od manjih dijelova**; (b) entiteti **mogu imati veze** između sebe, a atributi **pripadaju** entitetima.

4. Što EER dodaje na ER Prikazuje dodatne detalje: **tipove podataka** atributa i **primarne/strane ključeve**, te preciznije vrste veza (1:N, N:1, N:N) s ograničenjima. Daje detaljniji pogled na strukturu nego što je uobičajeno u konceptualnoj fazi.

5. Datotečni izvori i skladišta Datoteke su **jedan od čestih izvora za skladišta podataka**. Zato je u projektu skup podataka namjerno podijeljen na relacijsku bazu + CSV — da se simulira dohvat podataka u skladište **iz više izvora**, što je zahtjev Checkpointa 4.

Odgovori — P3

1. Inmonova definicija „Skladište podataka jest **subjektno orijentiran, integriran, postojan i vremenski različit** skup podataka koji služi kao potpora odlučivanju.”

- *subjektno orijentiran* — podaci su organizirani po poslovnim temama, ne po aplikacijama
- *integriran* — podaci dolaze iz različitih izvora i međusobno se usklađuju
- *postojan* — podaci se u skladištu ne mijenjaju, samo se dodaju novi
- *vremenski različit* — postoji vremenska dimenzija koja omogućuje pregled podataka u vremenskom kontekstu

2. Postojanost i ETL Postojanost znači da ETL u pravilu **dodaje**, a ne prepisuje. Zato se povijest promjena u dimenzijama rješava mehanizmima SCD-a (osobito tip 2 — novi redak), a ne **UPDATE**-om. Tip 1 je iznimka koja se koristi samo kad povijest tog atributa nema analitičkog značaja.

3. Top-down vs. bottom-up

Kriterij	Top-down (Inmon)	Bottom-up (Kimball)
Izrada	vremenski iscrpna	vremenski kraća
Održavanje	lagano	teško
Trošak	visoki inicijalni	niski inicijalni
Vrijeme do početka	duže	kraće
Integracija	ukupna organizacija	pojedini dijelovi

4. Četiri koraka dizajna

1. odabrati poslovni proces → 2) odabrati granularnost tablice činjenica → 3) definirati dimenzije → 4) definirati mjere (činjenice).

5. Primjer: bolnica želi smanjiti vrijeme čekanja

- **Poslovni proces:** obrada pacijenta / posjet ambulantni
- **Granularnost:** jedan posjet pacijenta (najniža razina)
- **Dimenzije:** vrijeme, odjel/ambulantna, liječnik, pacijent (dobna skupina), tip zahvata, način dolaska (hitno/naručeno)
- **Mjere:** vrijeme čekanja u minutama, trajanje pregleda (*Napomena: dimenzija „dobna skupina“ je primjer transformacije kvantitativne vrijednosti grupiranjem, vidi P4.*)

Odgovori — P4

1. Zašto t.č. normalizirana, dimenzije nisu Tablica činjenica ima **velik broj zapisa**, pa bi svako ponavljanje teksta bilo skupo — zato sadrži samo mjere i strane ključeve i vrlo je slična tablici transakcijskog sustava. Dimenzijske tablice su **male** i denormaliziraju se namjerno: time se izbjegavaju JOIN-ovi na analitičkim upitima i model postaje **čitljiv poslovnim korisniku**. Cijena je redundancija, koja je ovdje prihvatljiva.

2. Star shema i OLAP kocka Imaju **isti logički dizajn, ali različitu fizičku implementaciju** — star u relacijskoj bazi (RDB), kocka u multidimenzijskoj (MDB). Dobra praksa je stvoriti star shemu **čak i kada** se podaci pohranjuju u kocke, pa kocke izvesti iz nje.

3. Hijerarhija i redundancija Hijerarhija je niz atributa različitih razina detalja unutar iste dimenzije (npr. Trgovina → Grad → Županija → Država). Kako više trgovina dijeli isti grad i županiju, ti se podaci **ponavljaju u svakom retku** dimenzije. Normalizacija te redundancije daje **snowflake** shemu — ali obično se ne radi, jer je prostor jeftin, a čitljivost i brzina važnije.

4. Kandidat za tablicu činjenica u ER dijagramu Asocijativni entiteti — oni nastaju iz M:M ili ternarnih veza, imaju vlastiti id i dodatne opisne attribute. Već sadrže veze prema više entiteta (koji postaju dimenzije) i vlastite mjerljive attribute (koji postaju mjere).

5. Najniža granularnost i njezina cijena Preporučuje se jer se iz detaljnih podataka **uvijek može agregirati naviše**, dok se obrnuto ne može — jednom sažeti podaci su izgubljeni za detaljnu analizu. Cijena je **veličina tablice činjenica** i sporiji upiti, što se kompenzira **agregacijama** (P8).

Odgovori — P5

1. Četiri pravila za surogat ključeve Uvode se u **sve** tablice dimenzijskog modela, kao cijeli brojevi (sekvence). Originalni produkcijski ključevi se **zadržavaju** kao veza na izvorne podatke. Ne smiju biti „pametni“ niti **kompozitni**. Ne smiju biti **povezani s produkcijskim ključevima**. Koriste se za vezu dimenzija prema tablici činjenica.

2. SCD tip 2 vs. tip 3 na istom primjeru Promjena procesora s i5 na i7:

- **Tip 2** — novi **redak** s novim surogat ključem; stari redak ostaje (uz **Datum do** ili **Aktivan = N**). Čuva se **potpuna** povijest, dimenzija raste.
- **Tip 3** — isti redak, dodaje se **stupac** **Stari procesor tip = i5**, a **Procesor tip** postaje i7. Čuva se **samo prethodna** vrijednost; sljedeća promjena briše i5.

3. Kada tip 4 umjesto tipa 2 Kada postoji **jasna potreba za odvojenom analizom trenutnih i povijesnih podataka**, a upiti nad trenutnim stanjem moraju biti brzi. Tip 4 drži trenutne podatke u maloj glavnoj tablici, a povijest u zasebnoj tablici — po cijenu dodatnog prostora i **složenijeg ETL-a**.

4. Degenerirana dimenzija Atribut **unutar same tablice činjenica** koji ima svojstva dimenzijskog ključa, ali **nema odgovarajuću dimenzijsku tablicu** (npr. broj računa, broj narudžbe). Nema svoju tablicu jer bi ta tablica sadržavala samo ključ i ništa više — nema opisnih atributa. Koristan je za **grupiranje zapisa**.

5. Mini vs. junk dimenzija **Mini** dimenzija odvaja **logički povezane** attribute iz velike dimenzije (npr. sva demografija kupca) da ubrza pretraživanje. **Junk (kompozitna)** dimenzija skuplja **logički nepovezane** attribute **niske kardinalnosti** (Da/Ne oznake, indikatori, statusi) iz tablice činjenica u jednu dimenziju. Razlika je upravo u (ne)povezanosti atributa.

6. Factless fact table Tablica činjenica **bez mjere** (vrijednost 1 ili 0/1) koja bilježi **postojanje događaja**. Nezamjenjiva je za analizu **onoga što se nije dogodilo** — npr. koji promovirani proizvodi nisu prodani, koji student nije došao na predavanje. Takvo pitanje se ne može postaviti nad običnom tablicom činjenica jer nepostojeći događaj nema zapisa s mjerom.

7. Zašto kasno dolazeće činjenice trebaju tip 2 Kasna činjenica se odnosi na **prošli trenutak**. Da bi se ispravno povezala, treba pronaći zapise u svim dimenzijama **koji su vrijedili u trenutku stvaranja transakcije**. Samo tip 2 čuva te povijesne verzije zapisa (s **Datum od/Datum do**); kod tipa 1 stara verzija više ne postoji, pa bi se činjenica pogrešno povezala s današnjim stanjem dimenzije.

8. Tablica pravovremenosti

	Rano	Kasno
Dimenzije	U redu	Problem
Činjenice	Problem	Problem

Jedini bezbolan slučaj je rano dolazeća dimenzija — jer je ionako ispravan redoslijed punjenja „prvo dimenzije, pa činjenice“.

Odgovori — P6

1. Tri faze ETL-a i izazovi

- **Izdvajanje** — detektiranje promjena, više izvora podataka, ne ugroziti produkcijski sustav
- **Transformacija i čišćenje** — način transformacije i čišćenja, mogućnost različitosti podataka
- **Punjenje** — način učitavanja (odjednom vs. zapis po zapis), koje zapise dodati/izmijeniti/brisati

2. Pripremno područje Postoji da se izvorni podaci transformiraju i čiste **izvan** produkcijskog sustava i **izvan** skladišta — u biti je kopija transakcijskog sustava u kojoj se tablice mogu dodavati i brisati bez pravila.

Korisnici nemaju pristup, a upiti ne mogu pristupiti podacima u njemu. Iz njega se puni skladište.

3. Pet CDC tehnika i po jedan nedostatak

Tehnika	Nedostatak
dodavanje vremenske oznake	bilježi samo zadnju izmjenu, ne vidi obrisane zapise ; srednji utjecaj na izvorišnu bazu
razlika snimki stanja	zahtijeva dosta resursa i vremena ; nema evidencije povijesti
aplikacijsko bilježenje promjena	visok utjecaj na aplikacije , visoka složenost implementacije
okidači baze podataka	visok utjecaj na izvorišnu bazu , opterećenje; treba ih vrlo oprezno koristiti
dnevnik transakcija	zahtijeva razvoj posebnog algoritma i sinkronizaciju s ETL-om

4. Tehnika koja ne bilježi brisanja **Dodavanje vremenske oznake.** Brisani zapis jednostavno nestaje iz izvora — nema retka čiju bi vremensku oznaku ETL mogao usporediti, pa promjena ostaje nezamijećena.

5. Tehnika bez evidencije povijesti **Razlika snimki stanja.** Ona vidi samo razliku između dvije snimke; sve međupromjene koje su se dogodile i poništile unutar razdoblja su nevidljive.

6. Shema grešaka **Dimenzijski model čiji je cilj evidentiranje svih grešaka koje su se dogodile u ETL procesu.** Tablica činjenica je **događaj greške**, granularnost je **svaka pojedina greška u ETL-u**. Dimenzije su vremenska, obrada u kojoj se greška dogodila, test kvalitete i sl.

7. Shema grešaka vs. revizorska dimenzija Shema grešaka je **zaseban dimenzijski model** koji bilježi sve aktivirane testove kvalitete. Revizorska dimenzija je **dimenzija pridružena postojećoj tablici činjenica**, s metapodacima o ETL procesiranju i kvaliteti, i pridjeljuje se **svakom zapisu** t.č. Prva odgovara „koje su se greške dogodile“, druga „kolika je kvaliteta ovog konkretnog zapisa“.

8. Zašto dimenzije prije tablice činjenica Jer se u izgradnji dimenzija **generiraju surogat ključevi**, a tablica činjenica se zatim **povezuje s dimenzijama** preko tih ključeva. Bez postojećih dimenzijskih zapisa nema ključeva na koje bi se t.č. referencirala — to je i razlog zašto su „rano dolazeće činjenice“ (P5) problem.

Odgovori — P8

1. Pet faza implementacije DW-a i checkpointi

1. Poslovni zahtjev = CP1, 2) Analiza operativnog sustava = CP2, 3) Dizajn DW-a = CP3, 4) ETL = CP4, 5) Korištenje / OLAP = CP5.

2. Slice vs. dice **Slice** ograničava **jednu** dimenziju na neki raspon vrijednosti (rez kroz kocku). **Dice** ograničava **više** dimenzija istovremeno, pa je rezultat **manja kocka**.

3. Roll-up i redukcija dimenzija To su **dva oblika iste operacije**. Roll-up je sažimanje podataka — **ili** kretanjem prema višim razinama hijerarhije (dan → mjesec → godina), **ili** redukcijom dimenzija (izbacivanjem dimenzije iz pogleda). Oba smanjuju razinu detalja.

4. FASMI Fast — većina upita **unutar 5 sekundi**, rijetki do 20. **Analysis** — poslovna logika i statistička analiza, **ad-hoc upiti bez programiranja**. **Shared** — sigurnosni zahtjevi. **Multidimensional** — multidimenzionalni konceptualni pogled, podrška dimenzijama i hijerarhijama. **Information** — obrada velikih količina podataka.

5. Agregacije — kada i gdje Nastaju **prilikom ETL procesa, točnije punjenja**, i pohranjuju se u **posebnu tablicu namijenjenu isključivo za to**. Procesorsko vrijeme i disk troše se **unaprijed**, da bi upiti kasnije bili brzi. Osvežavanje kocke i agregatne tablice zove se **procesiranje kocke**.

6. Izvedena dimenzija Dimenzija koja nastaje **iz više razine hijerarhije postojeće dimenzije** pri izradi agregirane tablice činjenica — npr. iz dimenzije Proizvod (Proizvod → Tip proizvoda → Linija) izvede se dimenzija **Tip proizvoda** koja se koristi u agregatu.

7. MOLAP vs. ROLAP

	MOLAP	ROLAP
+	dobre performanse (brzina upita); kompleksne kalkulacije	velike količine podataka; funkcionalnosti relacijske baze
—	limitirana količina podataka; tehnologija često nije u organizaciji, može biti skupa	slabije performanse upita; ograničenje na SQL

8. Zašto drill across treba usklađene dimenzije Drill across kombinira podatke **iz više tablica činjenica** u jedinstven rezultat. Da bi se rezultati mogli spojiti i uspoređivati, dimenzije po kojima se spaja moraju biti **identično definirane u oba modela** — to su upravo usklađene (conformed) dimenzije. Bez toga bi se npr. „proizvod“ u dva modela odnosio na različite skupove vrijednosti. Tablice činjenica pritom smiju biti različite granularnosti.

Odgovori — P9

1. Pet ograničenja skladišta Velike količine podataka u odnosu na mogućnosti OLAP alata · *data rich, information poor* situacija · analiza je ovisna o poslovnom korisniku, a odluka se često donosi na temelju intuicije · potrebno je ekspertno znanje · potreba za alatima koji **sami** pronalaze znanje u podacima.

2. Data rich, information poor Situacija u kojoj organizacija ima ogromne količine prikupljenih podataka, ali iz njih ne izvlači korisnu informaciju — jer OLAP zahtijeva da **čovjek unaprijed zna što pitati**. Obrasci koje nitko nije pretpostavio ostaju neotkriveni.

3. Pet koraka KDD-a Odabir podataka → predprocesiranje → transformacija → **rudarenje podataka** → evaluacija. Rudarenje podataka je **četvrti korak**, dakle dio KDD procesa (prema drugom gledištu ta se dva pojma izjednačavaju).

4. Poveži Nadzirano učenje $\approx$ prediktivni modeli (klasifikacija, regresija — poznata izlazna varijabla, cilj je predviđanje budućih događaja). **Nenadzirano učenje $\approx$ deskriptivni modeli** (klasteriranje, asocijativna pravila, detekcija anomalija — nema izlazne varijable, cilj je razumijevanje odnosa među atributima).

5. Tip izlazne varijable po zadaći

Zadaća	Izlazna varijabla
Klasifikacija	kategorička, mali broj diskretnih vrijednosti
Regresija	kontinuirana
Klasteriranje	nema — broj i značenje klastera nisu poznati unaprijed
Asocijativna pravila	nema — rezultat su pravila oblika $X \Rightarrow Y$
Detekcija anomalija	nema (nenadzirano); rezultat je da/ne ili score

6. Primjer (helpdesk / podrška)

- **Zadaća:** klasifikacija · **Izlazna varijabla:** hoće li ticket prekoračiti SLA (da/ne) · **Izvor:** povijesni tiketi iz skladišta, s dimenzijama projekt, prioritet, status i mjerom vremena rješavanja
- Alternativno: **regresija** · izlazna varijabla = vrijeme rješavanja u satima · isti izvor.


Odgovori — P10

1. Tri uvjeta za strojno učenje (a) **postoji uzorak u podacima**, (b) **ne može se matematički odrediti formula**, (c) **postoje podaci**. Ako ne vrijedi (a) — model uči šum. Ako ne vrijedi (b) — napiši formulu, ne treniraj model. Ako ne vrijedi (c) — nema učenja.

2. f, h i H $f : X \rightarrow Y$ je **ciljna funkcija** — savršeno pravilo koje preslikava ulaz u izlaz; ona je **nepoznata**. **H** je **skup (prostor) hipoteza** — sve moguće funkcije odabranog tipa. **$h : X \rightarrow Y$** je konkretna **hipoteza** koju je algoritam odabrao iz H . Nepoznatost f nije problem jer h aproksimira f na podacima, a **validacija** provjerava koliko dobro ta aproksimacija generalizira na neviđene primjere.

3. Zašto greška 0 na treningu nije dobra vijest Jer model može biti naučio **šum** umjesto obrasca (overfitting). Slajd „Odabir hipoteze — validacija” pokazuje četiri hipoteze sa sličnom trening-točnošću koje **ne generaliziraju jednako**. Kvaliteta se mjeri na podacima koji nisu korišteni u treningu.

4. Dijagram komponenti učenja



Komponente: x (ulaz), y (izlaz), f (ciljna funkcija), podaci $(x_1, y_1) \dots (x_n, y_n)$, h (hipoteza), H (prostor hipoteza).

5. Klasično programiranje vs. strojno učenje Klasično: ulaz = **podaci + program**, izlaz = **rezultat**. Strojno učenje: ulaz = **podaci + rezultat**, izlaz = **program**. U prvom slučaju čovjek piše pravila, u drugom ih računalo izvodi iz podataka.

6. Zašto rekalkibracija Jer se sustav koji modeliramo **dinamički mijenja** — obrazac naučen na starim podacima s vremenom prestaje vrijediti. Nakon određenog vremena model treba ponovno trenirati na novijim podacima.

Odgovori — P11

1. Klasifikacija vs. regresija Razlika je isključivo u **tipu vrijednosti koje može poprimiti izlazna varijabla**: klasifikacija — diskretne (konačan skup klasa), regresija — kontinuirane. Oba su nadzirano učenje.

2. Izračun β $X^T X = \begin{bmatrix} 5 & 15 \\ 15 & 55 \end{bmatrix}$, $\det = 275 - 225 = 50$, $(X^T X)^{-1} = \begin{bmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{bmatrix}$, $X^T y = [1000, 3650]^T$. $\beta = [1.1 \cdot 1000 - 0.3 \cdot 3650, -0.3 \cdot 1000 + 0.1 \cdot 3650] = [1100 - 1095, -300 + 365] = [5, 65] \rightarrow \hat{y} = 5 + 65x$.

3. RSS, OLS, rezidual **Rezidual** je odstupanje stvarne vrijednosti od predviđene ($y_i - \hat{y}_i$). **RSS** (*Residual Sum of Squares*) je **funkcija gubitka** — suma kvadrata reziduala. **OLS** (*Ordinary Least Squares*) je **optimizacijski postupak** koji bira koeficijente β tako da RSS bude minimalan. Rezidual je jedinica, RSS je mjera, OLS je postupak.

4. Interpretacija beta koeficijenta Ako se ta x varijabla promijeni za **jednu jedinicu**, uz **sve ostale nezavisne varijable nepromijenjene**, y će se promijeniti za vrijednost beta. Veličina koeficijenta **aproximira relativnu važnost** varijable. β_0 (intercept) je vrijednost y kada je $x = 0$.

5. Zašto MSE na testnom skupu Trening skup je model već „vidio“ i prilagodio mu se, pa greška na njemu mjeri **pamćenje**, ne sposobnost predviđanja. Testni skup sadrži **primjere koji nisu korišteni u treningu**, pa jedino on mjeri **generalizaciju**.

6. Tri definicije klastera (1) Podskup objekata koji su „slični“. (2) Podskup u kojem je udaljenost između bilo koja dva objekta **unutar** klastera manja nego udaljenost između bilo kojeg objekta izvan i onog unutar klastera. (3) Spojene regije multidimenzijskog prostora s relativno **visokom koncentracijom točaka**, odvojene od drugih takvih regija prostorom **niske** koncentracije.

7. Intra- i inter-cluster sličnost Dobra metoda daje klastere kod kojih je **sličnost unutar klase (intra-cluster) visoka**, a **sličnost izvan klase (inter-cluster) niska** — objekti u istoj grupi međusobno slični, objekti iz različitih grupa međusobno različiti.

8. Particijsko vs. hijerarhijsko

	Particijsko	Hijerarhijsko
Grupe	međusobno nepovezane	postoji povezanost i hijerarhija
Složenost	linearna	kvadratna ili veća
Preduvjet	treba zadati broj grupa	rezultat je stablo; treba uvjet prekida

9. k-means i slabosti

1. Odaberi k centara slučajno. 2) Dodijeli svaki element najbližem centru (Euklidova udaljenost). 3) Pomakni centar prema srednjoj vrijednosti dodijeljenih primjera. 4) Ponovi 2 i 3 dok se ne zadovolji uvjet prestanka (centar se ne miče, niti jedan primjer ne mijenja klaster). Slabosti: rezultat **ovisi o početnom slučajnom odabiru centara, i k se mora zadati unaprijed** iako pravi broj grupa obično nije poznat.

10. Zašto je evaluacija nenadziranog teža Jer **ne postoji izlazna varijabla** s kojom bi se rezultat usporedio — nema točnosti, preciznosti ni odziva. Kvaliteta ovisi o **odabranoj mjeri sličnosti i načinu njezine implementacije**, a **objektivna evaluacija je problem: vrlo često je radi čovjek/ekspert područja.**

Odgovori — P12

1. Formule $\text{sig}(A \Rightarrow B) = p(A \cup B)$ — „Koliko je ovo pravilo uopće važno u cijelom skupu?“ $\text{pouzdanost}(A \Rightarrow B) = p(B|A) = \text{sig}(A,B) / \text{sig}(A)$ — „Kad je pretpostavka ispunjena, koliko puta je došao i zaključak?“

2. Zašto ista signifikantnost, različita pouzdanost Signifikantnost oba pravila je $p(A \cup B)$ — **isti brojnik, isti skup transakcija**, pa je simetrična. Pouzdanost dijeli tim brojnikom **različite nazivnike**: $\text{sig}(A)$ za $A \Rightarrow B$, a $\text{sig}(B)$ za $B \Rightarrow A$. Iz primjera: $\text{sig}(A,C) = 2$; $A \Rightarrow C$ daje $2/3 = 66\%$, $C \Rightarrow A$ daje $2/2 = 100\%$.

3. Apriori princip i kontrapozicija Princip: **svaki podskup čestog skupa atributa je čest**. Kontrapozicija: **nijedan nadskup nečestog skupa nije čest**, pa ga ne treba generirati ni provjeravati. Kontrapozicija je korisnija jer je **operativna** — omogućuje **rezanje cijelih grana** prostora pretrage odmah nakon što se skup proglaši nečestim, umjesto provjere svih kombinacija.

4. Apriori do L3 (minSig = 2)

- **C1:** {1}:2, {2}:3, {3}:3, {4}:1, {5}:3 → **L1 = {1},{2},{3},{5}** ({4} otpada)
- **C2:** {1,2}:1, {1,3}:2, {1,5}:1, {2,3}:2, {2,5}:3, {3,5}:2 → **L2 = {1,3},{2,3},{2,5},{3,5}**
- **C3:** jedini kandidat je **{2,3,5}** (svi 2-podskupovi su u L2); $\text{sig} = 2 \rightarrow \mathbf{L3 = \{2,3,5\}}$ Skupovi tipa {1,3,x} otpadaju jer bi {1,2} ili {1,5} morali biti u L2, a nisu.

5. Pravila iz {2,3,5}, minPouzdanost 75 %

Pravilo	Račun	Pouzdanost	
$2 \Rightarrow 3,5$	$2/3$	66 %	X
$2,3 \Rightarrow 5$	$2/2$	100 %	✓
$2,5 \Rightarrow 3$	$2/3$	66 %	X
$3 \Rightarrow 2,5$	$2/3$	66 %	X
$3,5 \Rightarrow 2$	$2/2$	100 %	✓
$5 \Rightarrow 2,3$	$2/3$	66 %	X

6. Tri uzroka anomalija Elementi drugih klasa (ne-balansirani skupovi) · priroda varijacija u podacima (udaljenost od centra distribucije) · **greška u prikupljanju podataka**. Treći **nije koristan signal** — to je šum koji treba očistiti u predprocesiranju; prva dva nose informaciju.

7. Pristupi detekciji anomalija Nadzirano — oznake klase dostupne i za redovne primjere i za anomalije. **Polu-nadzirano** — oznake dostupne **samo za redovne primjere**. **Nenadzirano** — neoznačeni podaci; temelji se na pretpostavci da su anomalije **vrlo rijetka pojava**.

8. Bias vs. variance — simptomi Bias / underfitting → **visoka trening i visoka test greška**; model prejednostavan (ravna crta na zakrivljenim podacima). **Variance / overfitting** → **vrlo mala trening greška, vrlo velika test greška**; model radi besprijeckorno na viđenim podacima, ne generalizira.

9. Koji ansambl što smanjuje i zašto Bagging → **varijancu**. Modeli se treniraju **paralelno i neovisno** na različitim bootstrap uzorcima; njihove pojedinačne, međusobno nekorelirane pogreške se pri agregaciji (glasovanje/prosjek) **poništavaju**, čime pada osjetljivost na šum. **Boosting** → **bias**. Proces je **sekvencijalan** — svaki novi model se fokusira na primjere koje je prethodnik pogriješio, pa ansambl postupno **povećava izražajnost** i ispravlja sustavno podbacivanje.

10. Feature randomness i OOB error Feature randomness — pri svakom dijeljenju čvora bira se samo **slučajan podskup atributa**; to **smanjuje korelaciju između stabala**, a nekorelirana stabla su preduvjet da agregacija uopće smanji varijancu (uvjet raznolikosti iz „mudrosti gomile“). **OOB error** — podaci koji **nisu ušli u bootstrap uzorak** za dano stablo služe kao **interna validacija** točnosti, bez potrebe za odvojenim testnim skupom.

11. GBM vs. AdaBoost AdaBoost mijenja **težine primjera** — pogrešno klasificirani dobivaju veću težinu, a svaki model ulazi u ansambl s „glasom“ ovisnim o njegovoj točnosti; koristi *decision stumps*. **GBM ne mijenja težine direktno**, nego **trenira novi model na rezidualima (pogreškama) prethodnog**, koristeći **gradijentni spust** za minimizaciju funkcije gubitka.

ODGOVORI — banka ispitnih pitanja (A–E)

A. Definicije

1. Vidi Odgovori — P3, pitanje 1. 2. „Rudarenje podataka je **istraživanje i analiza velikih količina podataka u nastojanju otkrivanja smislenih obrazaca i pravila**.” (Berry i Linoff, 2004.) **3.** „Klasifikacija predstavlja **problem identifikacije kojoj klasi (kategoriji) nova opservacija pripada, na temelju trening skupa podataka koji sadrži opservacije čije su klase unaprijed poznate**.” Primjer nadziranog učenja. **4.** „Klasteriranje je **proces grupiranja fizičkih ili apstraktnih objekata u klase sličnih objekata**.” Tri definicije klastera — vidi *Odgovori — P11, pitanje 6. 5. Change Data Capture* — sposobnost **detektiranja promijenjenih podataka u izvorišnom sustavu i njihovog prikupljanja**, ključna za inkrementalnu nadopunu u ETL-u. **6. Proces kombiniranja više modela strojnog učenja („slabih prediktora“)** **kako bi se dobio jedan jači, precizniji model** — s ciljem smanjenja pogrešaka, bolje robusnosti i generalizacije. **7. Podaci čije su karakteristike značajno različite od ostatka skupa podataka. 8. Vidi Odgovori — P8, pitanje 4.**

B. Nabranja

9. Deskriptivna (izvještavanje, skladišta podataka, dashboardi) · Prediktivna (rudarenje podataka, rudarenje teksta, forecasting) · Preskriptivna (optimizacija, simulacija, ekspertni sustavi). **10.** Poslovni proces → granularnost → dimenzije → mjere. **11.** Poslovni zahtjev → analiza operativnog sustava → dizajn DW-a → ETL → korištenje/OLAP. **12.** Odabir podataka → predprocesiranje → transformacija → rudarenje podataka →

evaluacija. **13.** Klasifikacija (prediktivna) · regresija (prediktivna) · klasteriranje (deskriptivna) · asocijativna pravila (deskriptivna) · detekcija anomalija (deskriptivna). **14.** Dodavanje vremenske oznake · razlika snimki stanja · aplikacijsko bilježenje promjena · okidači baze podataka · dnevnik transakcija. **15.** Slice · dice · roll-up · drill-down · pivot (rotate) · drill across. **16.** Tip 1 (presnimavanje) · tip 2 (novi zapis) · tip 3 (novi atribut) · tip 4 (zasebna tablica povijesti) · hibridni tip 1 (proširenje tipa 3) · hibridni tip 2 (kombinacija 1+2+3). **17.** Transakcijske · periodička snimka stanja · akumulirajuća snimka stanja. **18.** Stupčani · strukturni · testovi poslovnih pravila. **19.** Poslovni · tehnički · operacijski metapodaci. **20.** Grupiranje · procjena gustoće · otkrivanje novih/stršećih vrijednosti · smanjenje dimenzionalnosti. **21.** x (ulaz) · y (izlaz) · $f : X \rightarrow Y$ (ciljna funkcija) · podaci $(x_1, y_1) \dots (x_n, y_n)$ · $h : X \rightarrow Y$ (hipoteza) · H (skup hipoteza). **22.** Bagging · Boosting · Stacking.

C. Usporedbe

23. Vidi *Odgovori — P3, pitanje 3*. **24.** OLTP: veliki broj transakcija, brza obrada, normalizirani podaci, puno tablica. OLAP: velika količina podataka, de-normalizirani podaci, manje tablica. **25.** Isti logički dizajn, različita fizička implementacija — vidi *Odgovori — P4, pitanje 2* i tablicu u P4. **26.** Vidi tablicu u P6 („Usporedba CDC tehnika”) i *Odgovori — P6, pitanje 3*. **27.** Vidi *Odgovori — P8, pitanje 7*. HOLAP kombinira oba: dio podataka u RDB, dio u MDB; tipično se podaci dijele na **agregate i podatke**; različite interpretacije ovisno o proizvođaču. **28.** Struktura: paralelna / sekvencijalna / hijerarhijska. Cilj: varijanca / bias / sveukupna točnost. Osjetljivost na šum: mala / veća / srednja. Interpretacija: teška / vrlo teška / nemoguća. **29.** Nadzirano: $y = f(x)$, D sadrži (x, y) , model $h(x)$, cilj greška ≈ 0 , mjere točnost/preciznost/odziv. Nenadzirano: ciljni model je generator, D sadrži samo (x) , **nema definiranog cilja ni dobro definiranih mjera** — jer ne postoji izlazna varijabla s kojom bi se rezultat usporedio. **30.** Vidi *Odgovori — P11, pitanje 8*. **31.** Vidi *Odgovori — P12, pitanje 8*.

D. Računski zadaci

32. Postupak: sortirati niz $\rightarrow$ **mean** = $\sum x/n$, **median** = središnji element (kod parnog n prosjek dvaju središnjih), **mod** = najčešća vrijednost, **raspon** = $\max - \min$, **std** = $\sqrt{(\sum (x - \bar{x})^2)/(n-1)}$, **CV** = $\text{std}/\text{mean} \cdot 100\%$, kvantili preko **quantile([.25, .5, .75])**. Referentni primjer: [5, 210, 10, 3, 5, 7, 411557, 1, 78, 220, 4589] $\rightarrow$ mean 37 880.45, mod 5, medijan 10, raspon 411 556, std 123 941.96, var 15 361 610 476.07, CV 327.19 %, $Q1 = 5$, $Q2 = 10$, $Q3 = 215$. **Zaključak koji se traži: medijan** najbolje opisuje podatke — jedna ekstremna vrijednost razvalila je sredinu, a $CV > 300\%$ potvrđuje da „tipična vrijednost” praktički ne postoji.

33. Vidi *Odgovori — P11, pitanje 2*. Postupak: $X^T \rightarrow X^T X$ (gornji lijevi element = n , ostalo $\sum x$ i $\sum x^2$) $\rightarrow$ det i inverz 2×2 preko $1/\det \cdot [[d, -b], [-c, a]] \rightarrow X^T y = [\sum y, \sum xy]^T \rightarrow$ množenje.

34. Vidi *Odgovori — P12, pitanje 4*. **35.** Vidi *Odgovori — P12, pitanje 5*. Opće pravilo: iz uzorka od k elemenata dobiva se $2^k - 2$ pravila.

36. Tipovi problema u tablici iz P6: **reprezentacija** („Anić, Ivan” vs. „Ivan Anić”) · **jedinstvenost** (ID 233 dvaput) · **kontradikcija** (ista godina rođenja, starost 26 vs. 36) · **netočne vrijednosti** (datum 33.4.87, telefon 999999999) · **nedostajuće vrijednosti** · **referencijalni integritet** (pošta 99999 nije u šifrniku) · **greške** („Rjeka”, 1000 $\rightarrow$ „Hrvatska” umjesto grada) · **duplikati** (233 i 234 su ista osoba).

37. Promjena **i5** $\rightarrow$ **i7** za zapis 1200345 „Acer A5 Računalo”:

- **Tip 1:** 1200345 | Acer A5 | i7 — stara vrijednost prepisana, povijest izgubljena.
- **Tip 2:** 1200345 | Acer A5 | i5 | od 2018-01-12 | do 2019-03-15 | N + 1200346 | Acer A5 | i7 | od 2019-03-16 | – | Y.

- **Tip 3: 1200345 | Acer A5 | Procesor tip: i7 | Stari procesor tip: i5** — jedan redak, dodan stupac.

E. Primjena / esejska

38. Postupak: iz opisa izvuci **imenice** → **entiteti i atributi, glagole** → **veze**; primijeni smjernice za razlikovanje entiteta i atributa (entitet sadrži attribute i ima veze); za svaku vezu odredi naziv, sudionike, stupanj i **kardinalnost** (1:1, 1:M, M:M); nacrtaj — entiteti pravokutnici, atributi ovali spojeni ravnom linijom, veze rombovi s oznakom kardinalnosti na krajevima. Ne zaboravi implicitna ograničenja iz teksta (npr. u case studyju: samo jedan proizvod po narudžbi; zemlja plaćanja nije vezana uz partnera).

39. Postupak: (1) poslovni proces = onaj podržan OLTP-om koji odgovara postavljenom cilju; (2) granularnost = **najniža razina**, tipično pojedina transakcija ili linija dokumenta; (3) dimenzije = odgovori na **Tko/Što/Gdje/Kada**, uz **obaveznu dimenziju vrijeme**, kvantitativne attribute pretvoriti grupiranjem, definirati hijerarhije; (4) mjere = kvantitativni atributi asocijativnog entiteta. Star shema: t.č. u sredini sa surogat ključem, mjerama i stranim ključevima; dimenzije oko nje u vezi 1:M.

40. Logika izbora: atribut čija promjena **nema analitičkog značaja** (npr. ispravak tipfelera u nazivu) → **tip 1**. Atribut čija promjena mora biti vidljiva u povijesnim izvješćima (npr. kategorija kupca, prodajna regija) → **tip 2**; to je i preduvjet za ispravno rukovanje kasno dolazećim činjenicama. Ako se traži samo usporedba „prije/poslije” jedne promjene → **tip 3**. Ako se trenutno i povijesno stanje analiziraju odvojeno i upiti nad trenutnim moraju biti brzi → **tip 4**. Ako su promjene redovite i predvidive (npr. godišnje) → **hibridni tip 1**.

41. Logika izbora CDC-a: ako izvorišna baza **ne podržava** mehanizme praćenja promjena i ne smije se dirati → **razlika snimki stanja** (nema utjecaja na bazu ni aplikacije, niska složenost — cijena su resursi i vrijeme). Ako je dopušten razvoj i traži se najmanji utjecaj na performanse uz punu povijest → **dnevnik transakcija**. Ako izvor već ima pouzdane vremenske oznake i brisanja nisu problem → **vremenska oznaka**. **Okidače** izbjegavati kad je baza opterećena; **aplikacijsko bilježenje** samo kad se aplikacije ionako mijenjaju.

42. Obrazac odgovora: *zadaca* → *izlazna varijabla* → *izvor*. Primjeri: predviđanje odljeva kupaca → klasifikacija → binarna oznaka „otišao/ostao” → povijest transakcija i ugovora. Predviđanje potrošnje energije → regresija → kWh (kontinuirano) → mjerni podaci + prihodi kućanstva. Segmentacija kupaca → klasteriranje → nema izlazne varijable → transakcijski podaci. Povezanost proizvoda → asocijativna pravila → nema izlazne varijable → računi/košarice. Otkrivanje prijevara → detekcija anomalija → da/ne ili score → zapisi transakcija/poziva.

43. Zato što se ne uči **sama f**, nego se iz prostora hipoteza H bira h koja f **aproksimira na dostupnim podacima**. Uvjet je da u podacima **postoji uzorak** i da podataka ima dovoljno. Koliko dobro ta aproksimacija vrijedi izvan viđenih primjera provjerava se **validacijom na testnom skupu** — a upravo je generalizacija, a ne trening greška, mjera uspjeha.

44. OLAP zahtijeva da **korisnik unaprijed zna koje pitanje postaviti** — odabire mjere, dimenzije, filtere i izgled izvješća. Analiza je time ovisna o poslovnom korisniku i njegovom ekspertnom znanju, a odluka se često donosi na temelju **intuicije**. Obrasci koje nitko nije pretpostavio ostaju neotkriveni, ma koliko podataka bilo — otuda *data rich, information poor*. Rješenje su alati koji **sami** pronalaze znanje u podacima, tj. rudarenje podataka.

45. Jer greška 0 na treningu znači da je model savršeno opisao **podatke koje je već vidio**, što je moguće i tako da nauči **šum** umjesto obrasca (overfitting, visoka varijanca). Simptom je vrlo mala trening greška uz vrlo

veliku test grešku. Kvaliteta se zato mjeri na **neviđenim podacima**, a između hipoteza sa sličnom trening-točnošću bira se ona koja najbolje **generalizira**.

Kraj skripte.